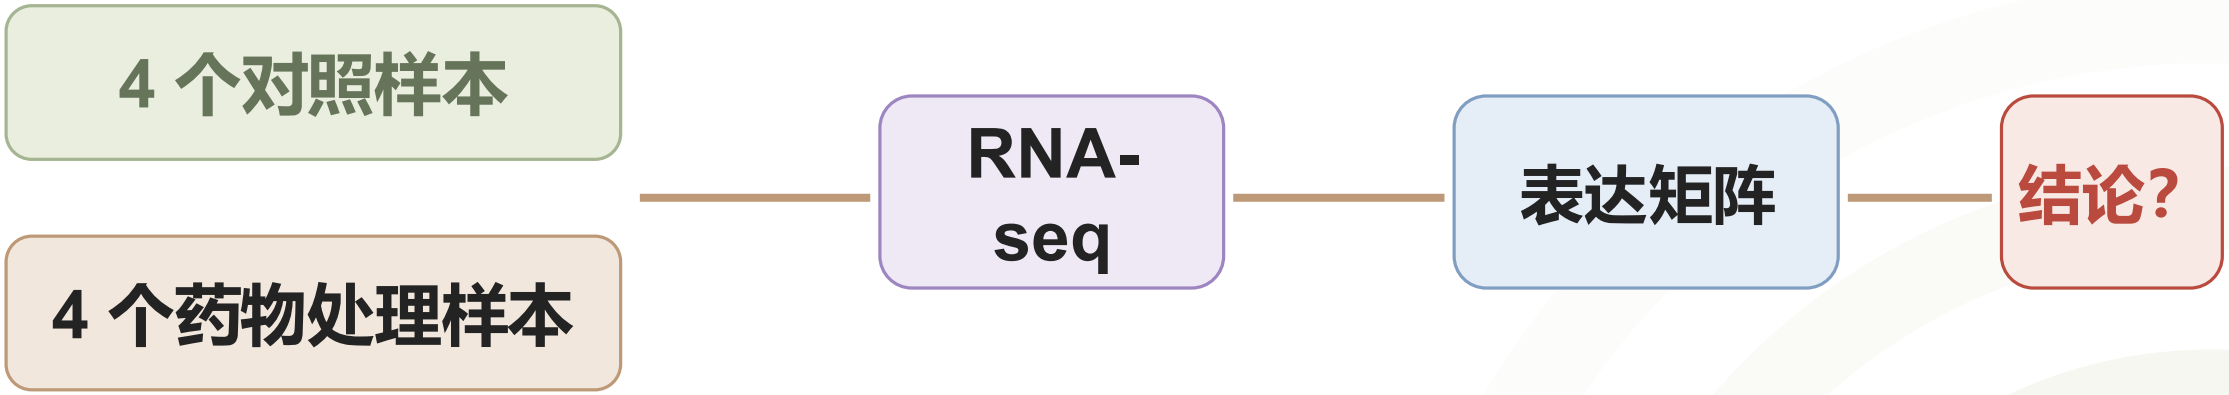
转录组数据检测和分析

陈同

中国中医科学院

中药研究所

药物处理后，细胞发生了什么？



处理组与对照组的稳定表达差异的基因都受哪些因素的影响？

可能的干扰：批次、性别、样本质量、测序深度和极端高表达基因

面对一套转录组数据，我们也许都有这些疑问

数据 FASTQ 里有什么，哪些质控异常需要追查

定量 genome、cDNA、GTF 如何配合，Salmon 输出结果怎么使用

统计 Gene counts、TPM 和标准化各自解决什么问题

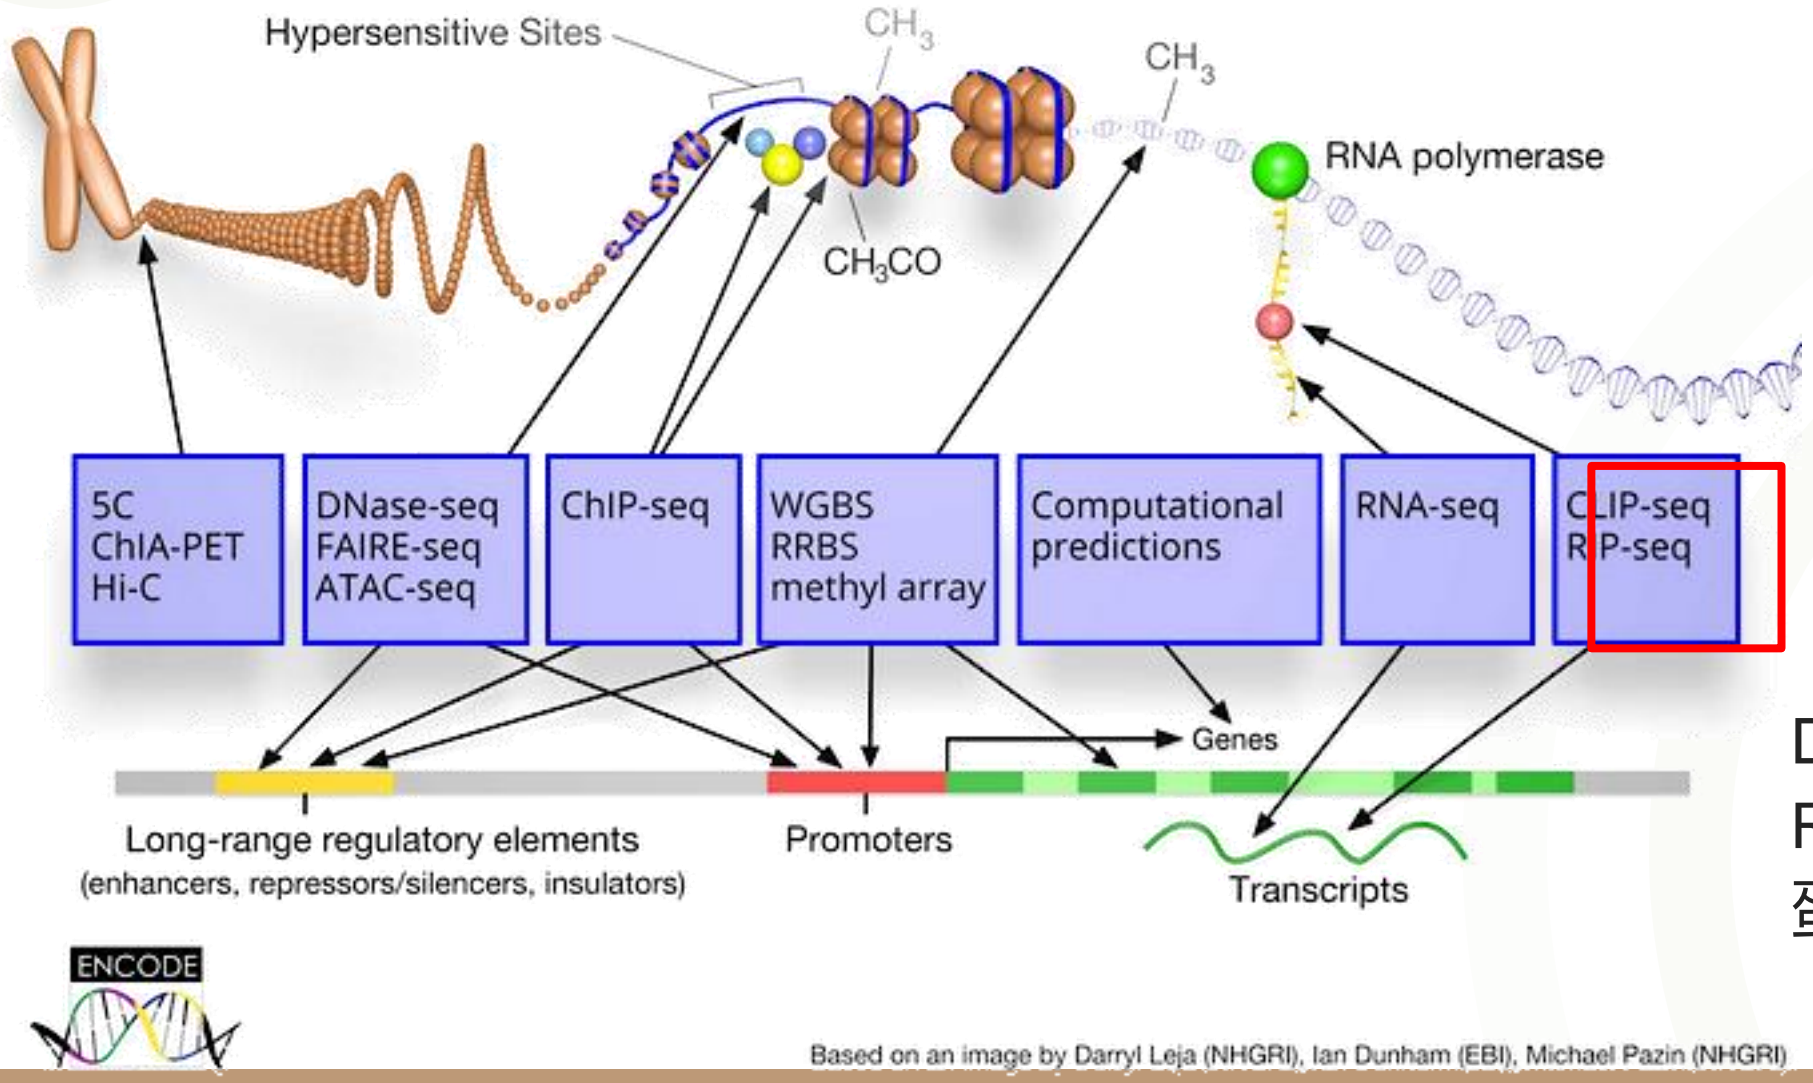
解释 差异基因、GO 和 GSEA 富集分析能支持哪些结论

01

RNA与转录组

我们在测量什么?

RNA-seq在组学测序技术中的位置



RNA-seq 记录某个时间点上细胞正在使用哪些基因

DNA 提供潜在能力
RNA 反映当前状态
蛋白质更接近功能输出

转录组能检测什么？

转录组是某个细胞、组织或样本在特定时间的 RNA 集合

spatial

不同组织与细胞不同

temporal

会随时间和处理变化

dynamic

是状态快照，不是固定清单

因此：转录组的结论总要带上样本、条件和时间

转录组测序能回答什么，不能回答什么？

直接观测

- 转录本丰度
- 剪接与转录本结构
- 新转录本、融合和 RNA 编辑线索

需要谨慎推断

- 蛋白质水平与活性
- 通路真正被激活
- 某基因导致表型

需要补强

- 蛋白质组或功能测定
- 遗传操作与救援实验
- 时间序列或多组学一致性

从 PCR 到 RNA-seq：测量范式的变化

1

PCR / EST

针对已知目标，通量有限

2

表达芯片

并行测量已知探针，依赖先验序列设计

3

RNA-seq

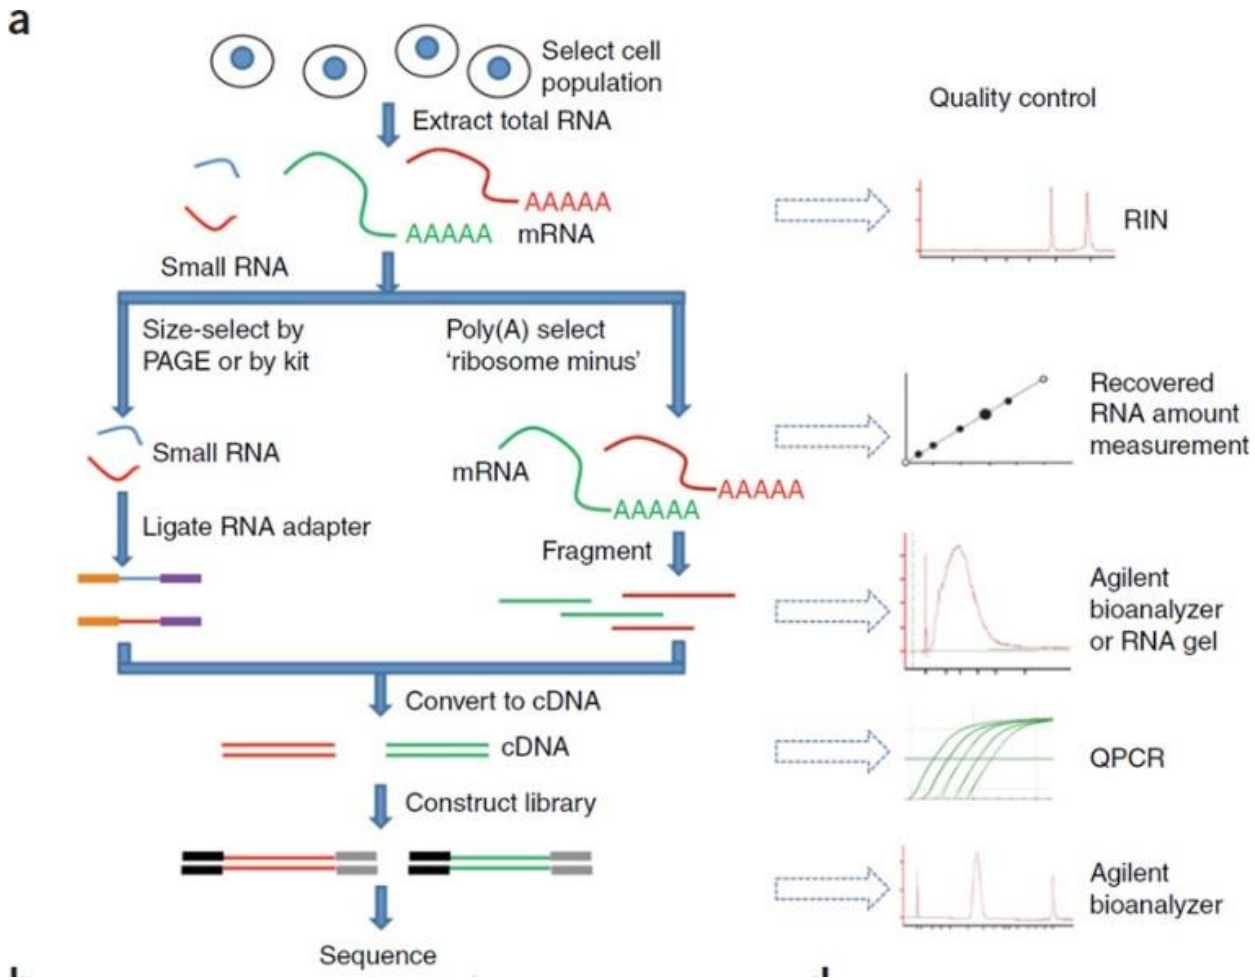
数字化计数，同时看表达与结构

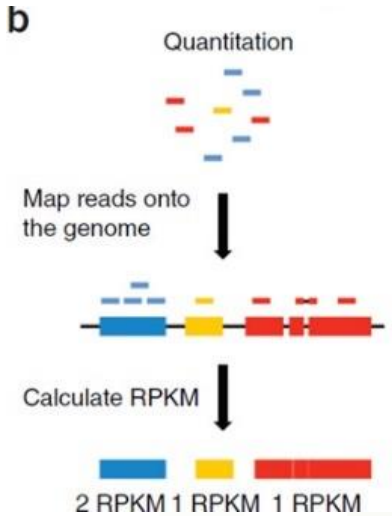
4

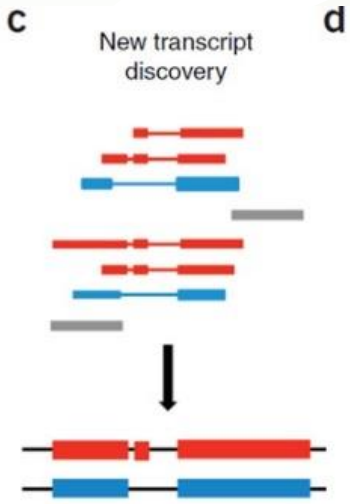
单细胞/长读长

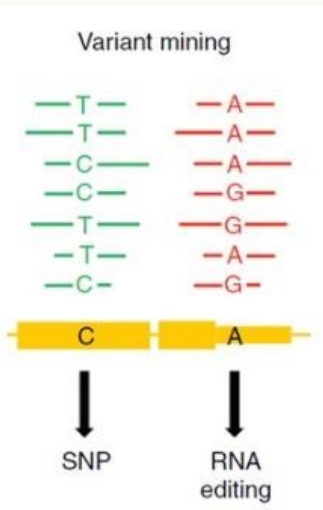
把平均信号拆到单细胞和全长转录本

转录组流程及应用

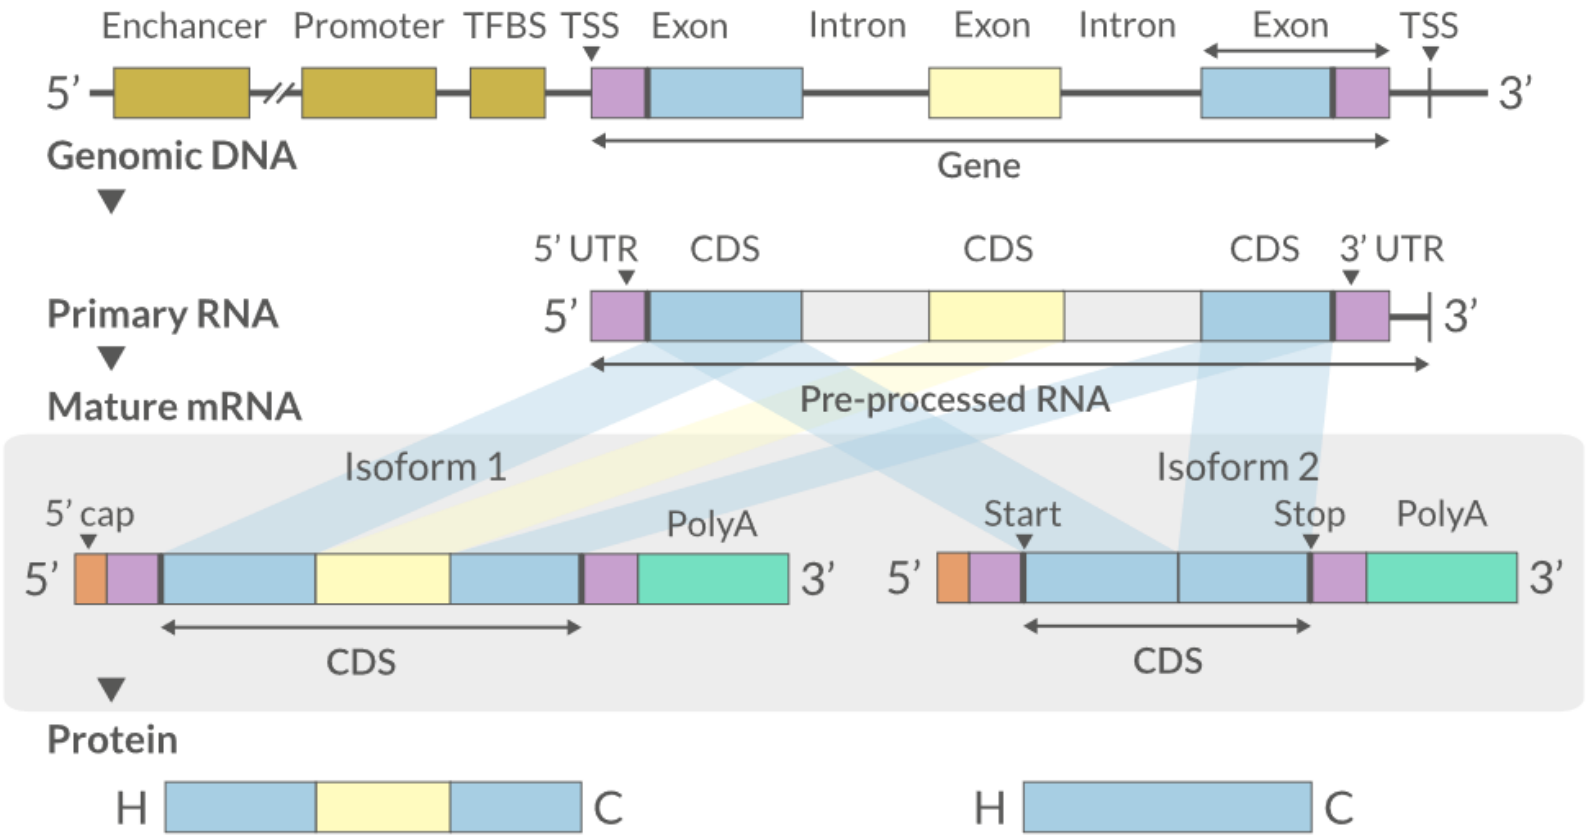

a
Select cell population
Extract total RNA
AAAAA
AAAAA mRNA
Small RNA
Size-select by PAGE or by kit
Poly(A) select 'ribosome minus'
Small RNA
mRNA
AAAAA
AAAAA
Ligate RNA adapter
Fragment
Convert to cDNA
cDNA
Construct library
Sequence
Quality control
RIN
Recovered RNA amount measurement
Agilent bioanalyzer or RNA gel
QPCR
Agilent bioanalyzer


b
Quantitation
Map reads onto the genome
Calculate RPKM
2 RPKM 1 RPKM 1 RPKM


c
New transcript discovery


d
Variant mining
T
T
C
C
T
T
C
A
A
A
G
G
A
G
C
A
SNP
RNA editing

从基因到转录本到蛋白是一对一还是一对多？



- The transcriptome is spatially and temporally dynamic
- Data comes from functional units (coding regions)
- Only a tiny fraction of the genome

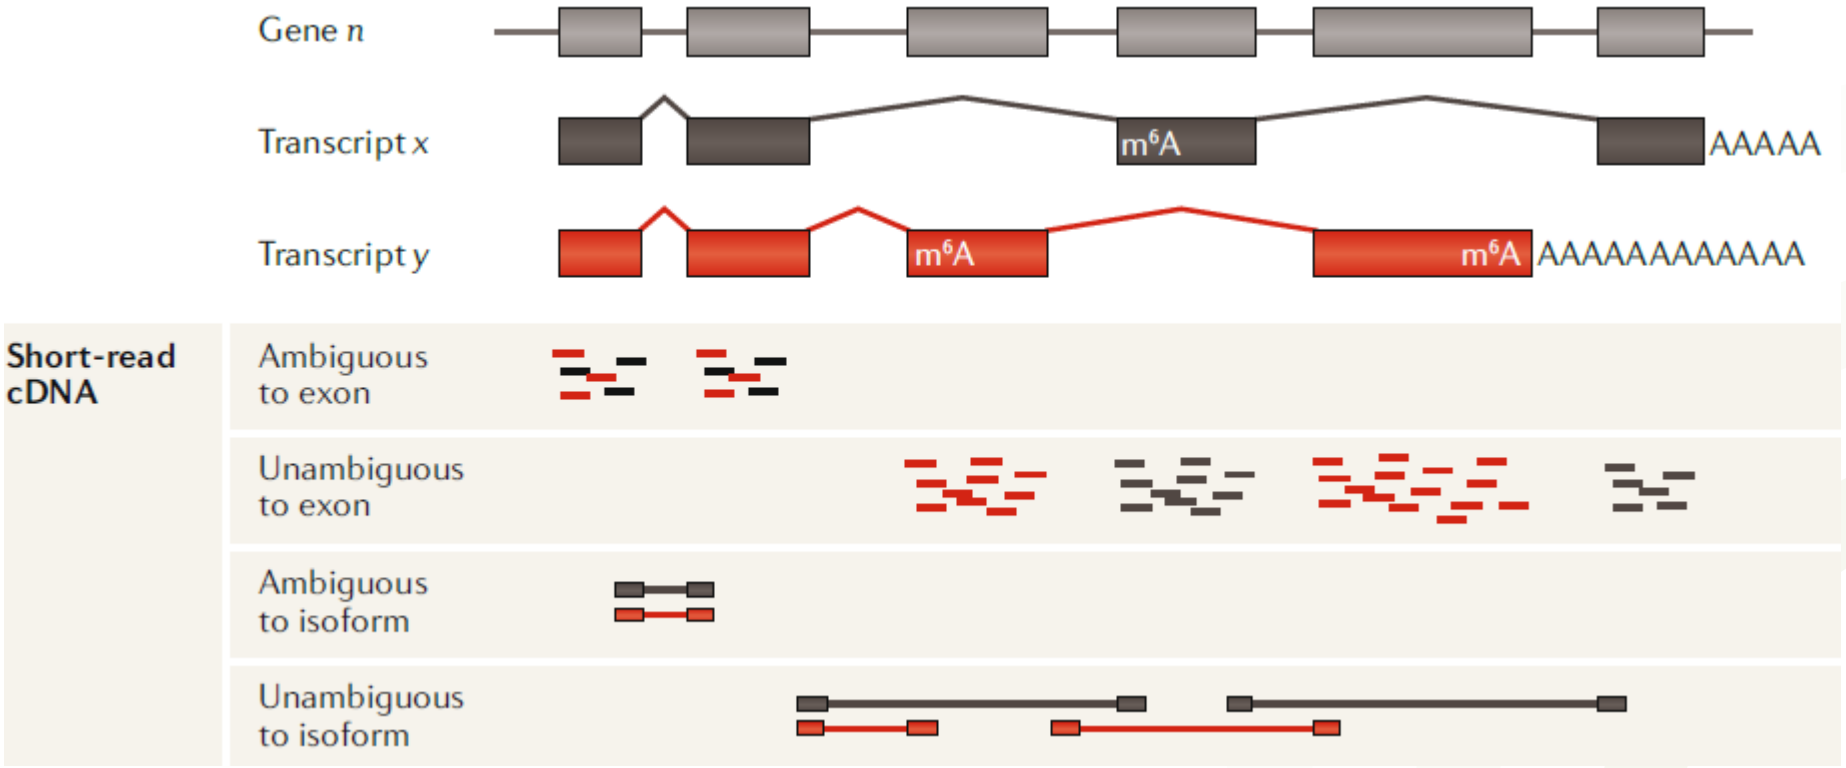
一个基因可以产生多个转录本。

剪接位点、5′/3′ UTR 和编码区共同决定转录本结构。

基因定量与转录本定量回答的问题不完全相同。

基因注释GTF/GFF 文件记录了这些结构

基因、转录本和外显子：三个层级



基因层定量适合组间总体表达比较。

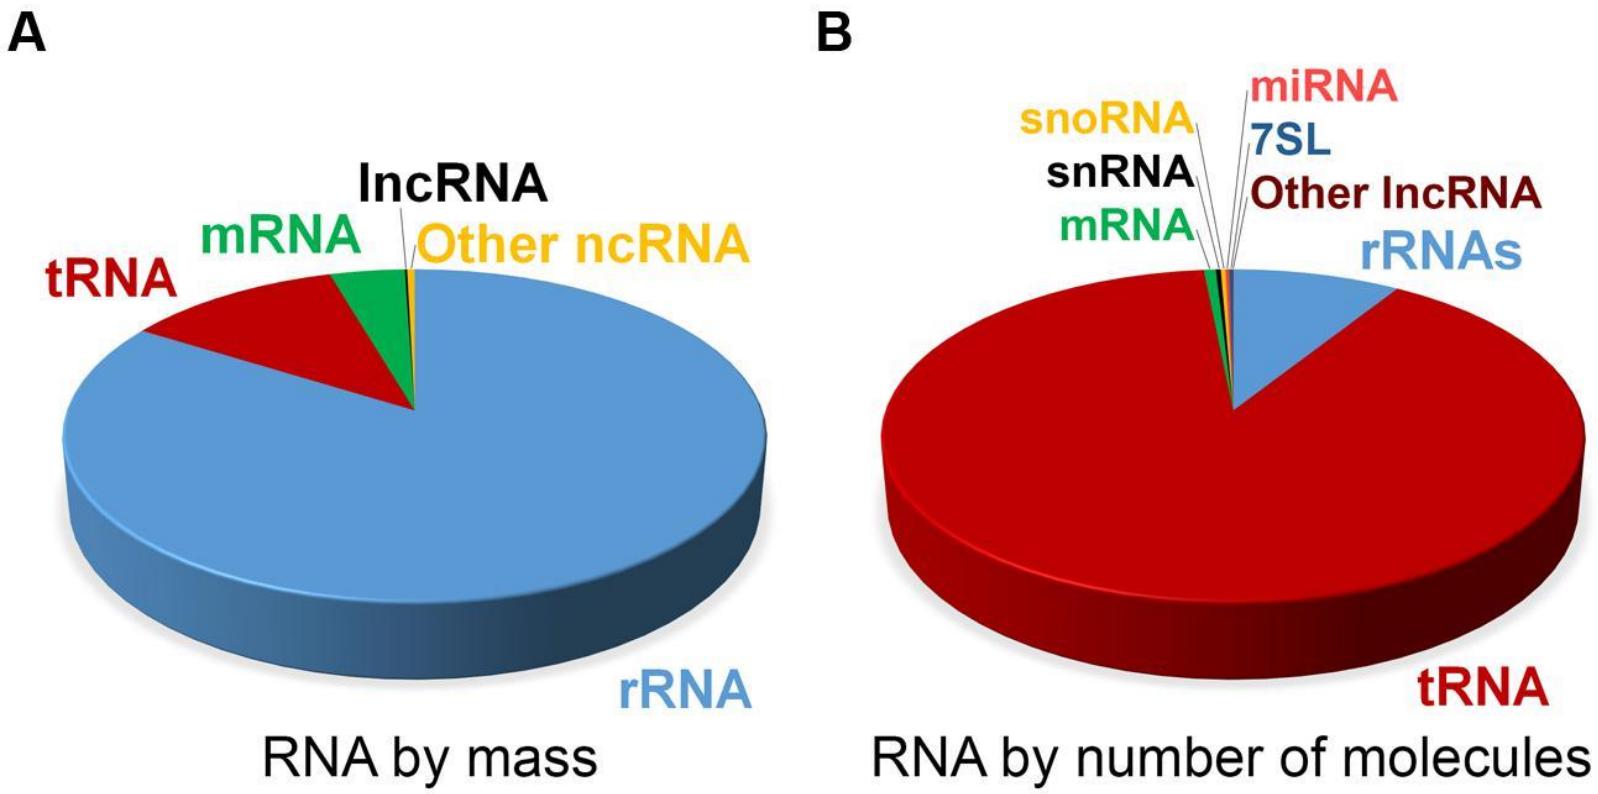
转录本层定量能反映 isoform switching，但不确定性更高。

外显子/剪接位点层适合局部可变剪接检验。

英文综述全文

中文全文翻译版

不同RNA种类总量不同，分子数不同



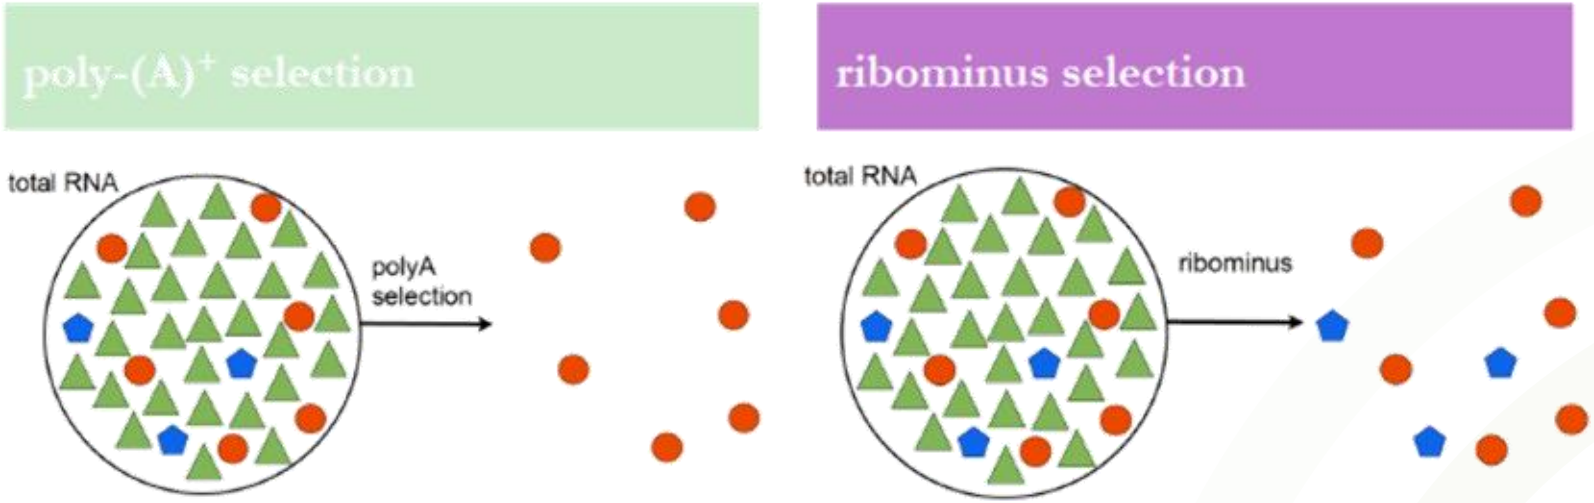
rRNA 占总 RNA 质量的主体。若不去除，会占用大量 reads。

mRNA 所占比例小，却是常规表达分析的主要对象。

建库策略会决定我们最终能看到哪些 RNA。

poly(A) 富集与 rRNA 去除不等同

不同的建库策略选择不同的 RNA 类型



- Most commonly used
- Many non-coding RNAs will be missed
- Requires more RNA
- Requires non-degraded RNAs

- More complex and expensive
- Provides “complete” transcriptome
- Requires less RNA
- Less affected by RNA degradation

poly(A) 富集：主要观测成熟真核 mRNA。

去 rRNA：保留更广的 RNA 种类，包括部分非编码 RNA。

一个细胞中RNA的量有多少?

总量

典型哺乳动物细胞约 10–30 pg RNA

某些小细胞如 T 细胞可低至 1–2 pg

分子数

一个细胞大约 36万个 mRNA 分子，12000 不同种类转录本

低丰度转录本可仅数个拷贝

分析后果

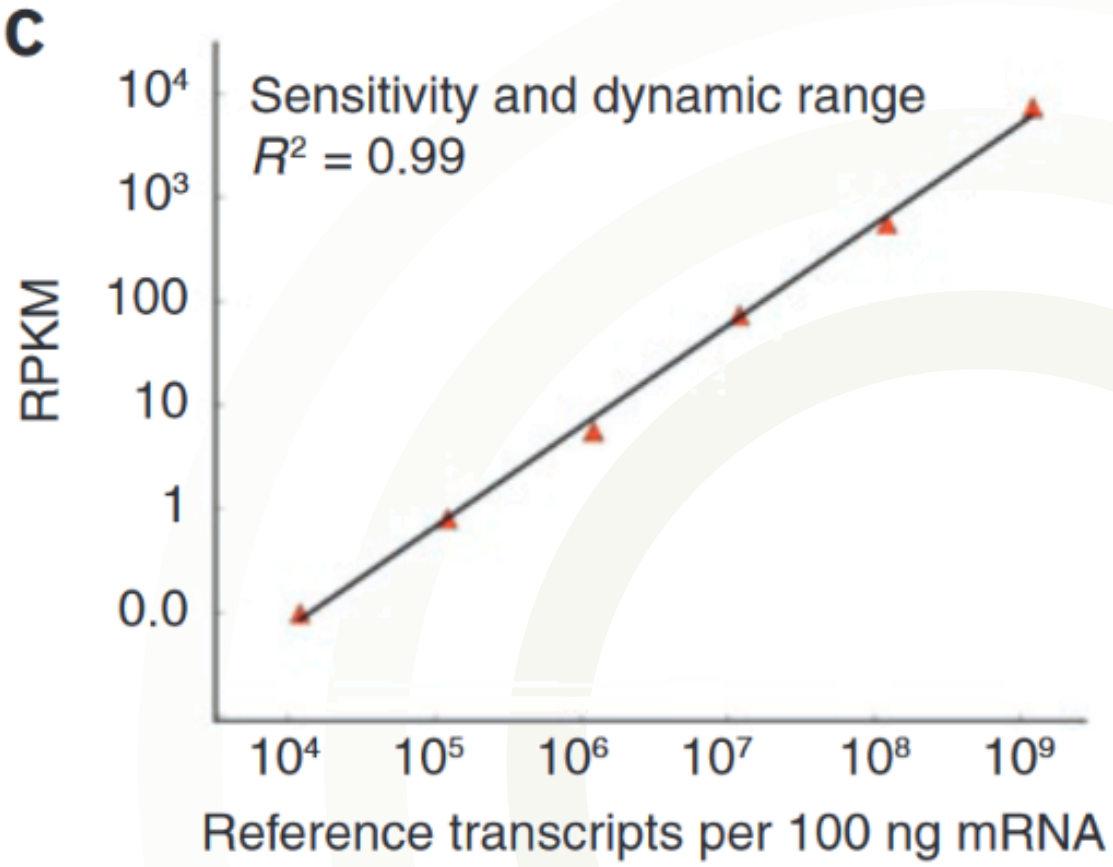
低起始量放大了抽样噪声

单细胞中 dropout 与“未表达”不等价

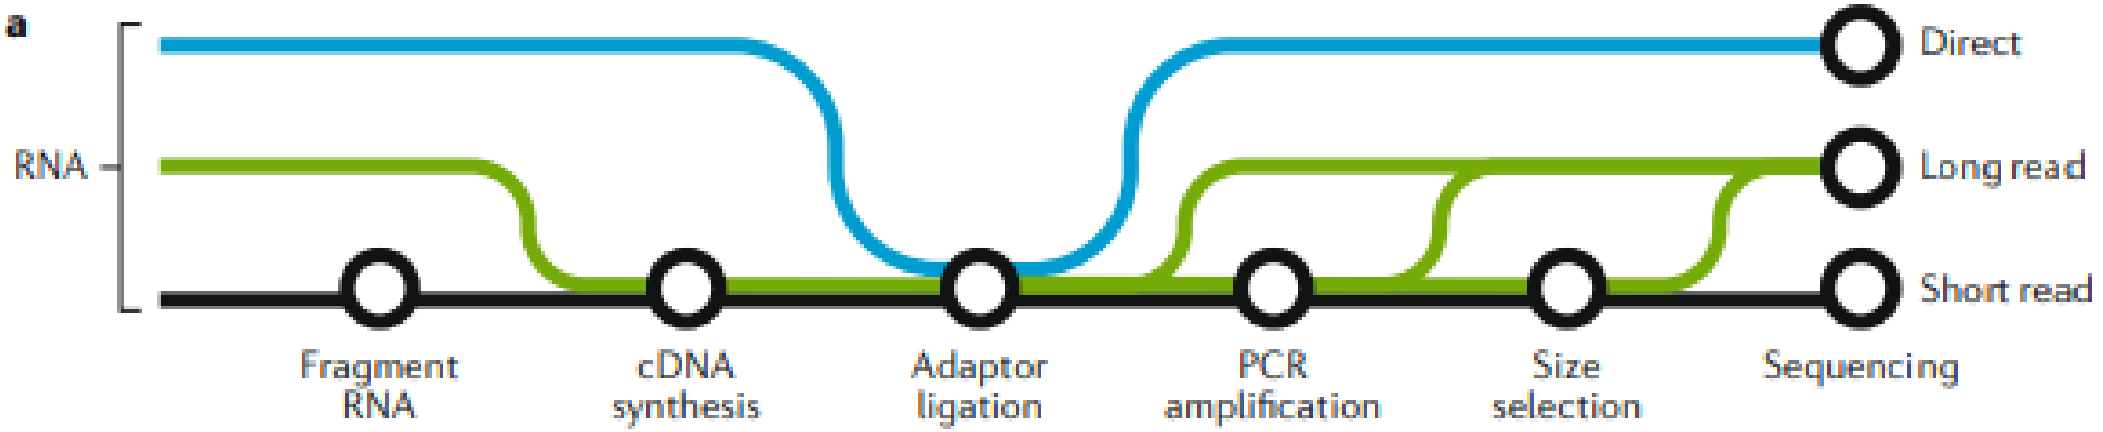
QIAGEN ***RNA Sequencing and Analysis***

转录组检测的灵敏度和动态范围

- 低丰度分子可因抽样不足而测不到。
- 进入线性范围后，read 计数与RNA量近似成比例。
- 高丰度转录本容易达到稳定定量，低丰度需要更多 reads。



短读长、长读长与直接 RNA 测序



短读长

定量成熟，但需要重建转录本

长读长

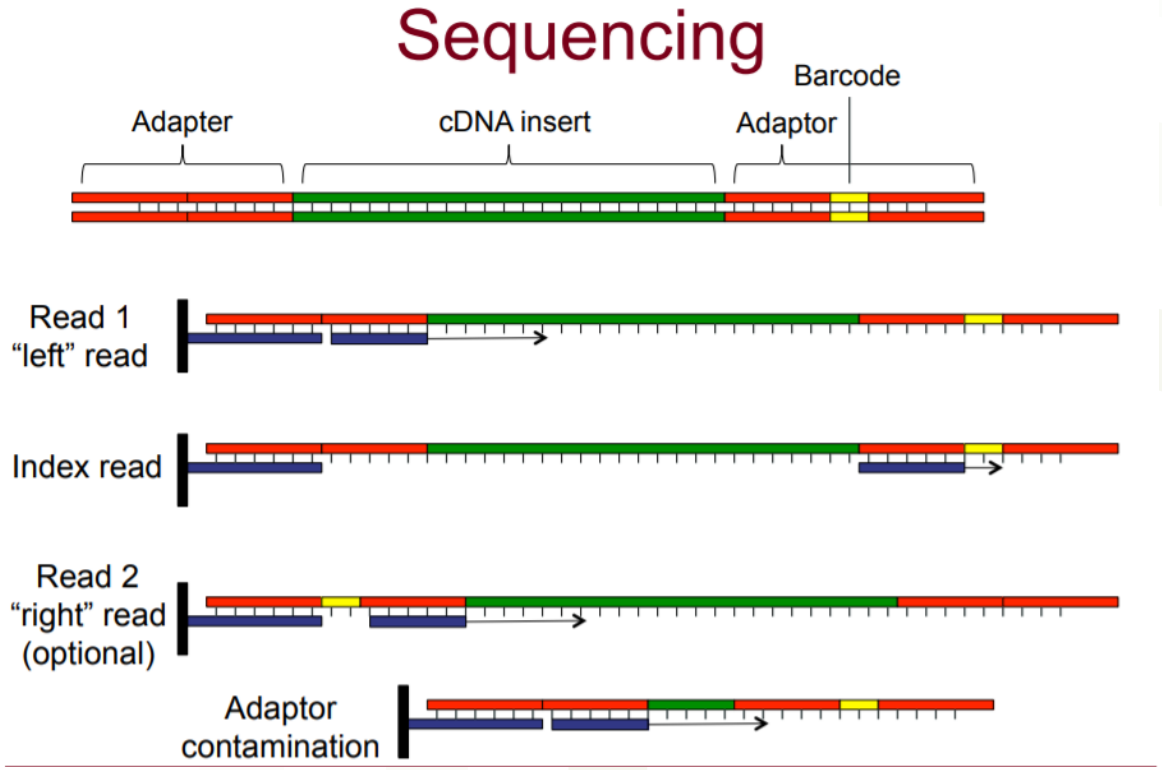
更容易看到完整异构体

直接 RNA

保留 RNA 本身的信息如表观修饰等

读长、插入片段和双端测序

- 读长决定单条 read 能解析多少序列上下文。
- 插入片段长度决定我们从一个分子中采样的范围。
- 双端读取增强比对唯一性，对剪接和融合更有帮助。
- 对单纯基因层差异表达，更多样本往往比更长 reads 更有价值。



普通转录组测序结果是混合样品的结果

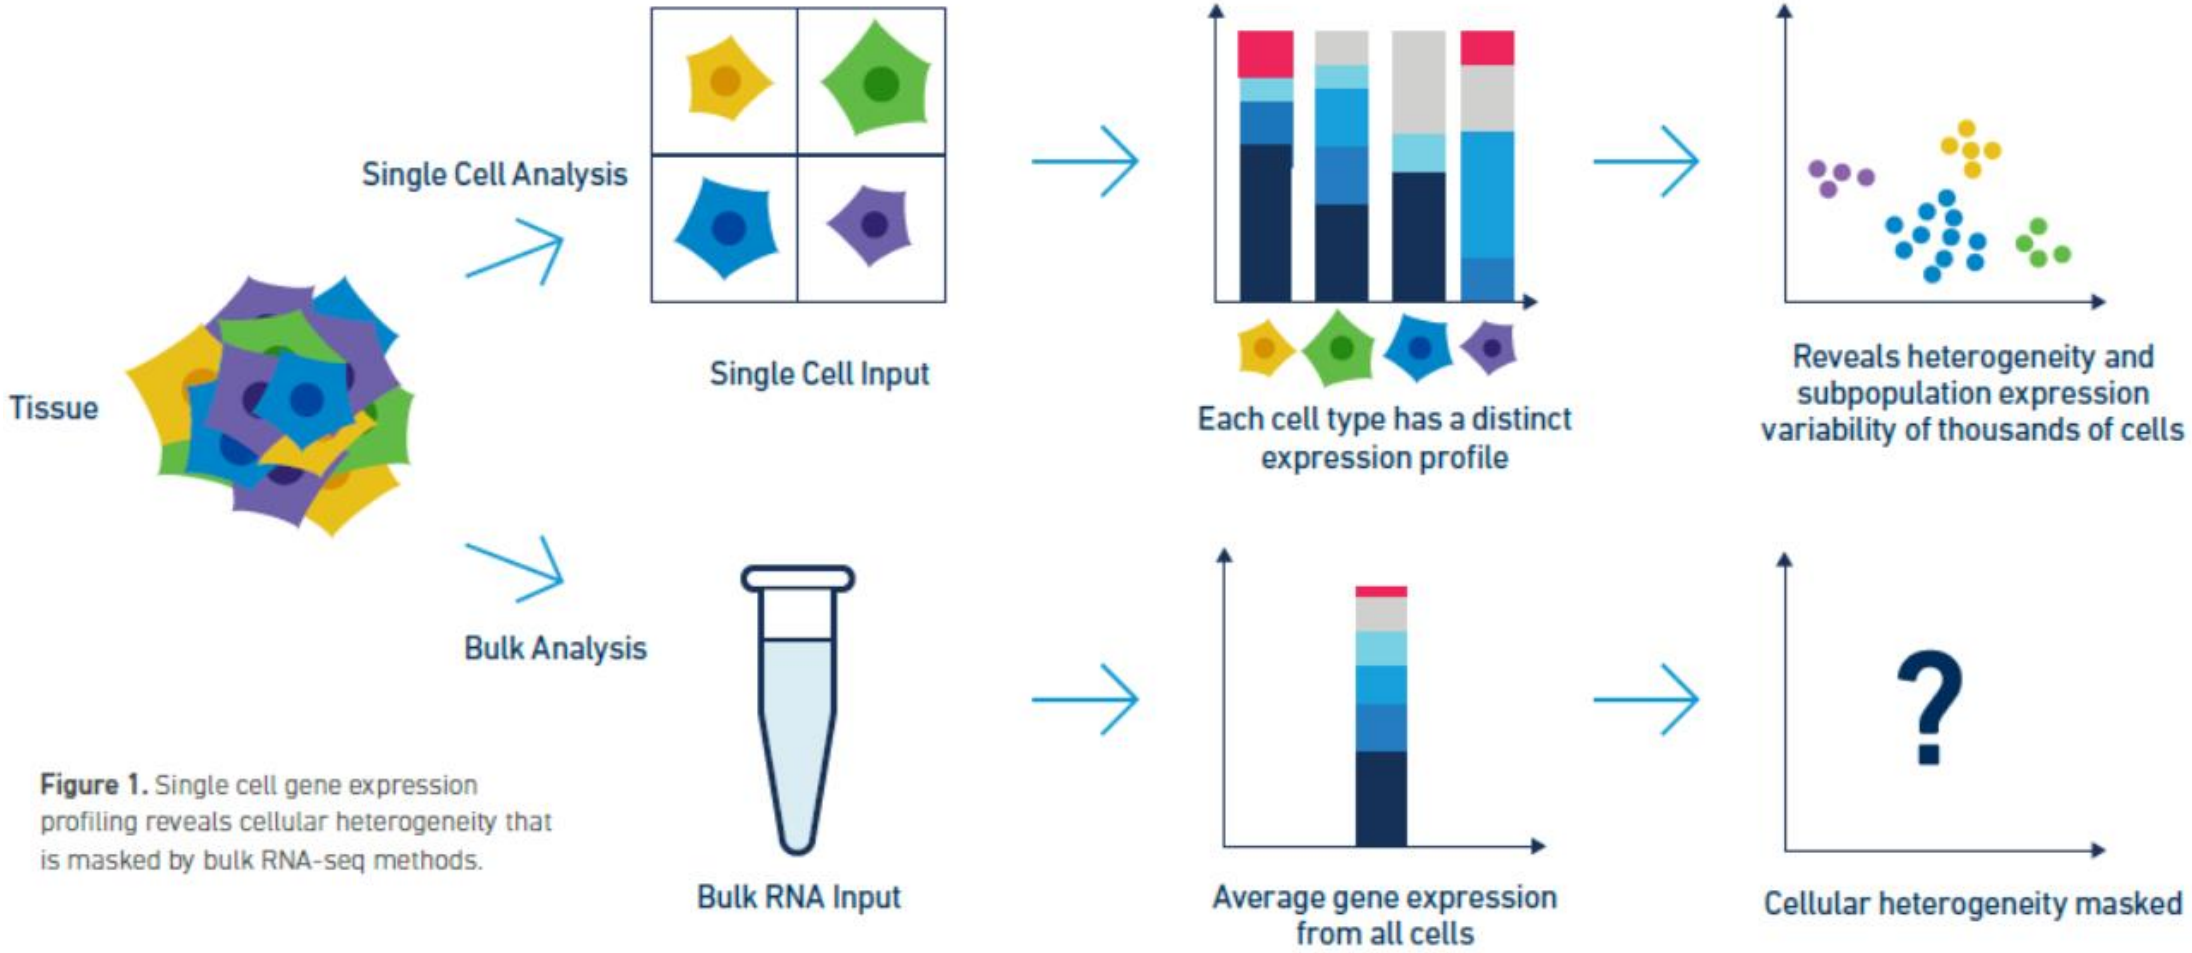


Figure 1. Single cell gene expression profiling reveals cellular heterogeneity that is masked by bulk RNA-seq methods.

平均表达可能隐藏两种完全不同的变化

场景 A：细胞内变化

- 细胞比例不变
- 每个细胞中目标基因升高
- 支持处理诱导调控

场景 B：组成变化

- 目标高表达细胞比例增加
- 每个细胞内表达不变
- 更像组织构成改变

如何区分

- 流式/组织学计数
- 单细胞或空间数据
- 细胞比例去卷积与敏感性分析

同一个 bulk 转录组差异可以对应不同的生物学故事。

某基因的 RNA 显著升高，可以直接得出什么结论？

蛋白质一定升高

该通路已激活

转录水平发生变化

某基因的 RNA 显著升高，可以直接得出什么结论？

蛋白质一定升高

该通路已激活

转录水平发生变化

最稳妥的结论是转录水平发生变化。蛋白质和功能活性需要额外证据。

02

实验设计和分析测策略

取样前设计好 Metadata 文件

Sample	Condition	Batch	Individual	Sex
untrt_N61311	untrt	A	N61311	F
untrt_N052611	untrt	A	N052611	M
untrt_N080611	untrt	B	N080611	M
untrt_N61011	untrt	B	N61011	F
trt_N61311	trt	A	N61311	F
trt_N052611	trt	A	N052611	M
trt_N080611	trt	B	N080611	M
trt_N61011	trt	B	N61011	F

一张好的 metadata 表应该同时告诉我们：

- 主要分组变量：condition / treatment / time
- 哪些样本属于同一组
- 哪些因素需要进入统计模型
- 可能影响表达的协变量：batch、sex、age、subject、RIN
- 不同组直接的样本属性是否均衡
- 文件名与样本名是否一致

配对设计：用每个个体做自己的对照

适用场景

同一患者处理前后

左右配对组织

同一系统多时间点

模型直觉

design = ~ subject + condition

先解释个体基线差异

再估计处理系数

常见错误

丢掉 subject ID

把配对样本当独立重复

某些个体只有一个条件

样本属性不均衡会有什么影响?

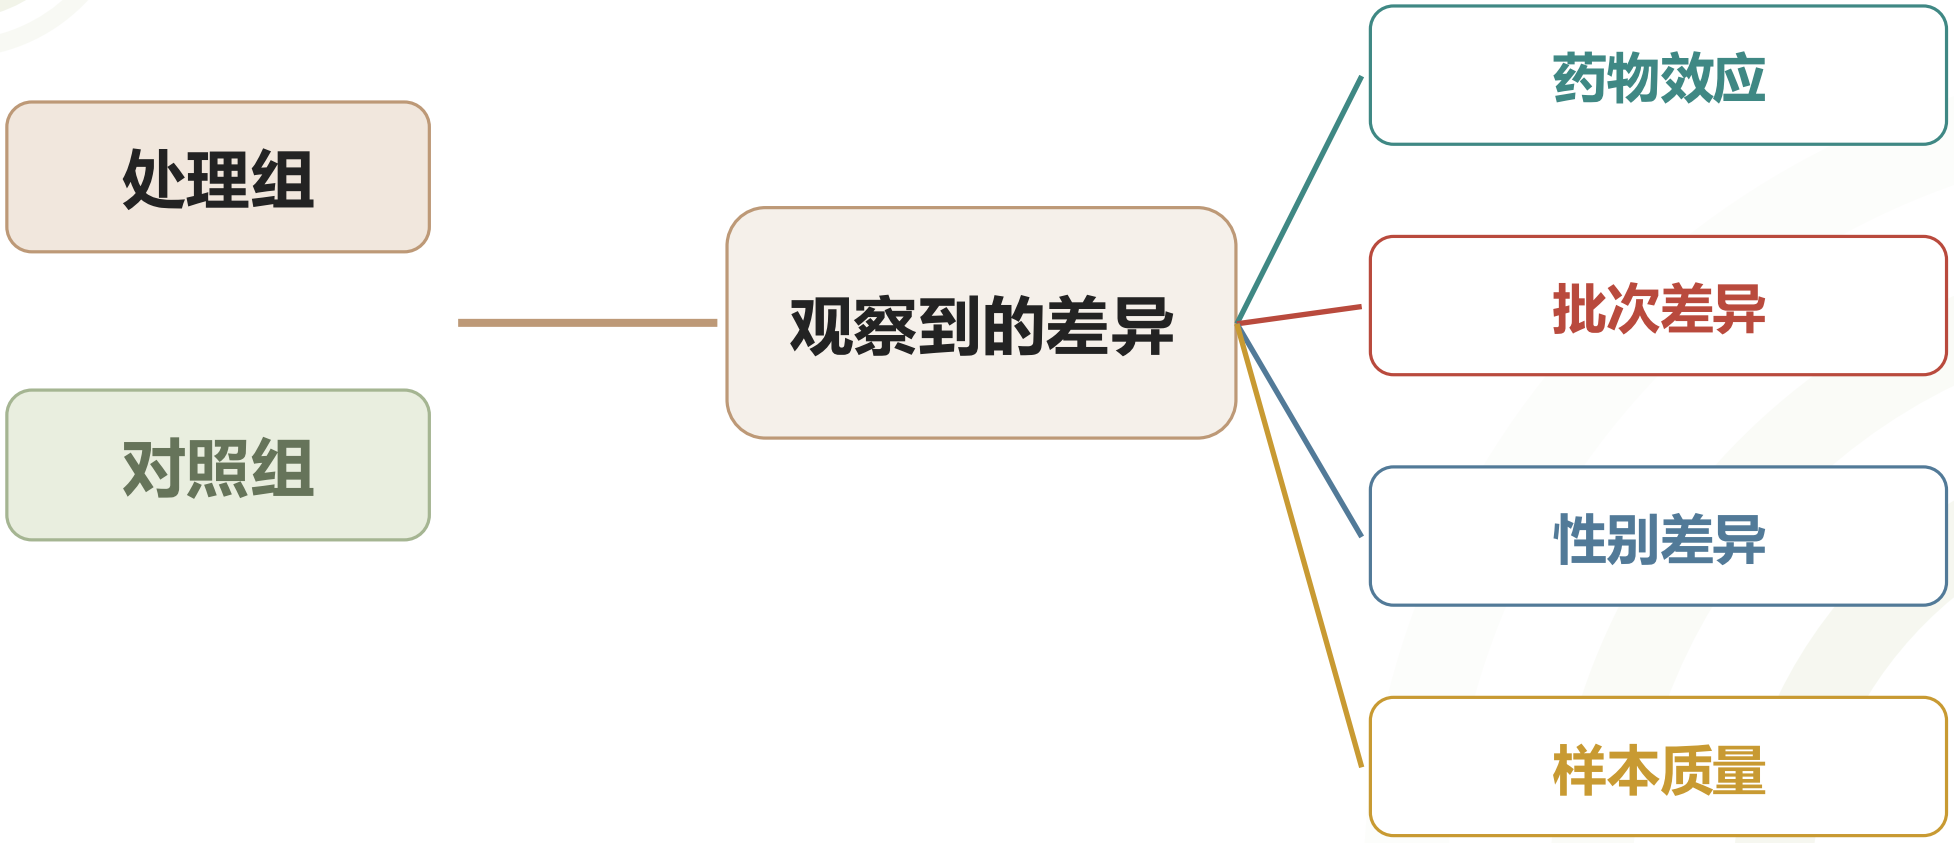
若处理组全为女性、对照组全为男性，加入 sex 协变量能恢复药物效应吗?

样本属性不均衡会有什么影响?

若处理组全为女性、对照组全为男性，加入 sex 协变量能恢复药物效应吗?

不能。sex 与 药物处理完全混杂，数据中没有信息区分两者。

药物效应和混杂效应



设计矩阵的任务是尽量分离这些来源

生物学重复能解决什么问题?

重复用于估计同一条件下的生物学变异

对照 1　对照 2　对照 3　对照 4

处理 1　处理 2　处理 3　处理 4

组内差异　　组内差异

组间差异

没有重复时，数学上无法区分药物效应与随机波动

生物学重复和技术重复

生物学重复

- 独立个体/培养物/组织
- 估计系统的真实变异
- 决定结论能否推广

技术重复

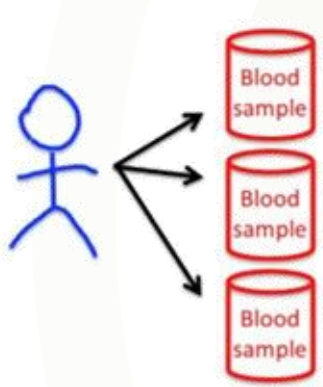
- 同一生物样本的重复建库/测序
- 估计技术流程变异
- 通常不能替代生物学重复

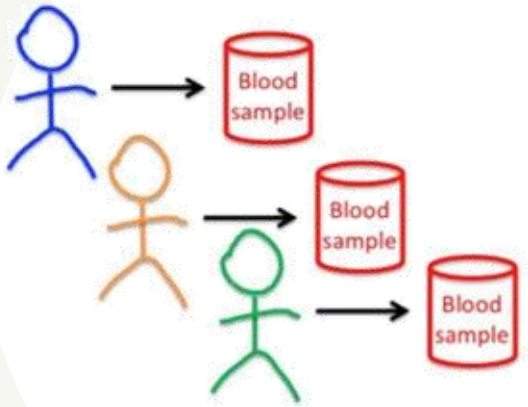
案例中

- 8 个独立样本 = 8 个生物学重复
- 同一库分两个 lane 不是新重复
- 合并 lane 后再建模

为什么需要生物学重复?

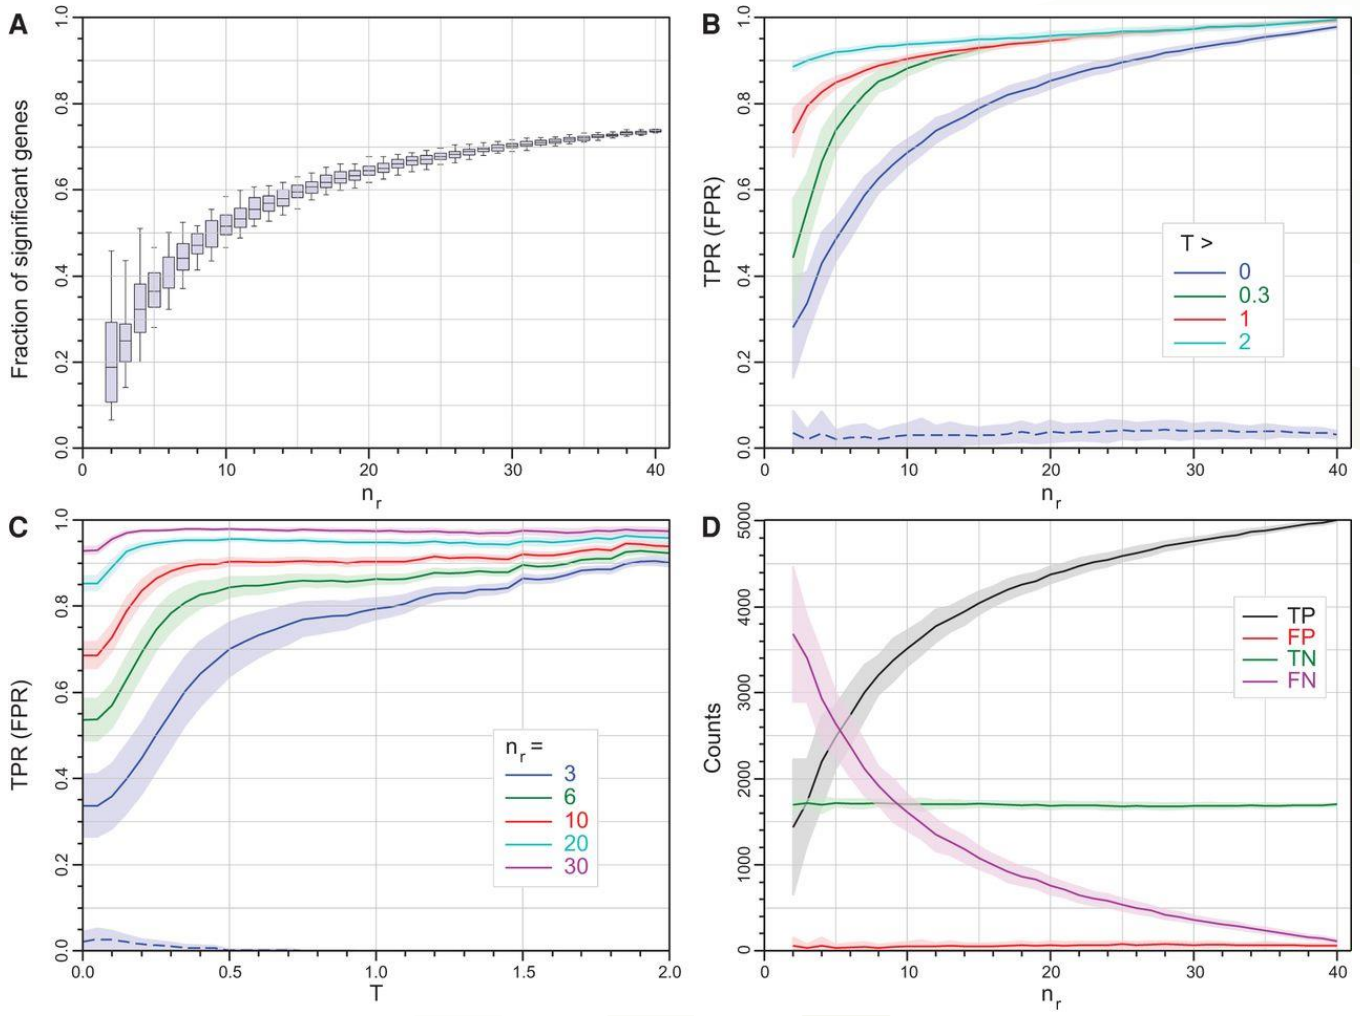
- 估计同一条件下的离散程度，从而区分效应与随机波动。
- 发现异常样本、批次和隐藏异质性。
- 在给定假阳性水平下获得更高检验功效。
- 支持对“这类样本”而不是“这一管样本”的结论。



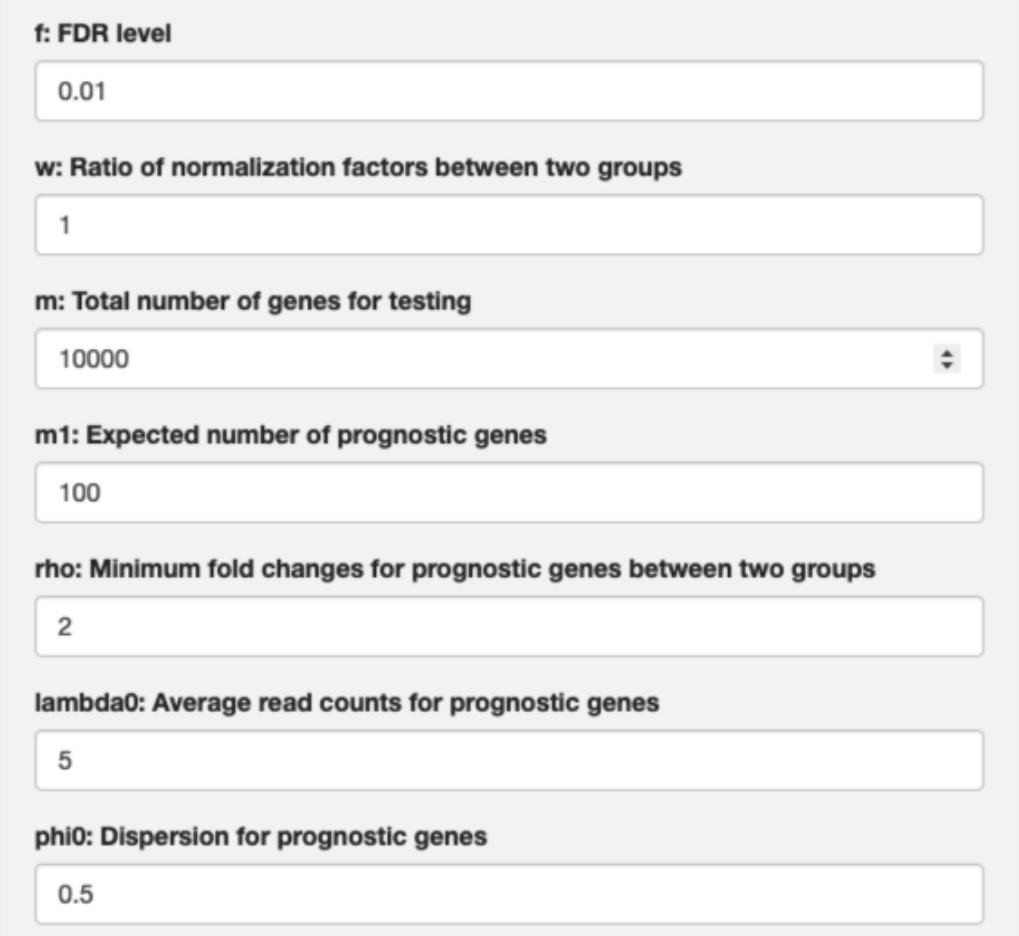


三个重复是下限，但并不总是足够

- 当组内变异大、效应小或需要多个协变量时，3个重复往往不够。
- 小样本的差异基因集合对抽样非常敏感。
- 增加重复常同时提高功效、稳定性和异常检测能力。



RnaSeqSampleSize根据经验、预实验估计生物重复



参数变化	样本量趋势
目标 Power：0.8 → 0.9	增加
FDR：0.05 → 0.01	增加
Fold change：2 → 1.5	明显增加
平均 count：50 → 5	增加
Dispersion：0.1 → 0.5	明显增加
检验基因数增加	通常增加
真正差异基因比例降低	通常增加
两组测序深度不平衡	有效功效降低

转录组测序多少生物重复合适 https://cqs-vumc.shinyapps.io/rnaseqsamplesizeweb/

预算固定时，更多样本还是更高深度?

增加样本数

- 提高差异表达功效
- 更好估计生物学变异
- 更适合小效应与异质系统

增加测序深度

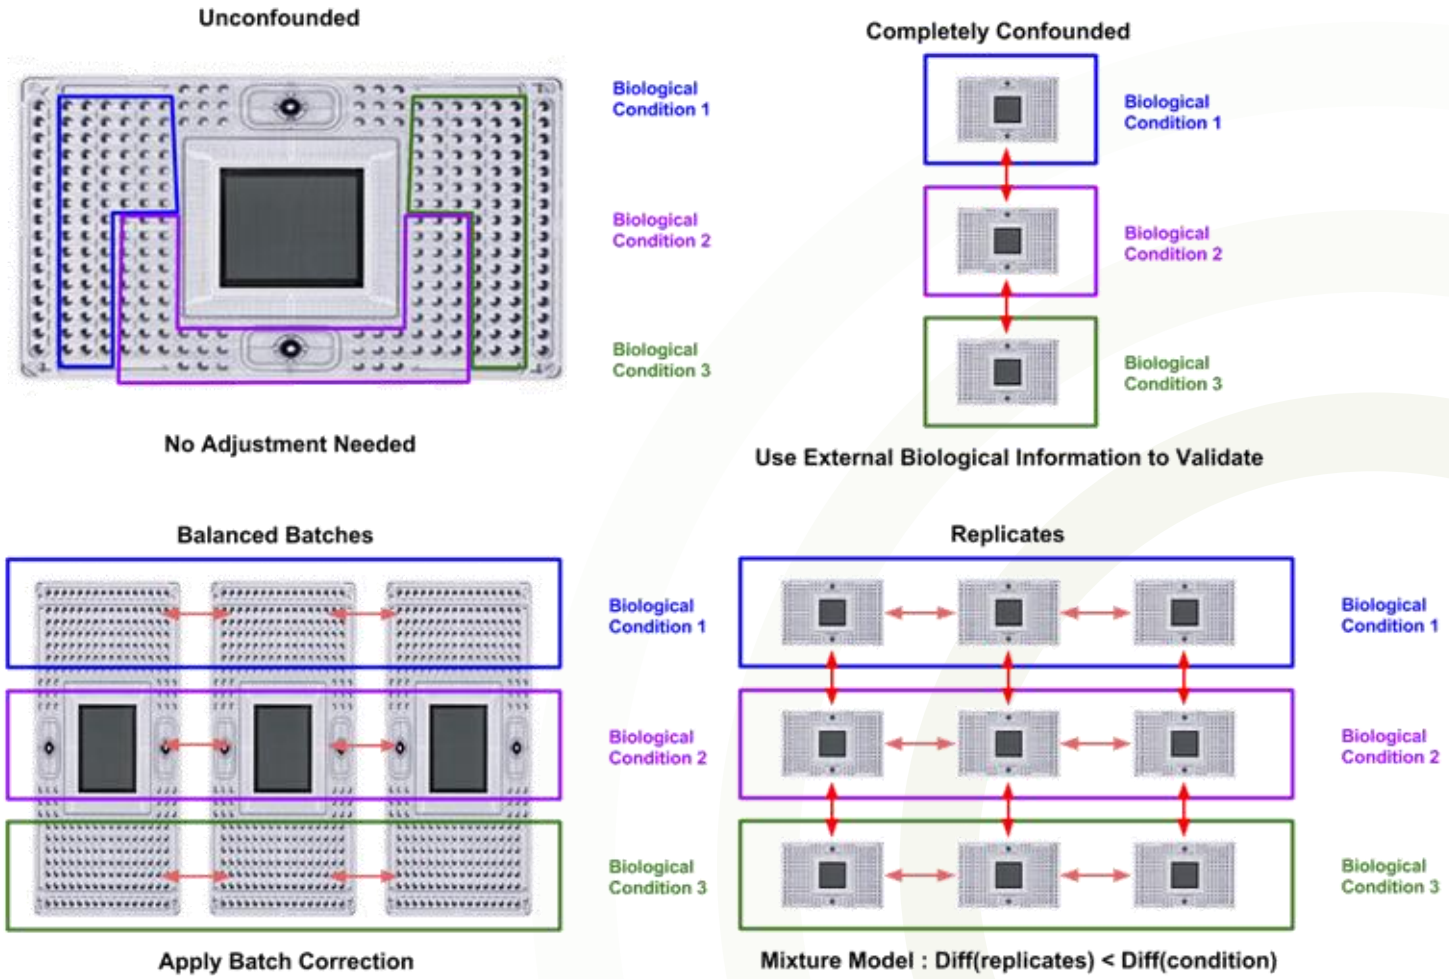
- 改善低表达特征检出
- 有利于可变剪接、新转录本
- 达到饱和后边际收益下降

默认倾向

- 基因层差异表达：先保证重复
- 结构发现：提升读长/深度
- 先做小规模预实验估计离散度

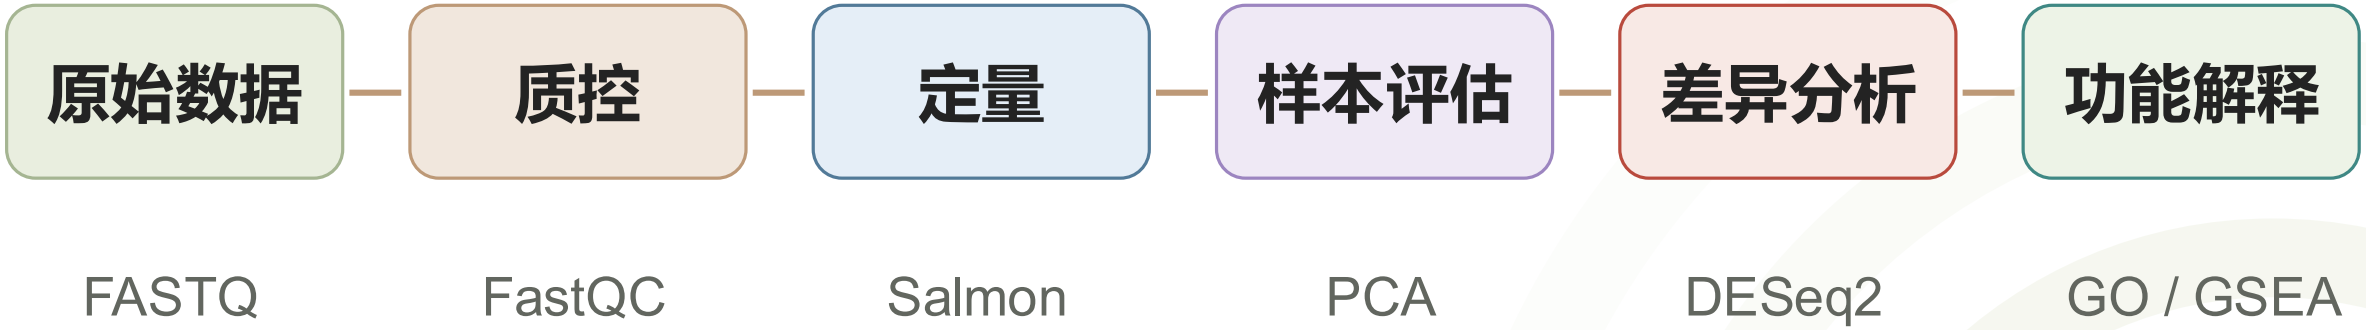
建库批次如何安排?

- 不要把处理组与对照组分到不同建库日期。
- 将各组样本随机分散到板、lane 和操作顺序中。
- 已知重要差异（如性别、个体）可用阻断平衡。



https://scrnaseq-course.cog.sanger.ac.uk/website/ideal-scrnaseq-pipeline-as-of-oct-2017.html

转录组测序分析的一般过程



每一步都会改变下一步能够支持的结论

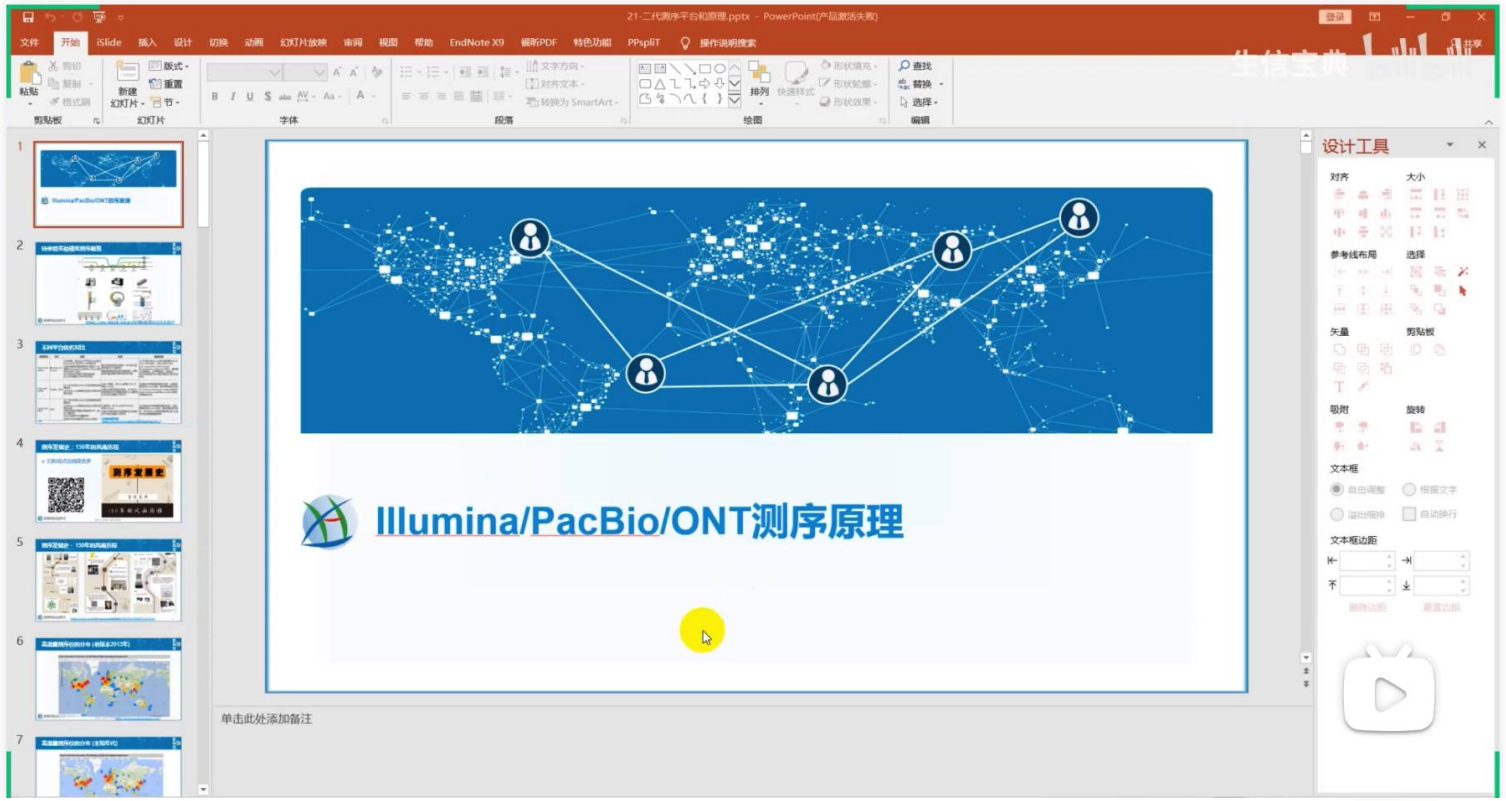
03

原始数据与质控

做分析需要懂基本的测序原理

易生信转录组高级课程系列节选

1.6万 4 2020-08-31 23:55:34 未经作者授权，禁止转载



生信宝典-陈同 发消息

充电 + 关注 2万

弹幕列表

视频选集 (6/11)

05-1-富集分析理论-GO富集分析理…	26:00
06-1-富集分析理论-GSEA理论和结…	31:27
07-1-高通量测序原理-文库构建-…	22:31
17-01-WGCNA理论-理论概述	36:53
服务器安装Rstudio-server操作	11:06
高通量数据中的批次效应鉴定和处理	39:05
Cytoscape整合富集和表达结果	49:17
21-IGV可视化reads分布和表达峰图	32:06

测序原理视频解读

Raw data, Clean data和有效数据

Raw data

- 测序仪直接产出
- 可含接头、低质量尾部与未定碱基
- 应作为原始证据保存

Clean data

- 根据明确规则去接头/修剪
- 可以改善比对或定量
- 不应覆盖原始 FASTQ

有效数据

- 最终能用于目标分析的 reads
- 受污染、复杂度、比对率和库类型共同影响
- 不等于 clean reads 总数

5 G 的数据量是多少 reads?

单端 100 nt

5×10^9 碱基 ÷ 100

约 50 million reads

一个 FASTQ 文件

双端 2×100 nt

5×10^9 碱基 ÷ 200

约 25 million read pairs

左右各 25 million reads

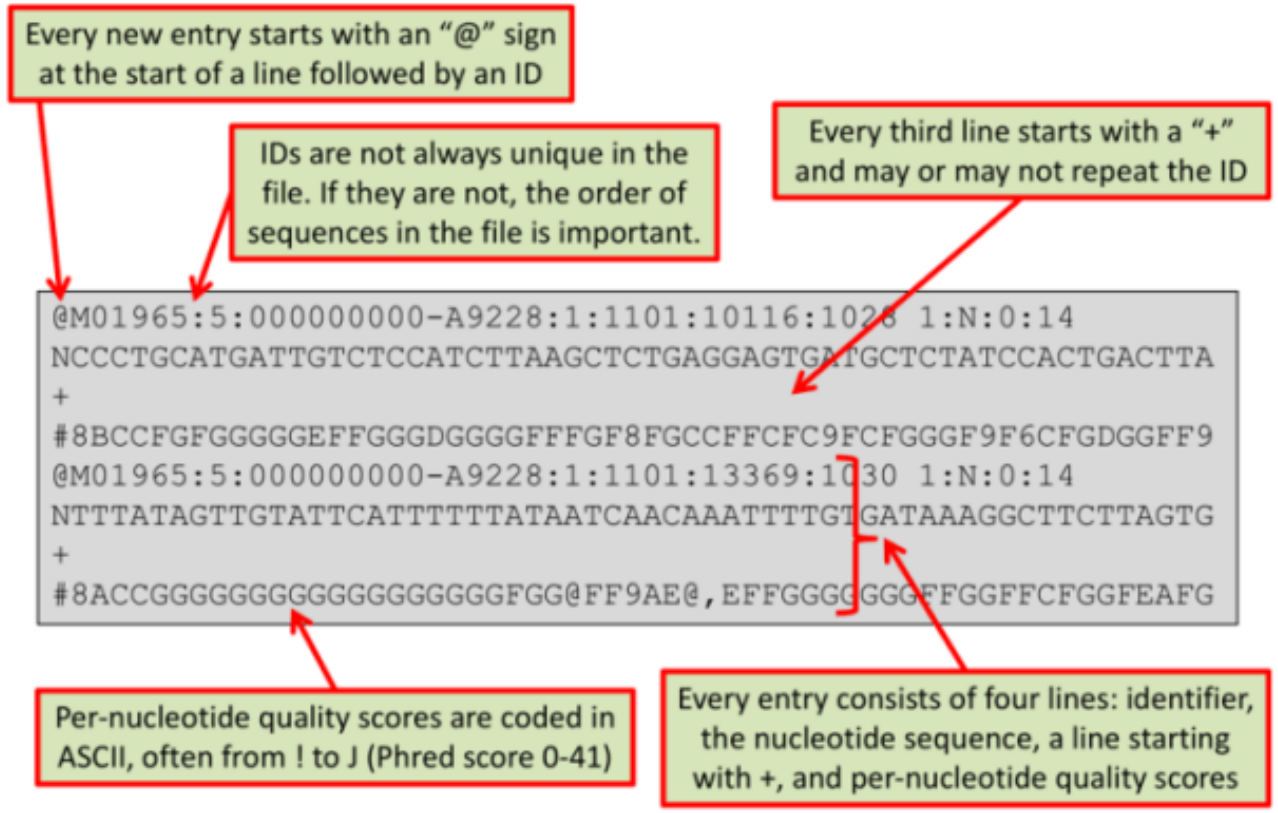
报告时

明确 bases、reads 还是 read pairs

明确 raw、clean 或 aligned

不用模糊的“G”替代完整描述

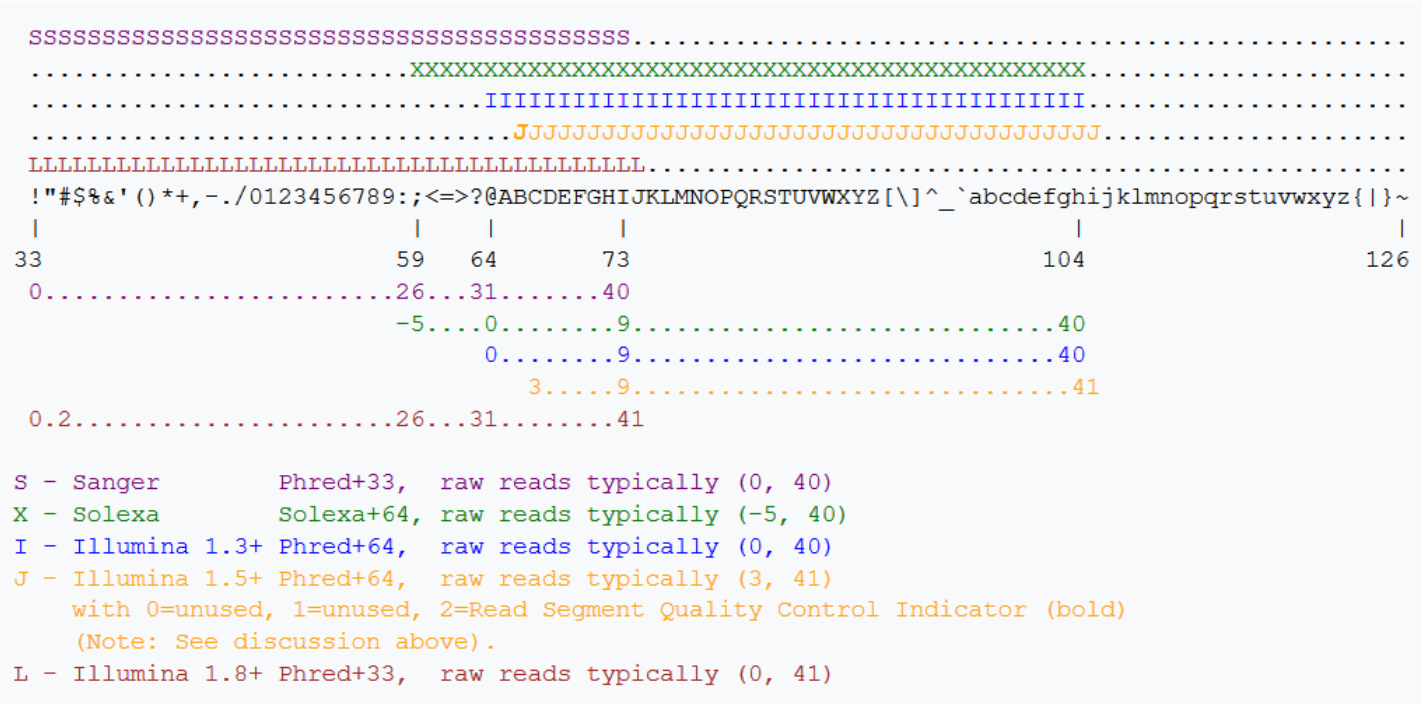
FASTQ 的四行结构



1. @开头的 read 名称
2. 碱基序列
3. + 分隔行
4. ASCII 编码的质量值

read 名不是装饰，它保留仪器、lane 和 pair 信息，如/1和/2等

Phred 质量值的含义



Q	P(错误)	直观理解
20	1%	约 100 个碱基错 1 个
30	0.1%	约 1,000 个碱基错 1 个
40	0.01%	约 10,000 个碱基错 1 个

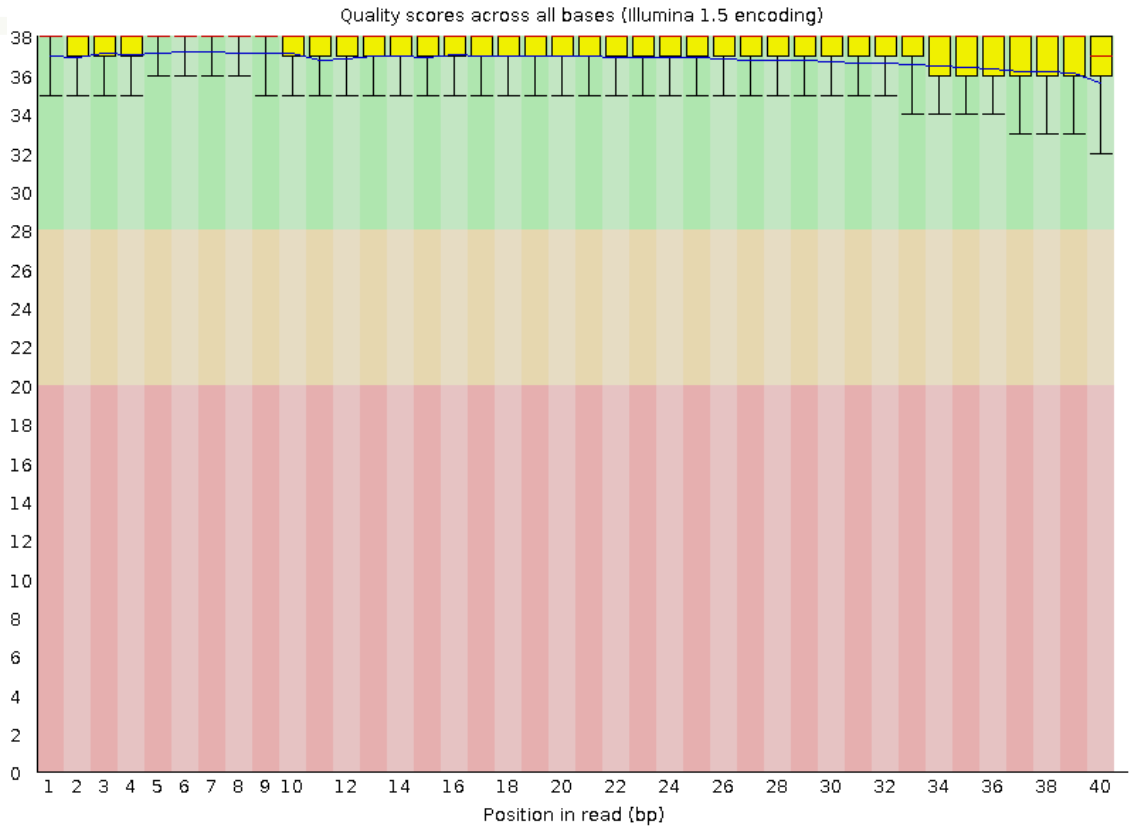
$$Q = -10 \log_{10}(P_{错误})$$

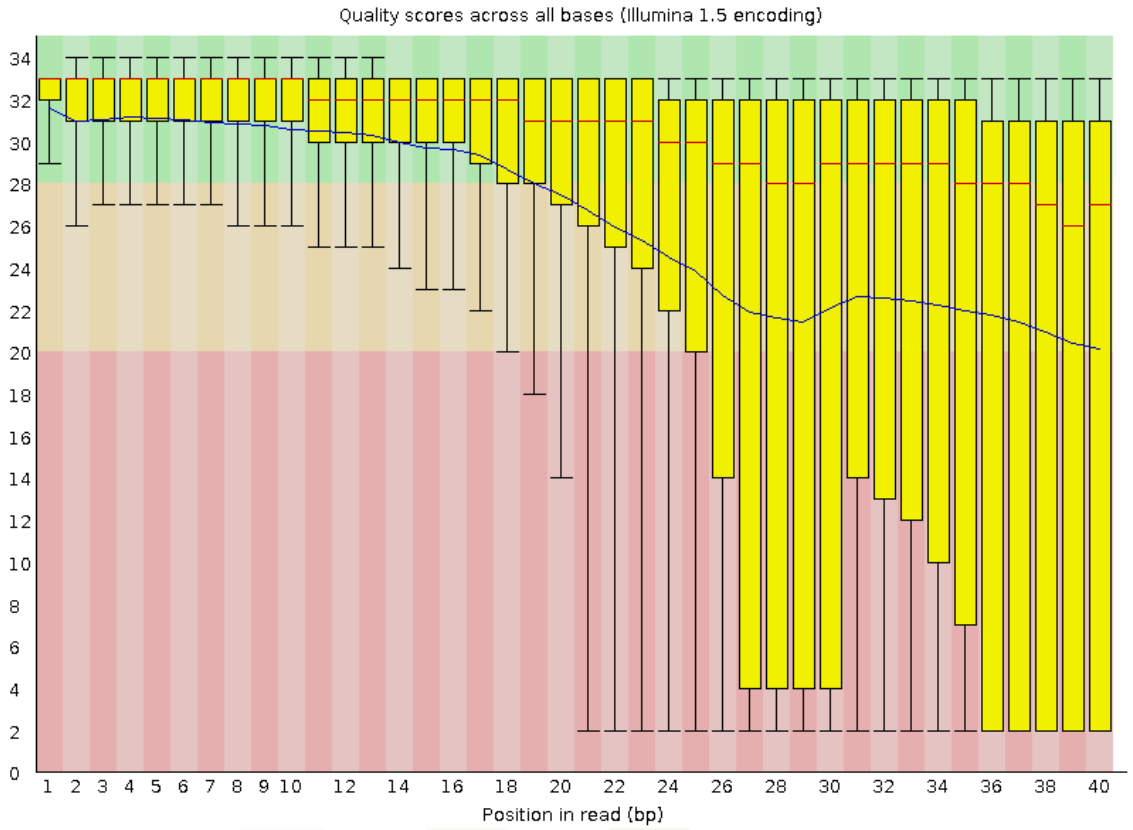
质量值是概率尺度，增加 10 分代表错误概率下降 10 倍

单个碱基质量差不代表样本不可用

- Q30 表示单碱基错误概率约 0.1%，是概率而非确定保证。
- 少量末端低质量未必会对比对定量造成显著影响。
- 若整条 read 质量低、N 多或一个样本明显偏离，则需要追查测序轮次和建库。
- 最终判断要结合比对率、基因体覆盖和样本间整体相似性。

FastQC reads 质量整体分布评估



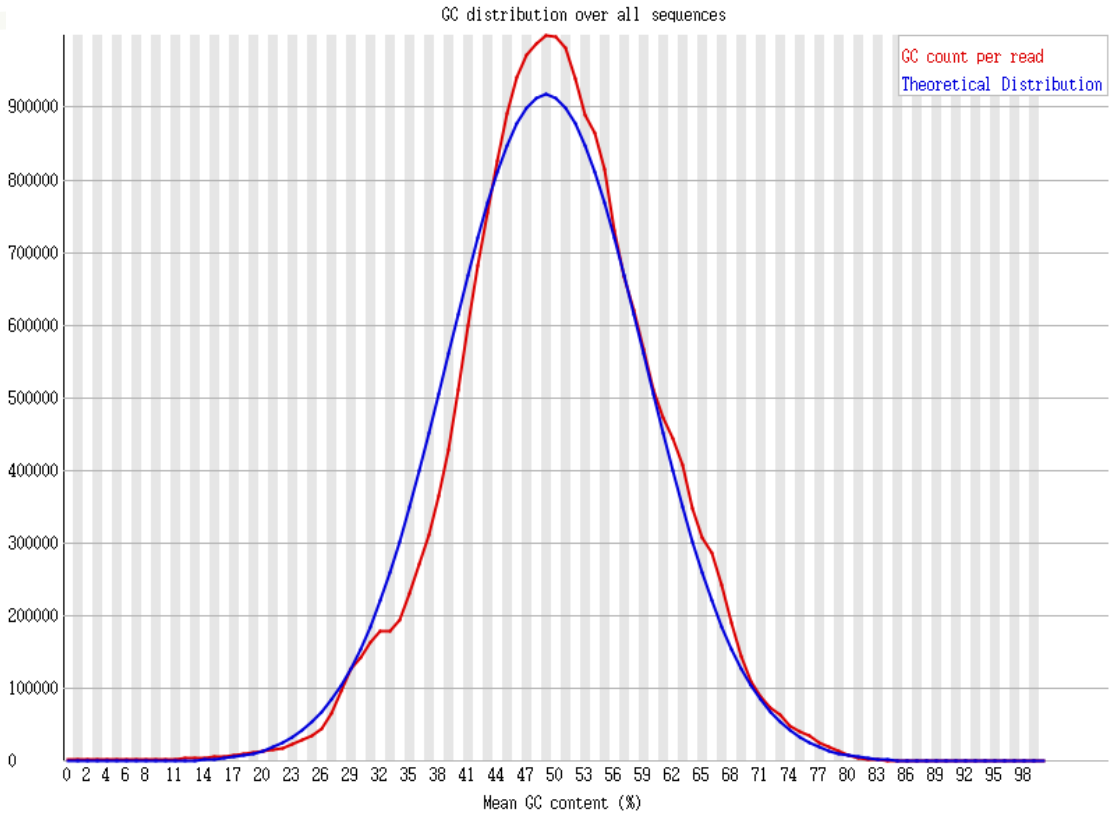


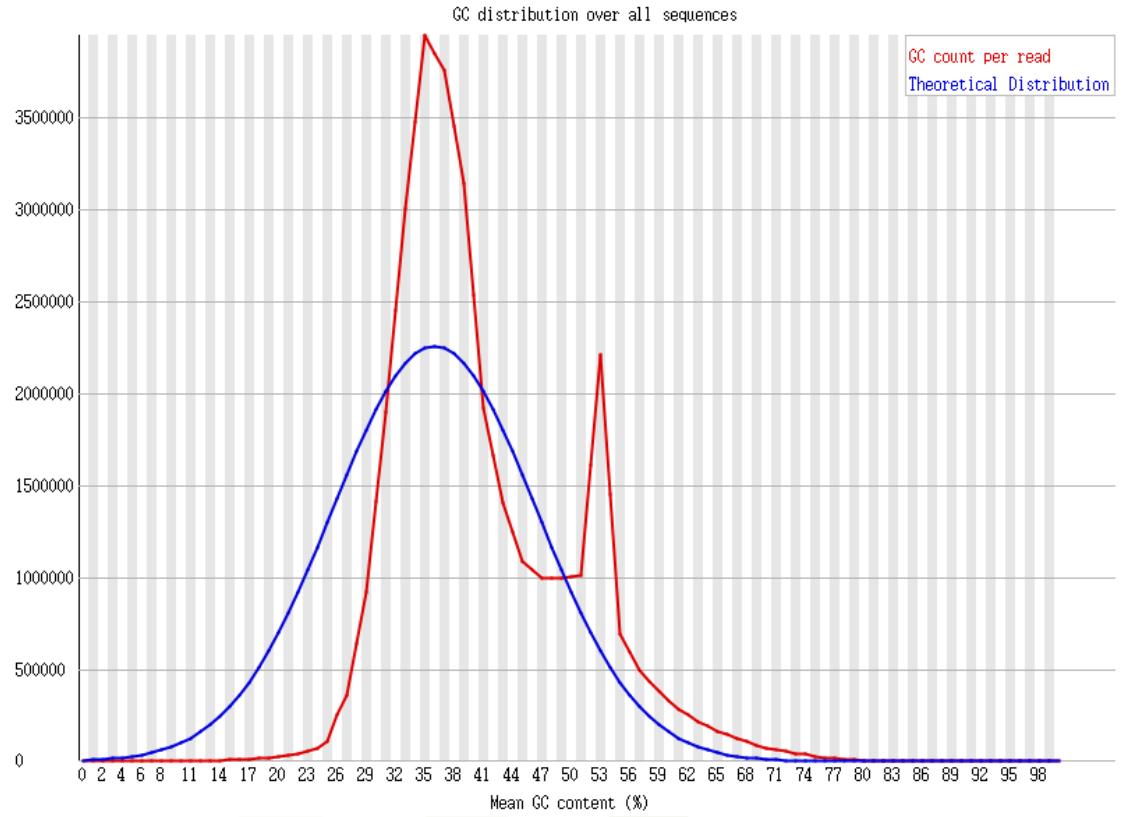
质量稳定

末端质量明显下降

原因可能包括信号衰减、相位不同步和序列组成，要结合比对率统一处理

reads的 GC 分布能推断出哪些信息?





观测分布接近期望

双峰或偏移需要追查

GC 异常可能来自污染、引物二聚体、富集策略或样本降解，需结合比对率判断

GC 异常和低比对率的追查路径

导出未比对上的 reads → BLAST 或物种分类 → 识别来源 → 决定是否去除

可能的结果

比对到其他物种

样本或实验室污染

比对到目标物种

参数过严、参考版本不够完成或高变区域

无可靠比对

引物、低质量或未知来源

删除数据之前，要记录证据和处理规则

测序 reads GC 含量异常，同时比对率低怎么处理

1. 找到未比对回基因组的序列 (STAR不分有输出)
2. 把未比对回基因组的序列放在 NCBI 的 blast 上进行搜索

A. 该序列比对到其他物种基因组 – 已知物种污染

B. 该序列比对到目标物种基因组，但错配多 – 调整匹配参数

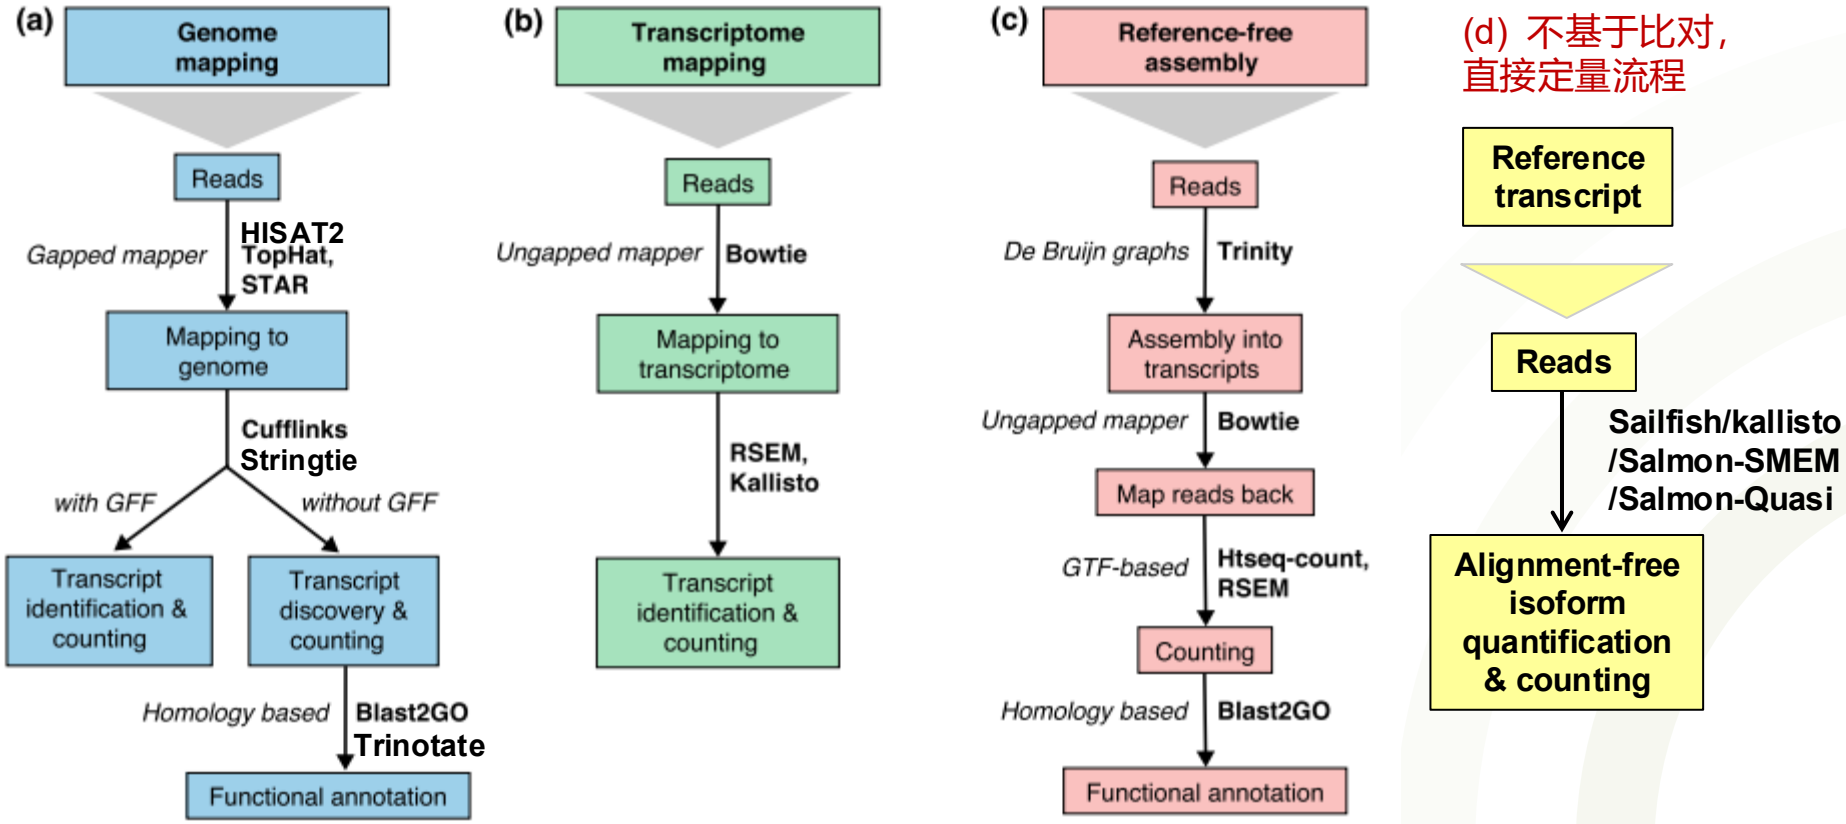
C.该序列比在 NCBI 没有比对结果 – 不明来源的序列污染

```
head trt_N052611.Unmapped.out.mate1
@SRR1039513.11314719 0:N:  00
AATTGGGGTGTGTCAATGGTTCGGGCGAGGAGGGGGTGGAGGTGCATGTGGCCATGG
+
FIIII+<C@FF1:*111:*1B00?(0.'-:',,,9@8@B(2(+(++3>:ABBBBBBB
@SRR1039513.13368724 0:N:  00
ATGTTGGCCAGGCTGGTCTTGAACTCCTGACCTCAGGTGATCCACCCGCCTCGGCCTCCCAAA
+
HJJIIJJJJIJJJJJJHIGHGGIIJJJJJJIHGIGIJGGGIHIJJJJJIJHHHFFFDEDDDDB
```

04

参考序列与表达定量

4种常见转录组分析策略



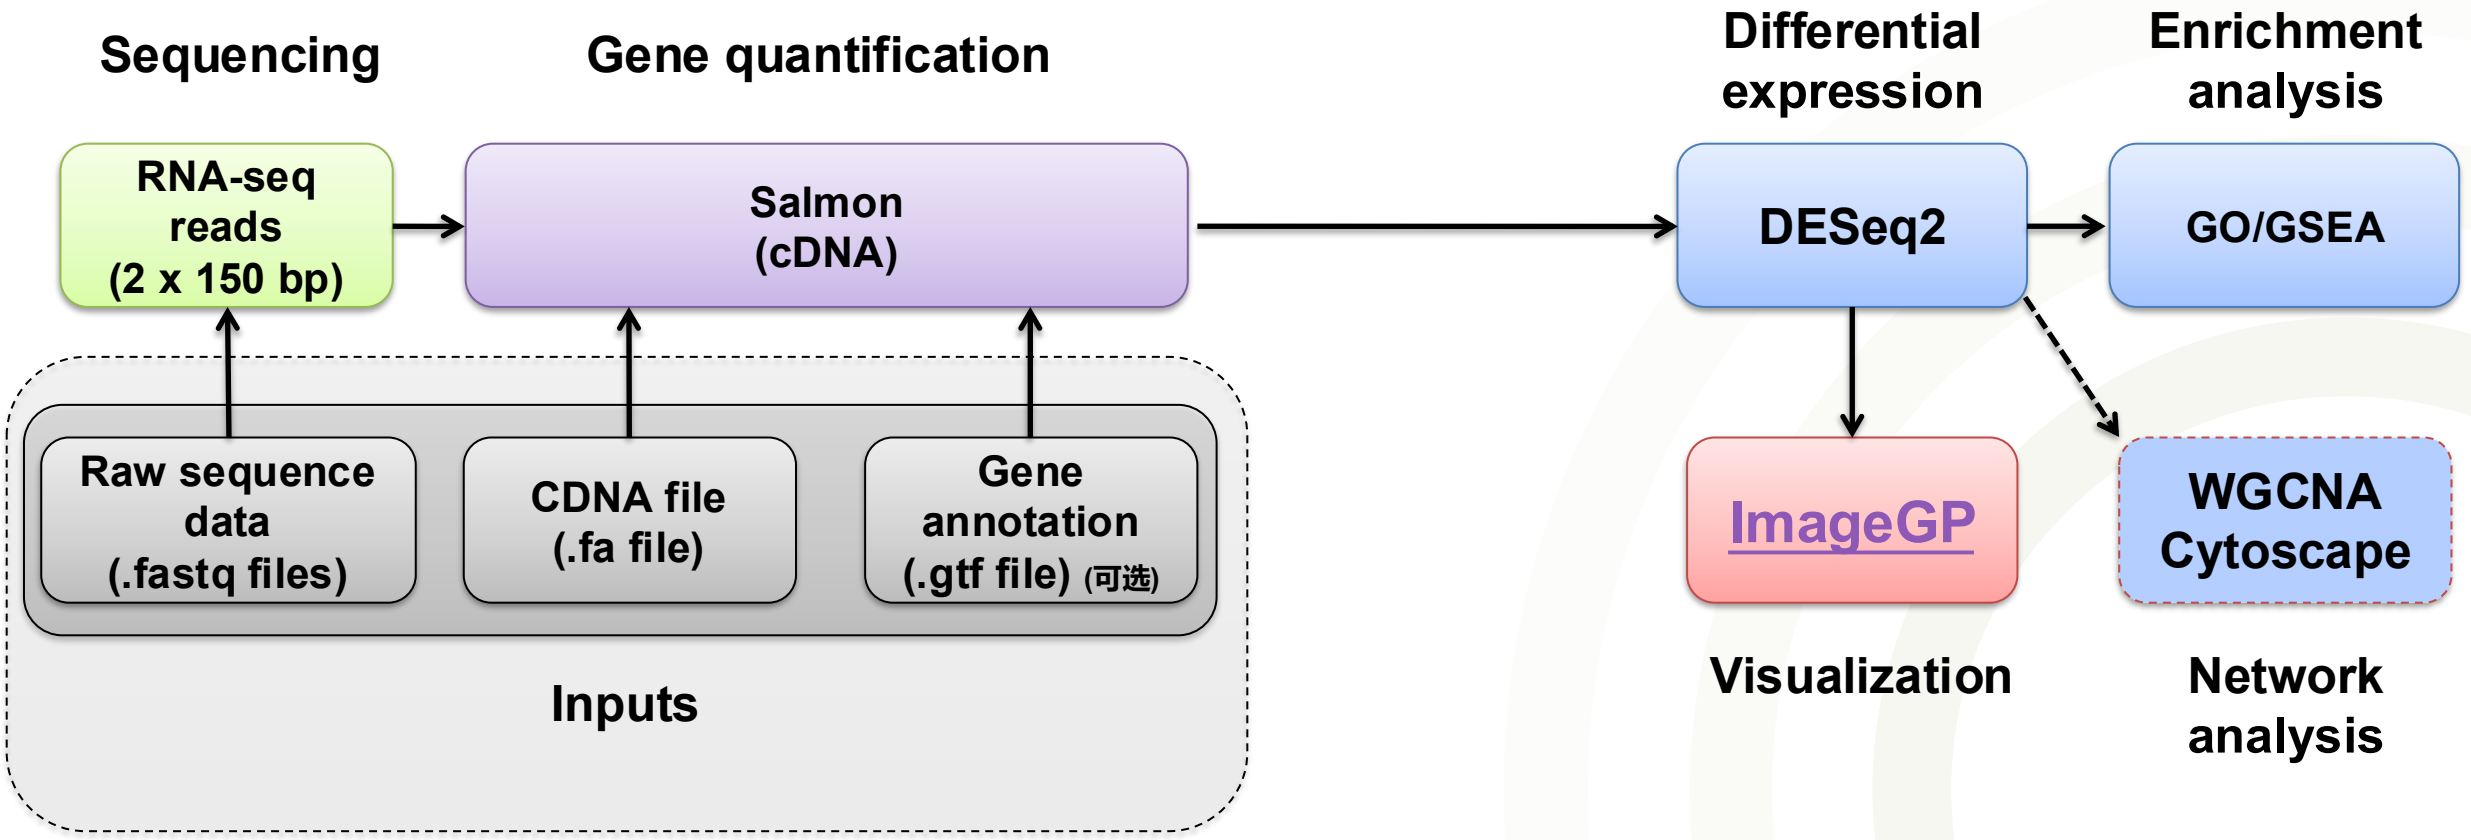
基因定量，还是局部剪接/轨迹?

参考基因组与注释是否高质量、版本一致?

是否需要保留 BAM 作为后续局部证据?

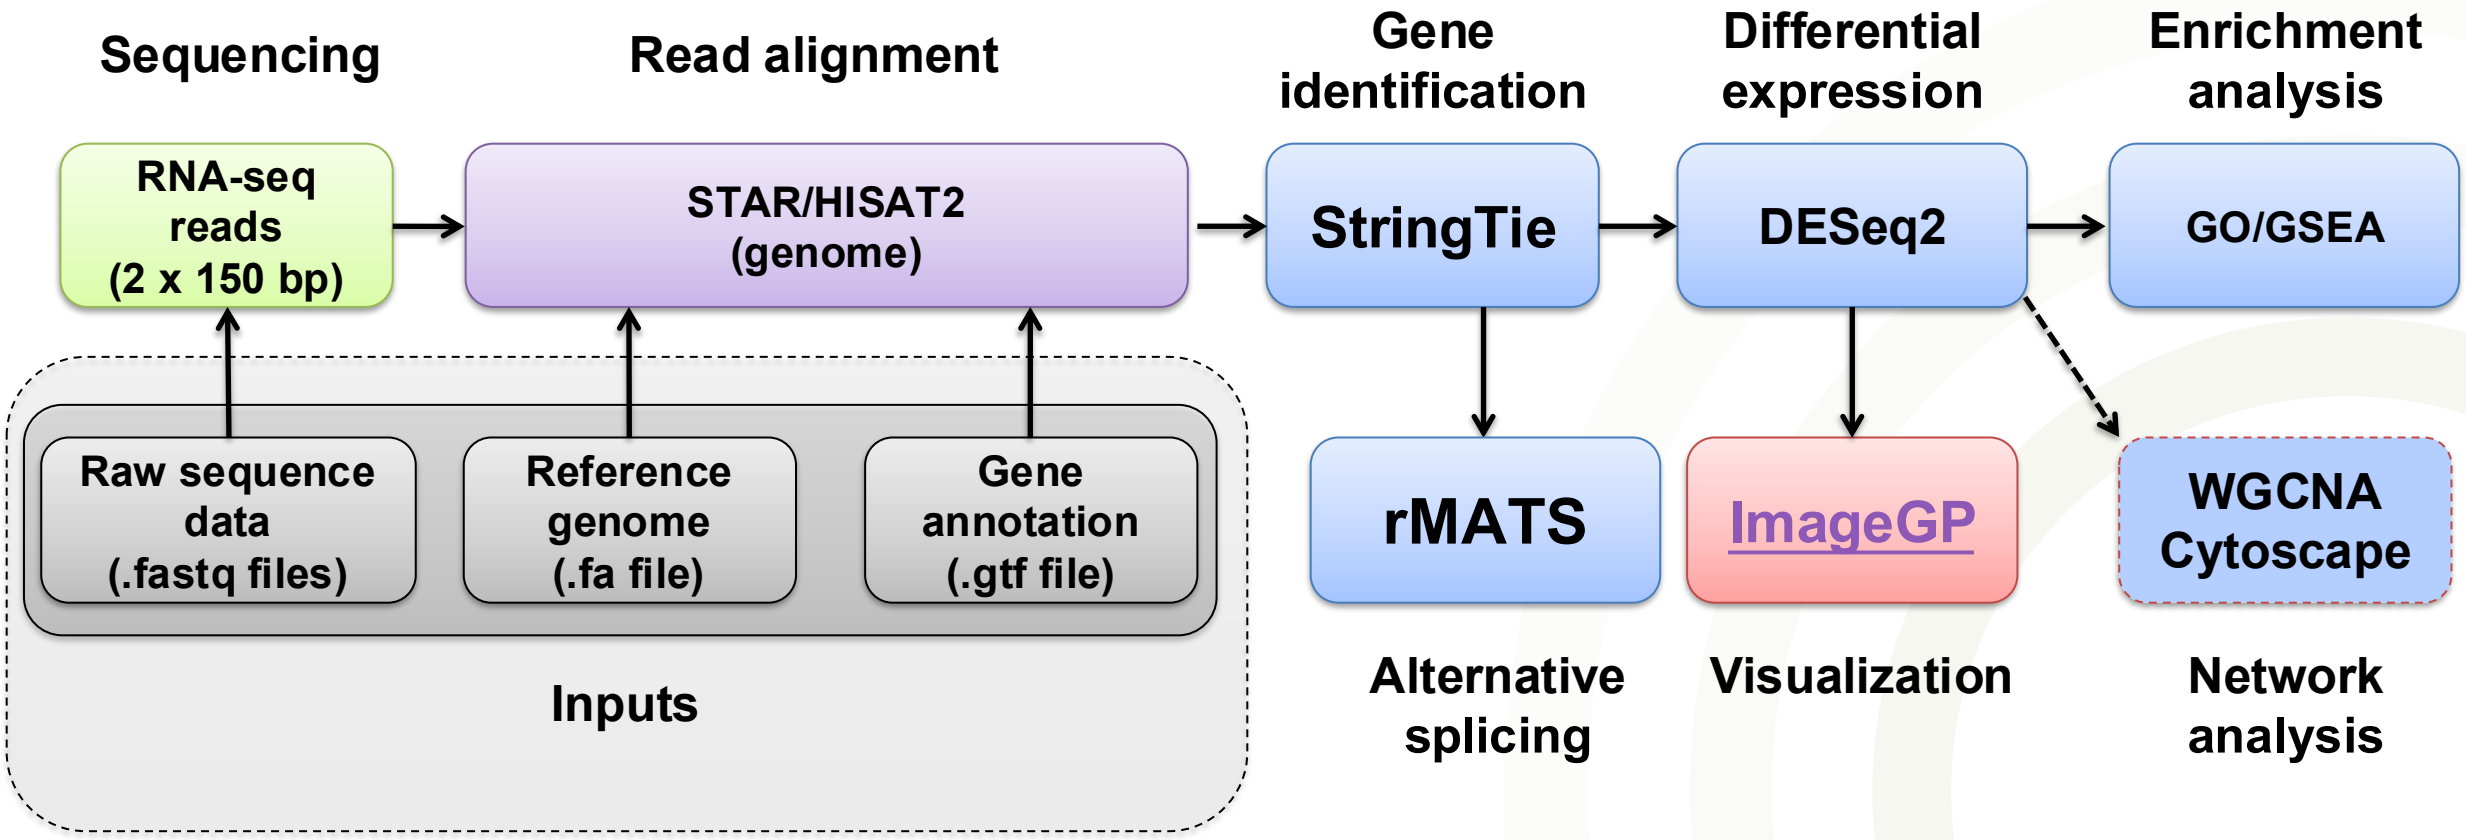
计算资源、存储、时间与复现性要求是什么?

有参不比对转录组分析流程



速度快，适合常规基因和转录本表达定量

有参比对转录组分析流程



保留基因组位置信息，适合新转录本和剪接分析

Genome、cDNA和 GTF 的关系

Genome FASTA

完整基因组序列
包含内含子和基因间区

cDNA FASTA

已剪接的转录本序列
适合 Salmon 定量

GTF/GFF

基因结构和坐标
连接 gene 与 transcript

版本必须一致：染色体命名、组装版本、注释版本和基因 ID 系统

参考版本不匹配会怎样?

常见不匹配

- 基因组 GRCh38 + GRCh37 GTF
- 不同版本 Ensembl/GENCODE 注释
- 染色体命名 chr1 vs 1

表现

- 许多特征无法定量
- 异常低的 assigned reads
- 基因 ID 无法注释或合并

防范

- 记录下载链接与 release
- 用同一来源的 FASTA/GTF
- 建立索引前检查 contig 和 ID

FASTA 格式中的名称与序列

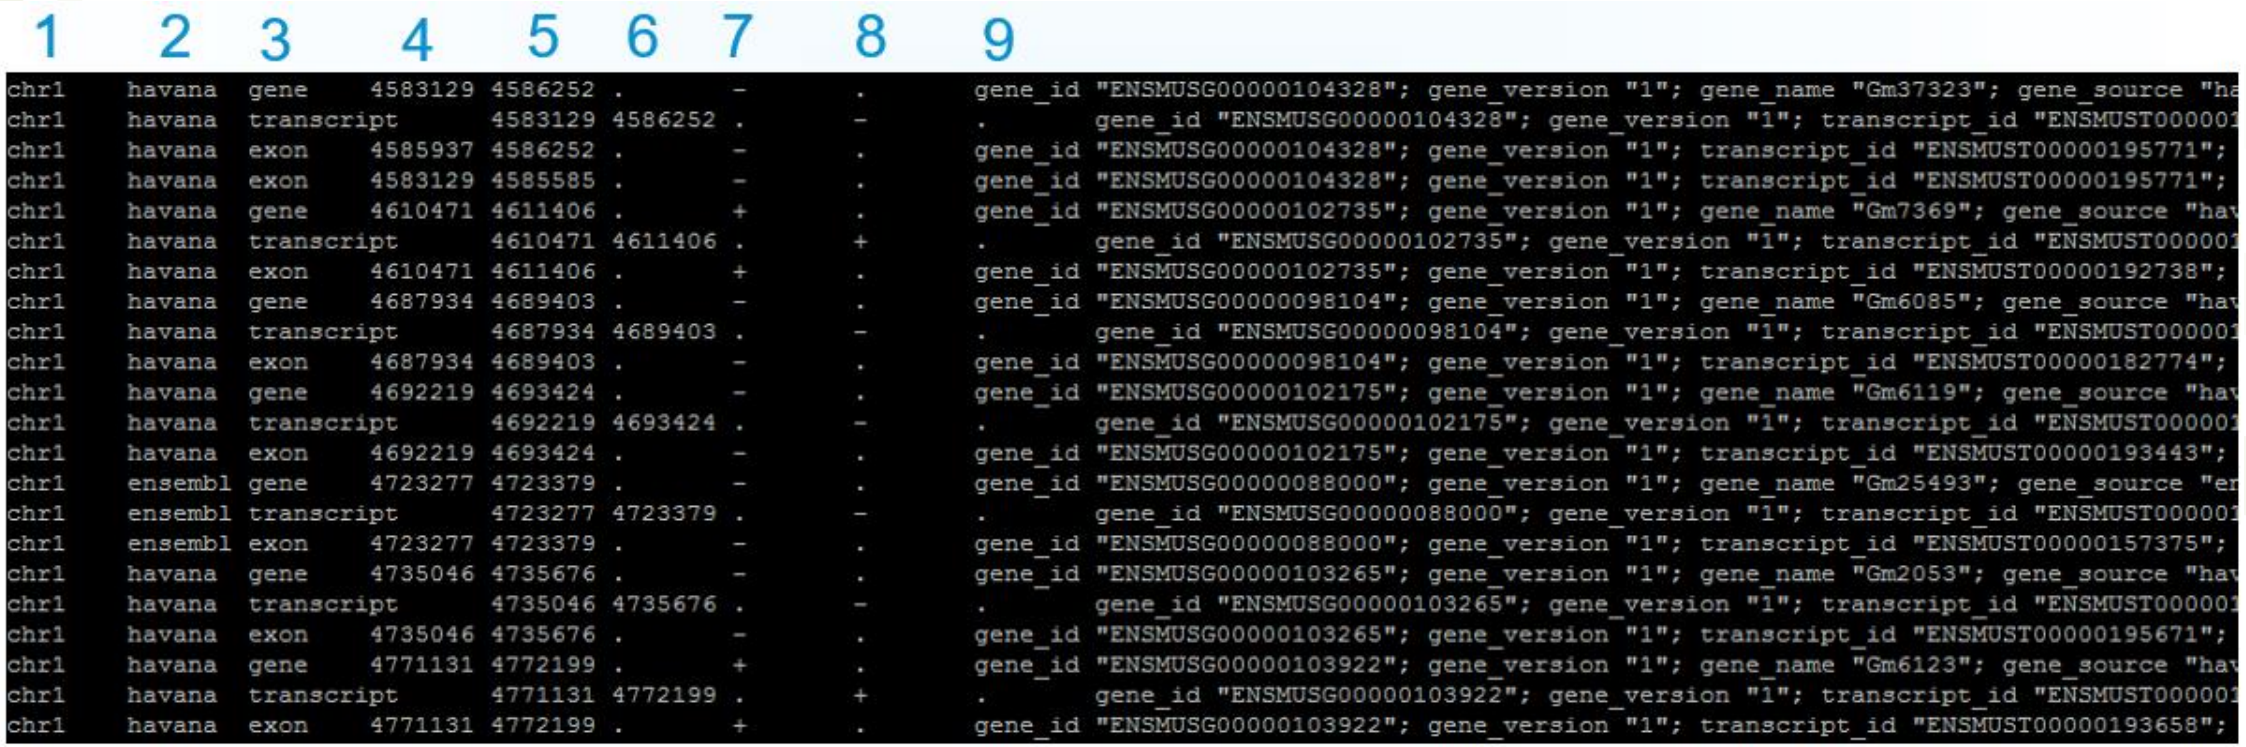
```
>ENST00000608838
ACAGGAATTCATATCGGGGTGATCACTCAGAAGAAAAGGTGAATACCGGATGTTGTAAGCTATTGAACTG
CCACAAGTGATATCTTTACACACCATTCTGCTGTCATTGGGTAGCTTTGAACCCCAAAAATGTTGGAAGA
ATAATGTAGGACATTGCAGAAGACGATGTTTAGATACTGAAAGGTACATACTTCTTTGTAGGAACAAGCT
ATCATGCTGCATTTCTATAATATCACATGAATATACTCGACGACCAGCATTTCCTGTGATTCACCTAGAG
GATATAACATTGGATTATAGTGATGTGGACTCTTTTACTGGTTCCCCAGTATCTATGTTGAATGATCTGA
TAACATTTGACACAACTAAATTTGGAGAAACCATGACACCTGAGACCAATACTCCTGAGACTACTATGCC
ACCATCTGAGGCCACTACTCCCGAGACTACTATGCCACCATCTGAGACTGCTACTTCCGAGACTATGCCA
CCACCTTCTCAGACAGCTCTTACTCATAATTAATTAACATTTACTTCTGGTATGGAACAACTAGAAATAC
TGCTGGAAATAATATCCAAAGAGCTGATTCTACCAATCCAATTTCACCAGGAAAATTCCATCAGGGATTG
GATGACCATGGGGATGGACATAATTGCTACTACCAACACAACAGCCAAGAGAGTTGCCTTACAATTAGAA
ATGTGTAGACAGAAATGTATAGAAGATACAAGGATTCTCTTAATTGGACTTAAATTCTTTATCTGTCTTC
CTCCGATGTACTCAAATATATGAGCTAATTTTTGTCTTAAGTGAACATTTGTATATCTATGTATTTTTCC
ATGCCAAAAACAAAAACGAAGACCATTGTTTGGAGCTGCCTCTTATGACTAAGACAAGAATTTTTACTTT
AACAGTGCCTGGCCCACTACTATCGTATATAGGAGAACATATAAAAGCATATAGAAAGTTCCAGATGAAT
GTTCCCTTCTCTACCCTCCACCTTTTATTGTAAGTTCTGACCCTAAATACTTTTCTGTGTCATGACGTCA
AATTTTGTTTAAGGTTCTAGCTGGTAACTAACAGAGTCAGAAGCTAATTCTTTCATTCAACACAAGCACT
GATCTAACTGGATAGAGATAAAAGTGGGACTTGCCTTGAGAGTACATCATATTAAATTAAAAGCTGCATC
TCAAATTCTA
>ENST00000382410
ATGAATATCCTGATGCTGACCTTCATTATCTGTGGGTTGCTAACTCGGGTGACCAAAGGTAGCTTTGAAC
CCCAAAAATGTTGGAAGAATAATGTAGGACATTGCAGAAGACGATGTTTAGATACTGAAAGGTACATACT
TCTTTGTAGGAACAAGCTATCATGCTGCATTTCTATAATATCACATGAATATACTCGACGACCAGCATTT
CCTGTGATTCACCTAGAGGATATAACATTGGATTATAGTGATGTGGACTCTTTTACTGGTTCCCCAGTAT
CTATGTTGAATGATCTGATAACATTTGACACAACTAAATTTGGAGAAACCATGACACCTGAGACCAATAC
TCCTGAGACTACTATGCCACCATCTGAGGCCACTACTCCCGAGACTACTATGCCACCATCTGAGACTGCT
ACTTCCGAGACTATGCCACCACCTTCTCAGACAGCTCTTACTCATAATTAATTAACATTTACTTCTGGTA
TGGAACAACTAGAAATACTGCTGGAAATAATATCCAAAGAGCTGATTCTACCAATCCAATTTCACCAGGA
AAATTCCATCAGGGATTGGATGACCAT
```

```
>Sox2
ACGTCGACTACGAGACGAGACAAGCCAG
>Sox21
ACGTCGACTACGAGACGAGACAAGCCAG
```

实用规则

- 名称从 > 开始
- 程序常以第一个空格前的字符作为 ID
- 序列可以单行或多行
- 同一文件中 ID 必须唯一

GTF 注释的九列结构



```
1       2       3          4        5        6  7  8  9
chr1    havana  gene       4583129  4586252  .  -  .  gene_id "ENSMUSG00000104328"; gene_version "1"; gene_name "Gm37323"; gene_source "ha
chr1    havana  transcript 4583129  4586252  .  -  .  gene_id "ENSMUSG00000104328"; gene_version "1"; transcript_id "ENSMUST000001
chr1    havana  exon       4585937  4586252  .  -  .  gene_id "ENSMUSG00000104328"; gene_version "1"; transcript_id "ENSMUST00000195771";
chr1    havana  exon       4583129  4585585  .  -  .  gene_id "ENSMUSG00000104328"; gene_version "1"; transcript_id "ENSMUST00000195771";
chr1    havana  gene       4610471  4611406  .  +  .  gene_id "ENSMUSG00000102735"; gene_version "1"; gene_name "Gm7369"; gene_source "hav
chr1    havana  transcript 4610471  4611406  .  +  .  gene_id "ENSMUSG00000102735"; gene_version "1"; transcript_id "ENSMUST000001
chr1    havana  exon       4610471  4611406  .  +  .  gene_id "ENSMUSG00000102735"; gene_version "1"; transcript_id "ENSMUST00000192738";
chr1    havana  gene       4687934  4689403  .  -  .  gene_id "ENSMUSG00000098104"; gene_version "1"; gene_name "Gm6085"; gene_source "hav
chr1    havana  transcript 4687934  4689403  .  -  .  gene_id "ENSMUSG00000098104"; gene_version "1"; transcript_id "ENSMUST000001
chr1    havana  exon       4687934  4689403  .  -  .  gene_id "ENSMUSG00000098104"; gene_version "1"; transcript_id "ENSMUST00000182774";
chr1    havana  gene       4692219  4693424  .  -  .  gene_id "ENSMUSG00000102175"; gene_version "1"; gene_name "Gm6119"; gene_source "hav
chr1    havana  transcript 4692219  4693424  .  -  .  gene_id "ENSMUSG00000102175"; gene_version "1"; transcript_id "ENSMUST000001
chr1    havana  exon       4692219  4693424  .  -  .  gene_id "ENSMUSG00000102175"; gene_version "1"; transcript_id "ENSMUST00000193443";
chr1    ensembl gene       4723277  4723379  .  -  .  gene_id "ENSMUSG00000088000"; gene_version "1"; gene_name "Gm25493"; gene_source "en
chr1    ensembl transcript 4723277  4723379  .  -  .  gene_id "ENSMUSG00000088000"; gene_version "1"; transcript_id "ENSMUST000001
chr1    ensembl exon       4723277  4723379  .  -  .  gene_id "ENSMUSG00000088000"; gene_version "1"; transcript_id "ENSMUST00000157375";
chr1    havana  gene       4735046  4735676  .  -  .  gene_id "ENSMUSG00000103265"; gene_version "1"; gene_name "Gm2053"; gene_source "hav
chr1    havana  transcript 4735046  4735676  .  -  .  gene_id "ENSMUSG00000103265"; gene_version "1"; transcript_id "ENSMUST000001
chr1    havana  exon       4735046  4735676  .  -  .  gene_id "ENSMUSG00000103265"; gene_version "1"; transcript_id "ENSMUST00000195671";
chr1    havana  gene       4771131  4772199  .  +  .  gene_id "ENSMUSG00000103922"; gene_version "1"; gene_name "Gm6123"; gene_source "hav
chr1    havana  transcript 4771131  4772199  .  +  .  gene_id "ENSMUSG00000103922"; gene_version "1"; transcript_id "ENSMUST000001
chr1    havana  exon       4771131  4772199  .  +  .  gene_id "ENSMUSG00000103922"; gene_version "1"; transcript_id "ENSMUST00000193658";
```

1	seqname	2	source	3	feature	4–5	start / end
6	score	7	strand	8	frame	9	attribute

第 9 列建立 gene_id、transcript_id 和其他属性之间的关系

GTF 属性列的作用

gene_id	transcript_id	gene_name	gene_biotype
ENSG00000178591	ENST00000608838	DEFB125	protein_coding
ENSG00000178591	ENST00000xxxxx	DEFB125	processed_transcript

同一 gene 可以对应多个 transcript

定量层级、ID 转换和注释合并都依赖这些字段。

reads 长度、测序深度与覆盖度

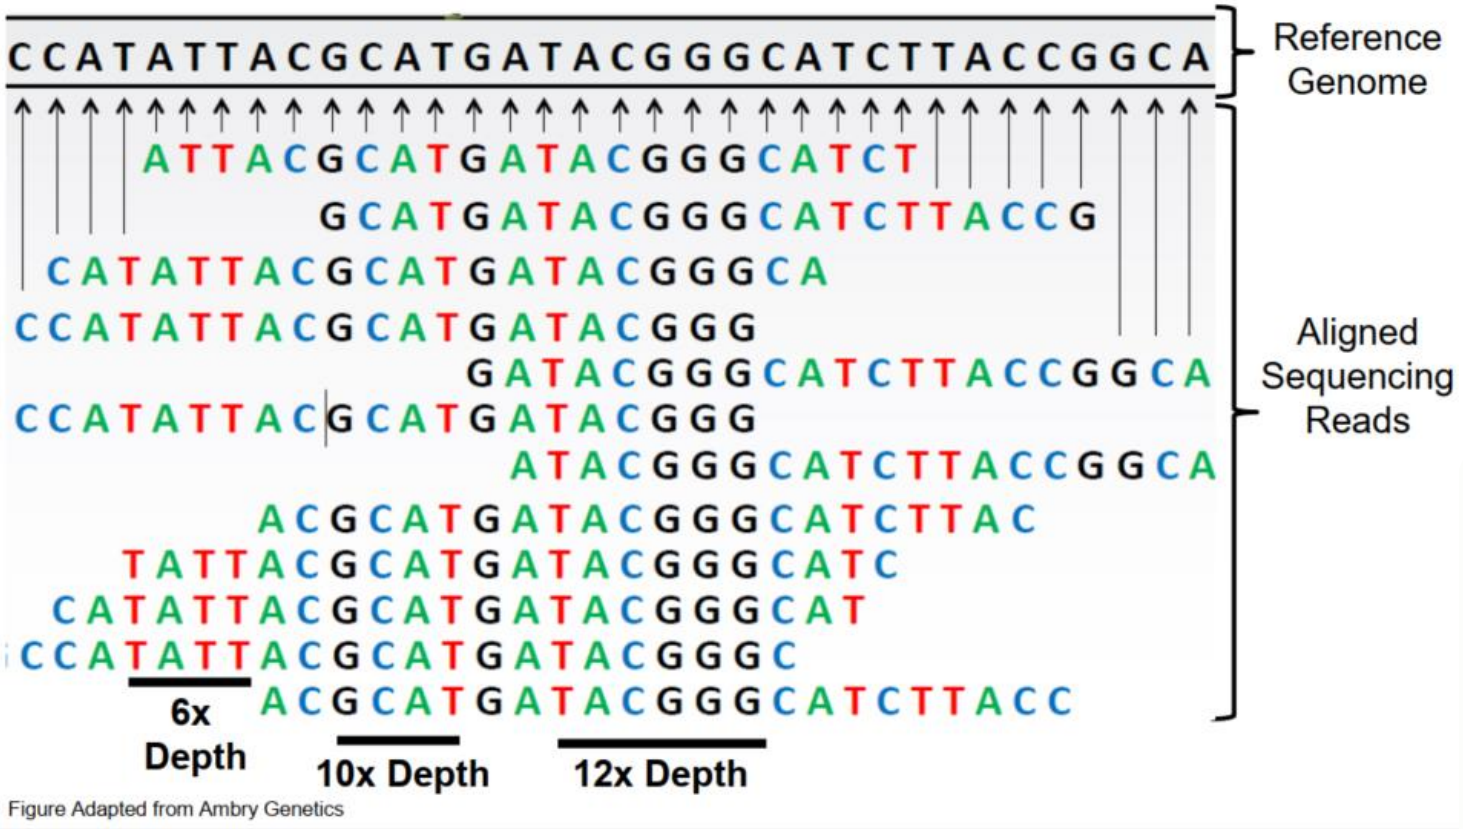


Figure Adapted from Ambry Genetics

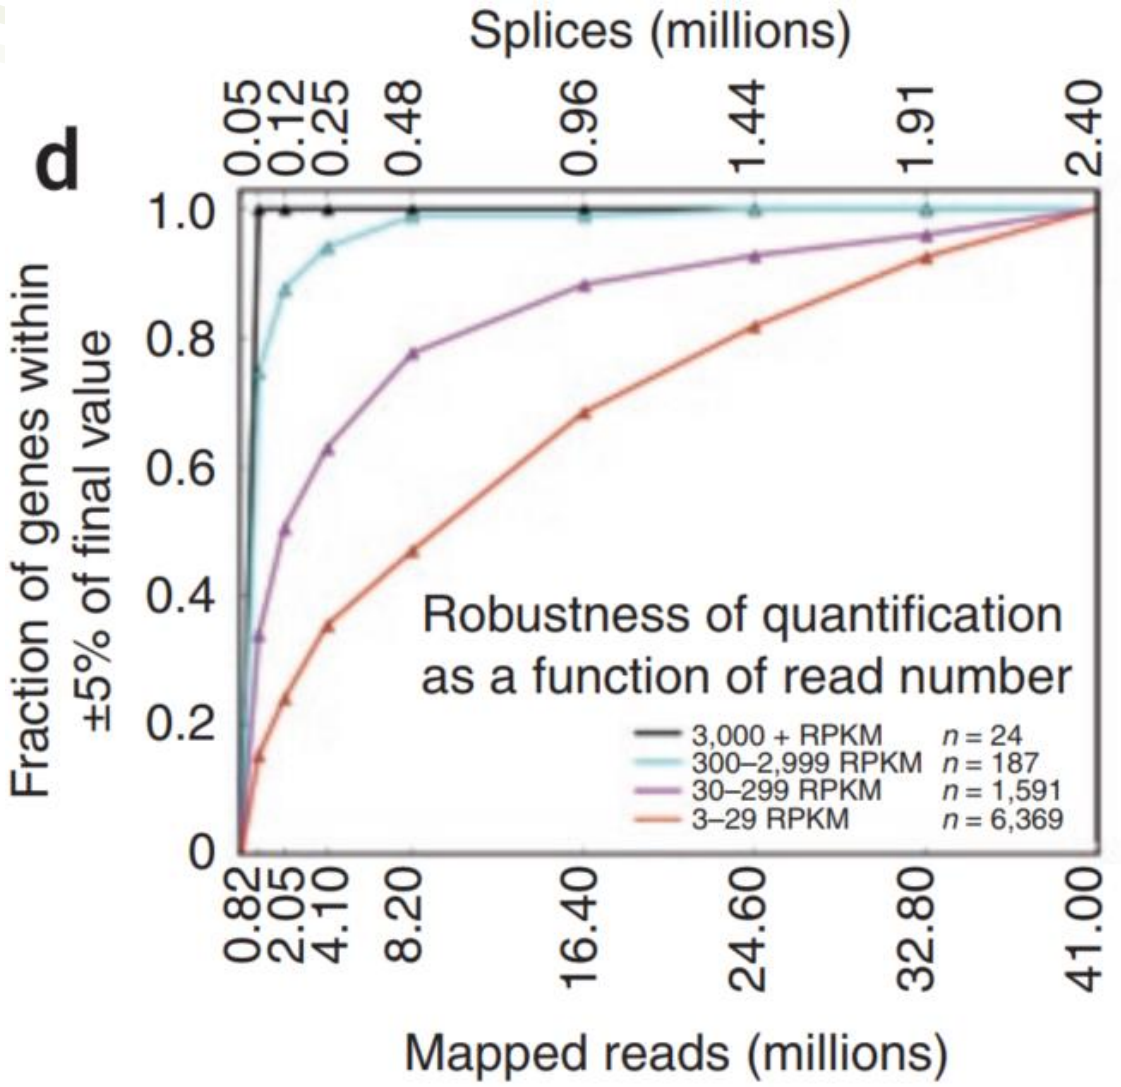
更多 reads 提高低表达特征的检测机会

但测序深度不能修复：

- 没有生物学重复
- 严重批次混杂
- 错误的参考版本
- 库类型设置错误

深度与重复数解决的问题不同

测序量与测序饱和度



- 高表达基因用较少 reads 就能得到稳定估计。
- 低表达基因和罕见转录本长时间处于抽样噪声区。
- “饱和”必须相对于某个目标：基因检出、定量、剪接或新转录本。

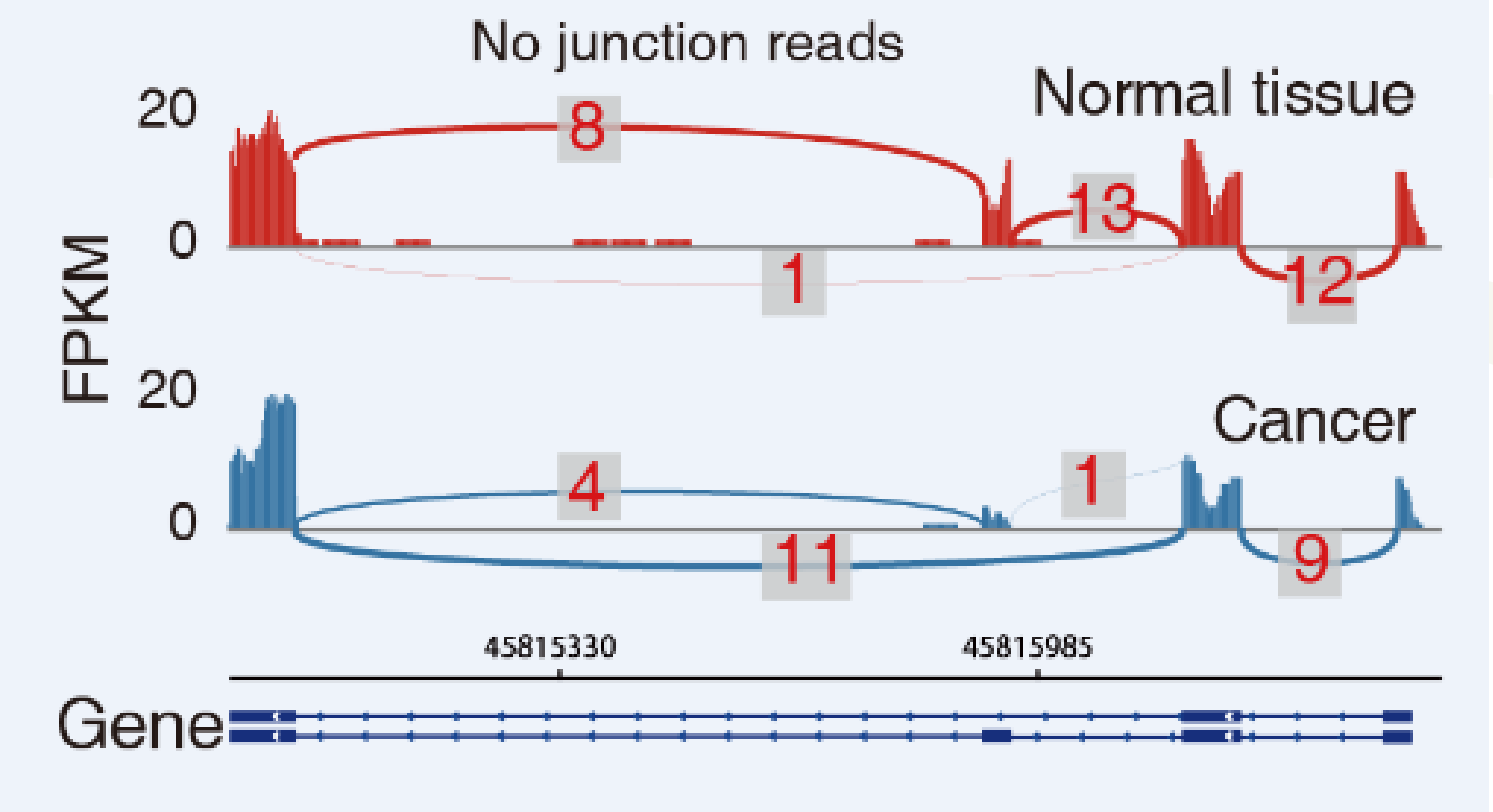
比对结果是一张局部基因转录证据图

- 覆盖高度反映局部片段支持，但受reads长度、 测序偏好和多重比对影响。
- 剪接 reads 跨越内含子，是 exon junction 的直接证据。
- 轨迹比较适合验证整体统计结果是否在局部可见。

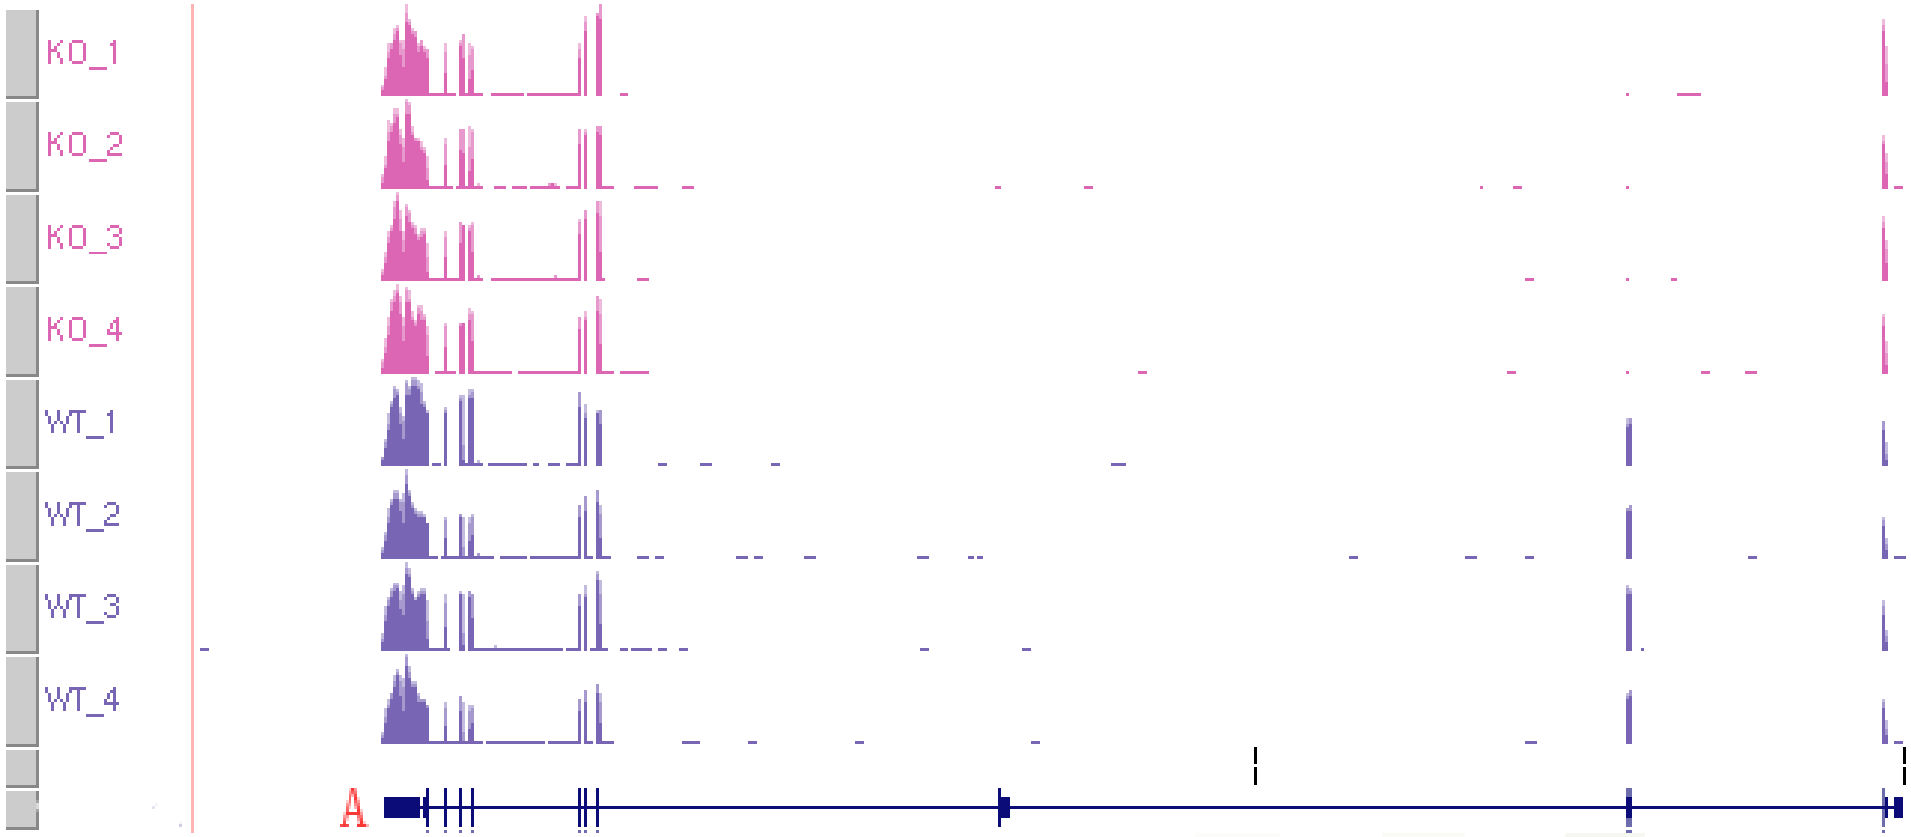


Sashimi plot展示可变剪接事件

- 平铺覆盖轨迹显示外显子区域上的 reads 密度。
- 弧线表示跨剪接位点的 reads，数字通常是 junction count。
- 先比较同一 junction 在各组的相对支持，再考虑总体表达差异。



用序列比对峰图检查基因敲除是否成功

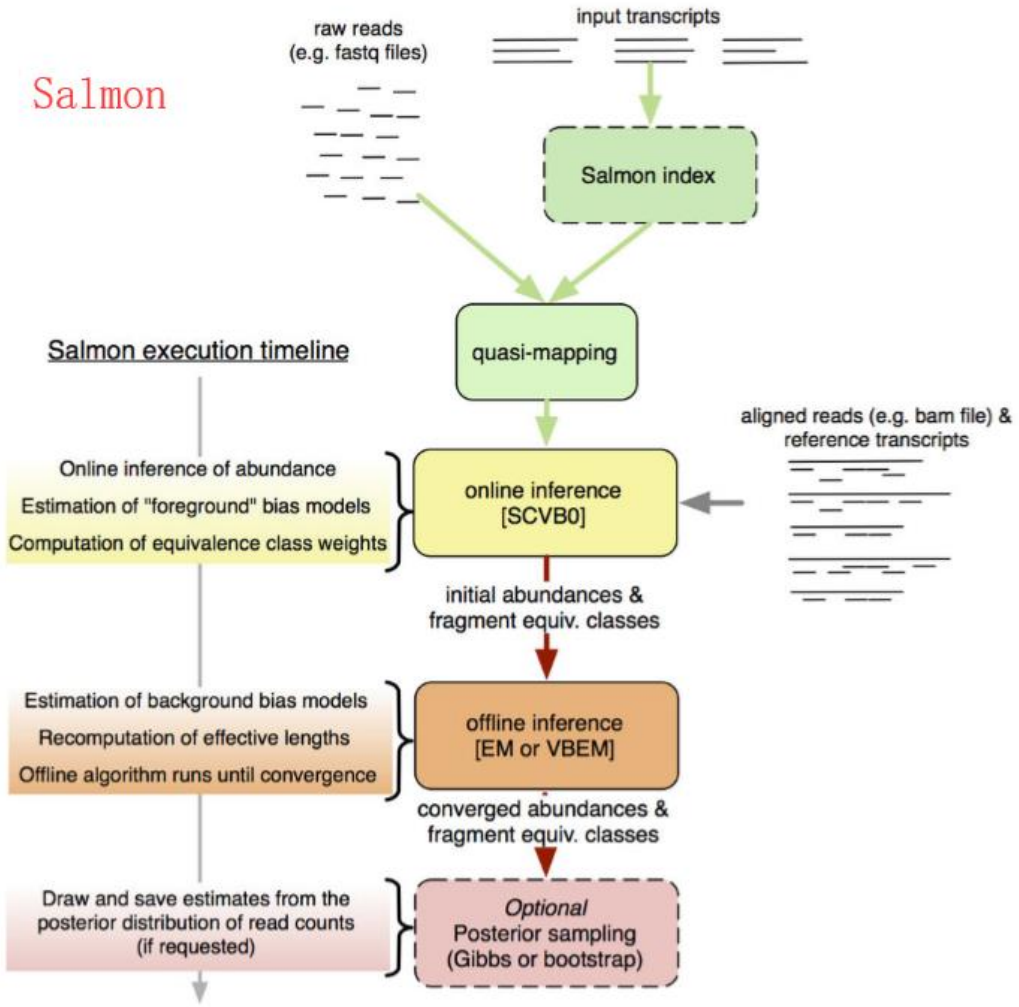


- 某个外显子覆盖下降，不一定等于整个基因无转录。
- 救援转录本、旁路起始和异常剪接可以保留部分 RNA 信号。
- 应将轨迹、转录本结构和蛋白/功能验证结合。

Salmon的优势

- 定量时考虑到不同样品中基因长度的改变（比如不同isoform的使用）
- 速度快、需要的计算资源和存储资源小
- 敏感性高，不会丢弃匹配到多个基因同源区域的reads
- 可以直接校正GC-bias
- 自动判断文库类型

Salmon 如何把 reads 分配给转录本



核心思路

- 根据与转录本的兼容性分组
- 对多重匹配 reads 进行概率分配
- 考虑有效长度和可选偏好模型
- 输出转录本层级的 counts 与 TPM

Salmon 不需要为每条 read 保存完整基因组坐标

counts、TPM 与 RPKM 的用途

数值	主要用途	不建议的用法
raw counts	DESeq2 / edgeR 差异分析	直接比较样本间丰度
TPM	样本内的相对表达构成	作为 DESeq2 输入
RPKM / FPKM	也常用的长度与深度校正	将其与 counts 混用

差异分析的输入与绘图
展示的矩阵不一定相同

$$\text{RPKM} = \frac{\text{Read counts} * 10^6 * 1000}{\text{Total reads} * \text{Gene length}}$$

$$\text{RPK} = \frac{\text{Read counts} * 1000}{\text{Gene length}}$$

$$\text{TPM} = \frac{\text{RPK} * 10^6}{\text{sum (RPK)}}$$

准备使用DESeq2检验处理效应，应输入哪种数据？

TPM

$\log_2(TPM+1)$

raw counts 或 tximport 导入的 Salmon 结果

准备使用DESeq2检验处理效应，应输入哪种数据？

TPM

$\log_2(TPM+1)$

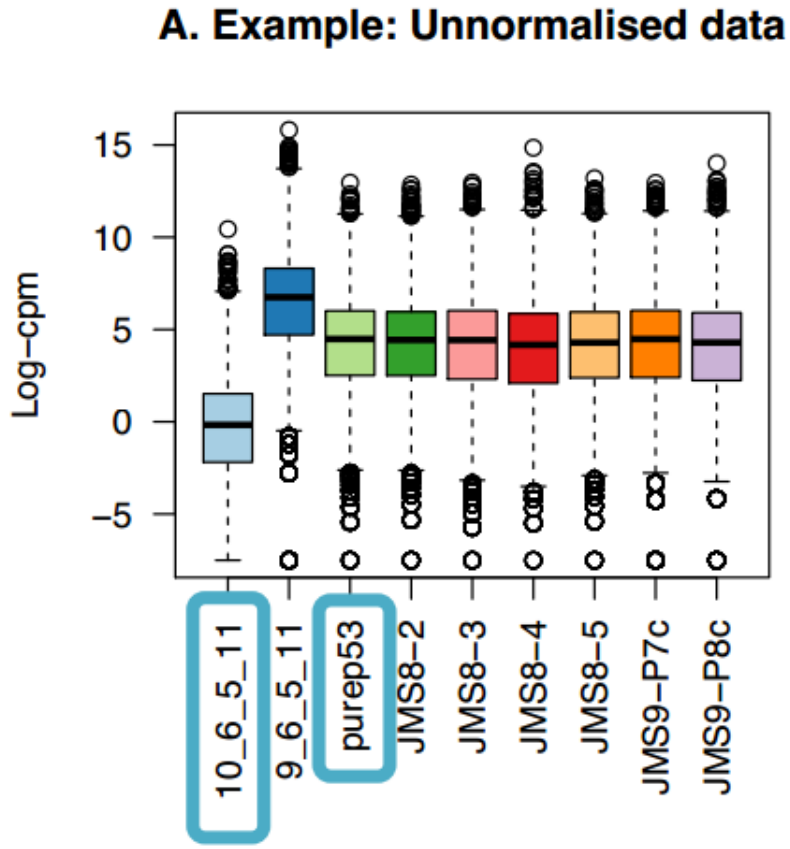
raw counts 或 tximport 导入的 Salmon 结果

DESeq2 的概率模型使用 counts 及其均值和方差关系。TPM 适合某些展示，不是常规 DESeq2 输入。

05

样本质控与差异表达

表达数据标准化是后续比较的基础



第3个样品与第1个样品直接差异分析，几乎所有基因都上调

标准化目标

尽量移除非生物学目标引起的系统差异，保留我们关心的处理效应。

常见影响因素

- 测序深度
- RNA 组成
- 基因或转录本长度
- 技术偏好

RPKM的计算

Gene A 600 bases　　Gene B 1100 bases　　Gene C 1400 bases

RPKM = 12/(0.6*6) = 3.33　RPKM = 24/(1.1*6) =3.64　　RPKM = 11/(1.4*6) = 1.31



Sample 1

C=12　　C=24　　C = 11

N = 6M



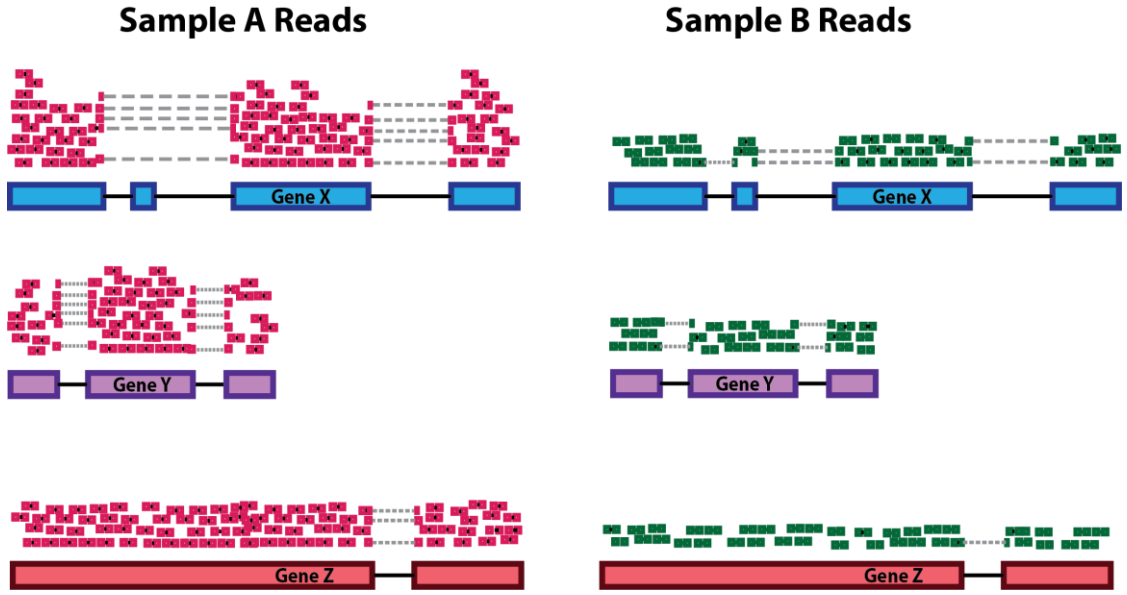
Sample 2

C=19　　C=28　　C = 16

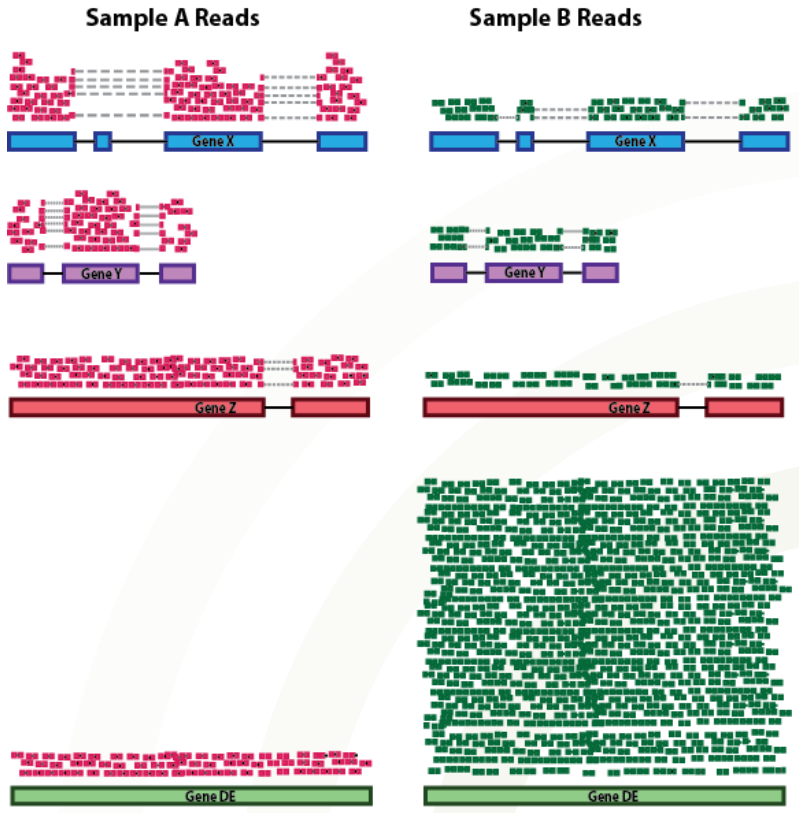
N = 8M

RPKM = 19/(0.6*8) = 3.96　RPKM = 28/(1.1*8) = 3.18　　RPKM = 16/(1.4*8) = 1.43

测序深度与 RNA 组成效应



测序量不同会使所有 counts 成比例变化



一个极端高表达基因可以改变样本的总构成

因此，简单除以总 reads 数可能制造假差异

DESeq2的size factor等同于每个样本的有效测序规模

1. 计算每个基因在所有样本中的几何均值 -- 虚拟参考样本
2. 每个样本的 count 除以相应基因的几何均值 -- 相对于参考的变化
3. 对每个样本的比值取中位数，得到 size factor – 变化的中位水平

中位数对少量极端高表达基因更稳健

前提：大多数基因不发生同方向的全局变化

差异表达分析的一般过程

1

整体相关性

相关性、PCA、距离和表达分布

2

解释异常

回到 metadata、QC、定量和实验记录

3

拟合模型

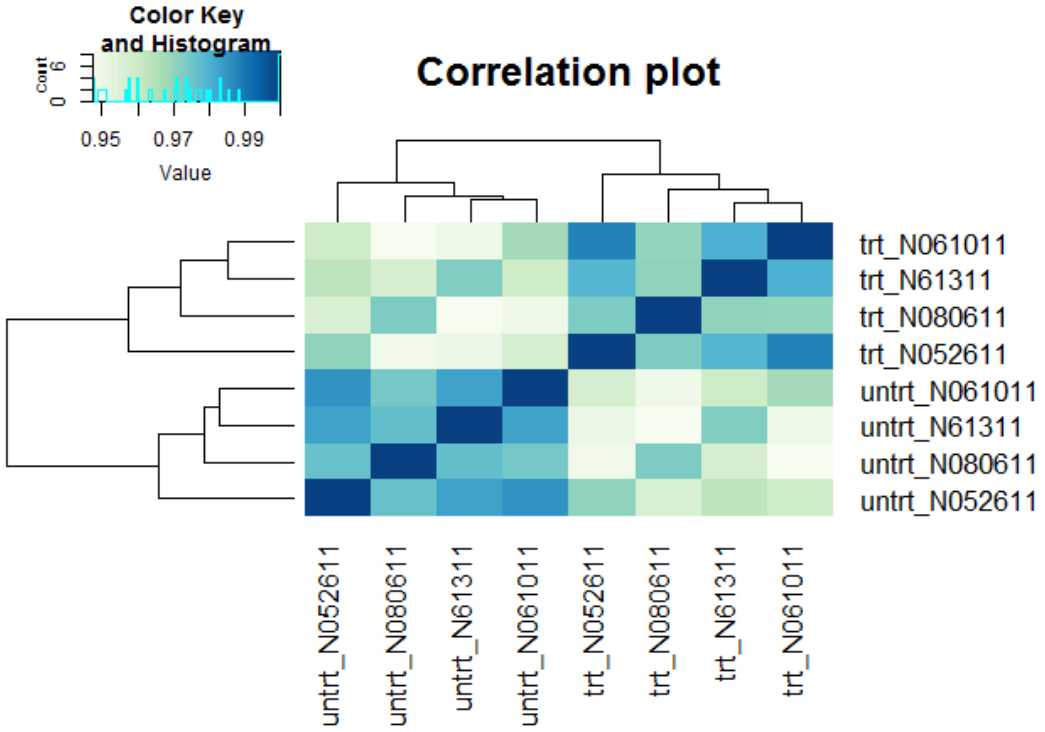
把处理与已知混杂因素放入 design设计矩阵

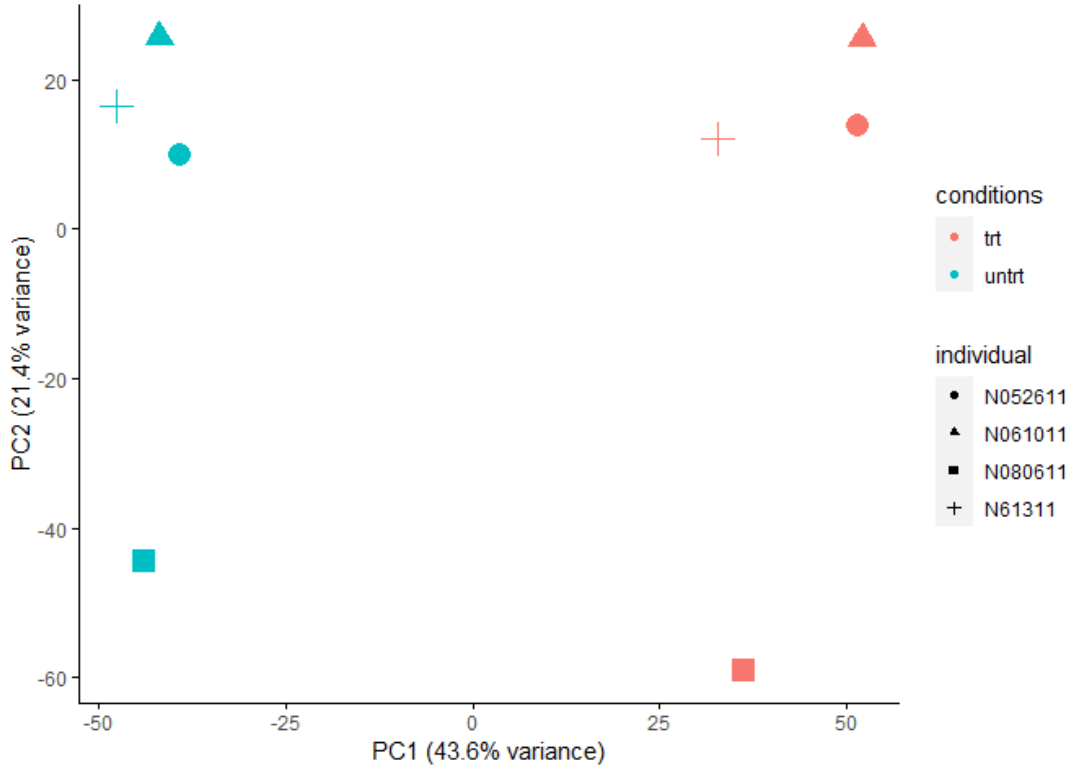
4

检查结果

效应量、不确定性、FDR 和敏感性分析

样本相关性热图与 PCA 回答不同的问题





相关性热图：哪些样本的整体表达更相似

PCA：主要变异方向是否对应处理或批次

异常样本的多证据判断

FastQC 原始碱基质量

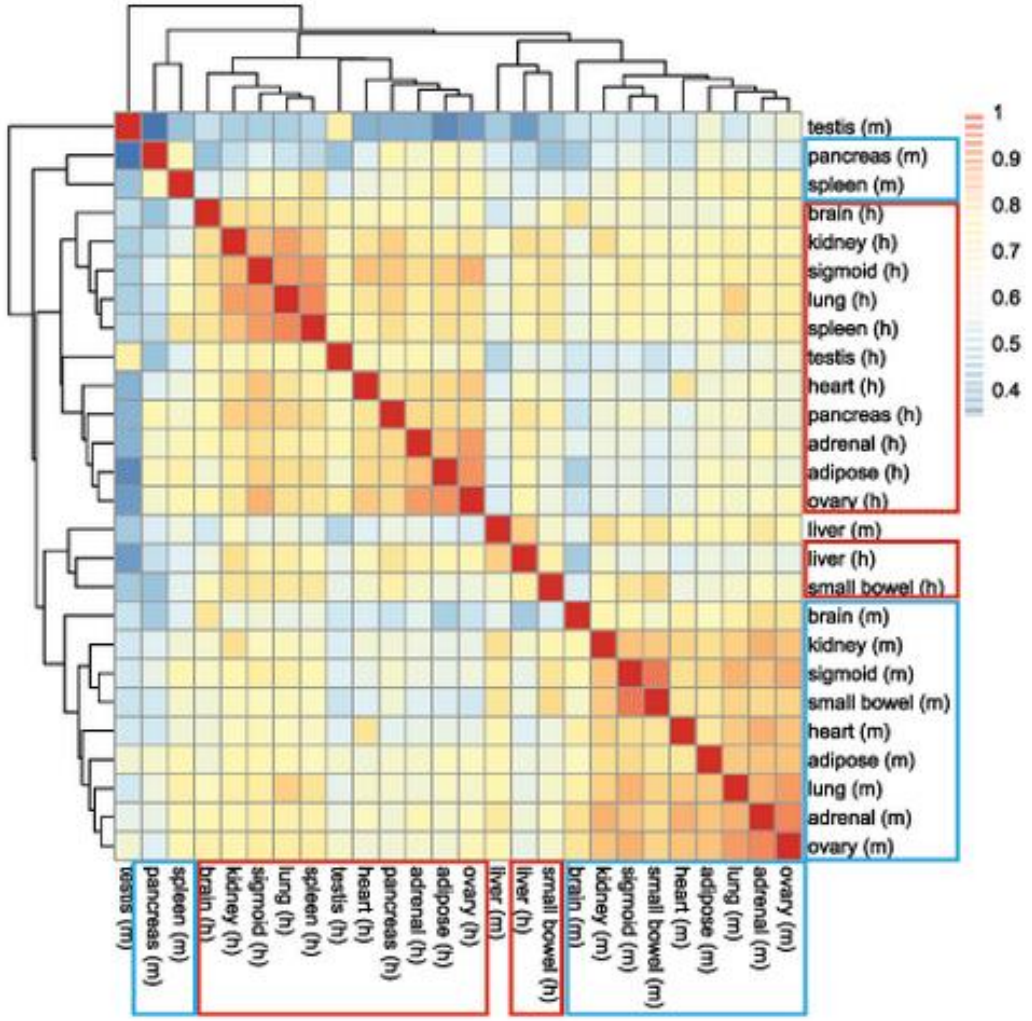
比对或定量 比对率、库类型、映射偏好

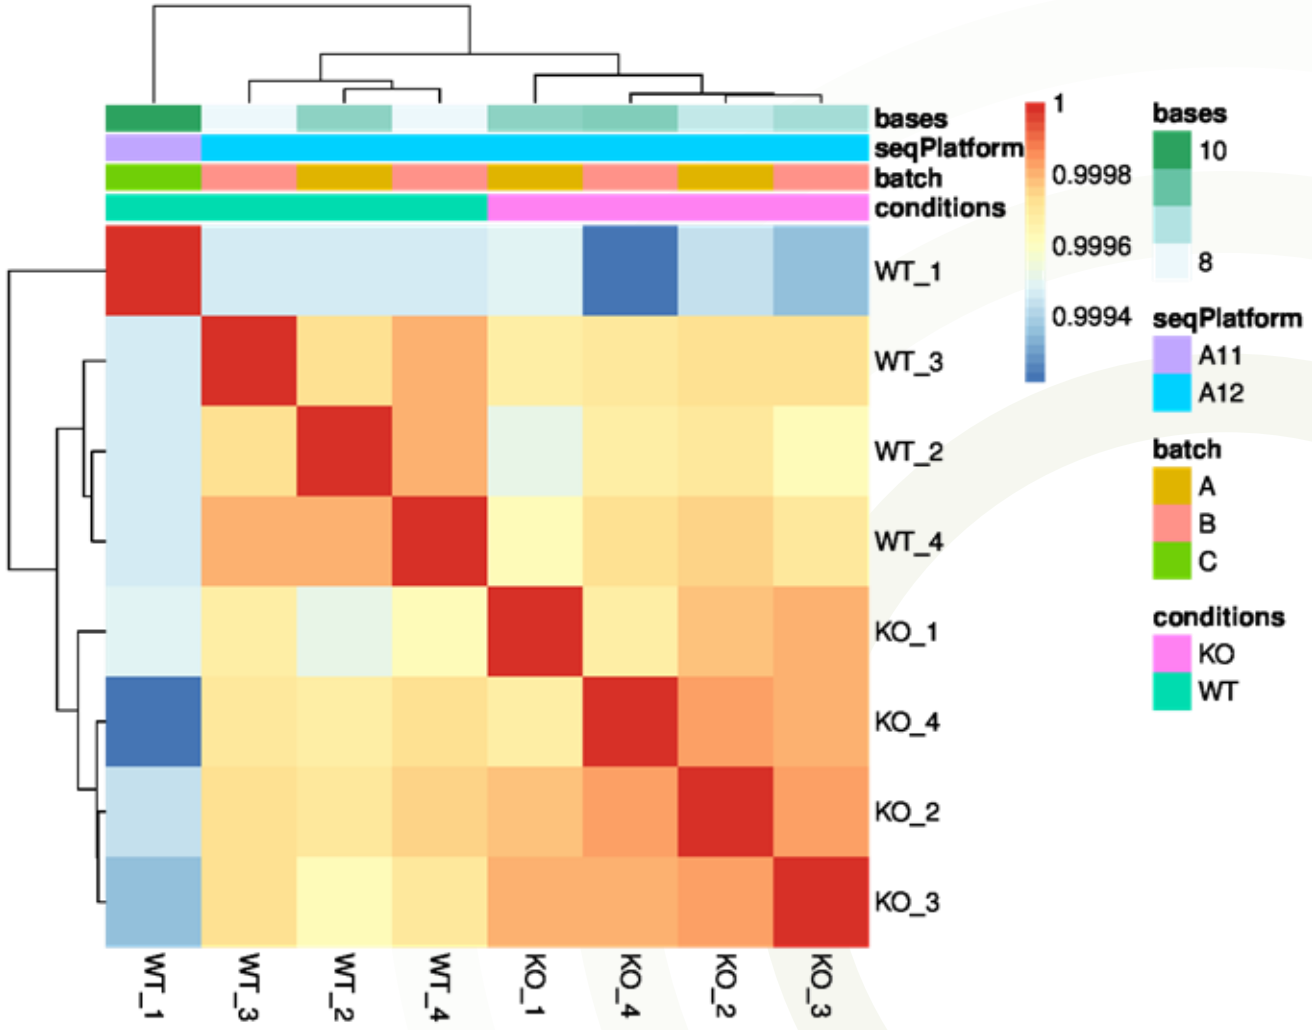
样本关系 相关性、PCA、聚类

metadata 批次、性别、时间和实验记录

样本剔除是一个会改变结论的分析决策，必须记录理由、操作过程并进行敏感性分析

从聚类结果查看批次效应：样本是否首先按批次而非条件分组?

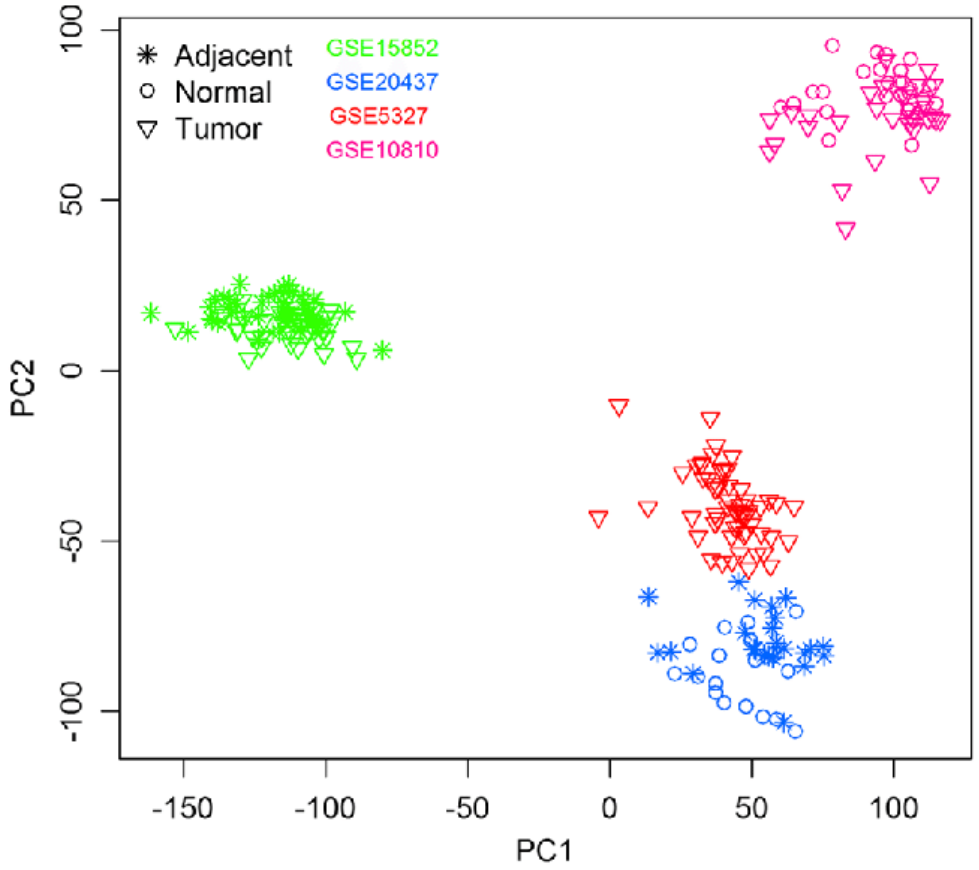




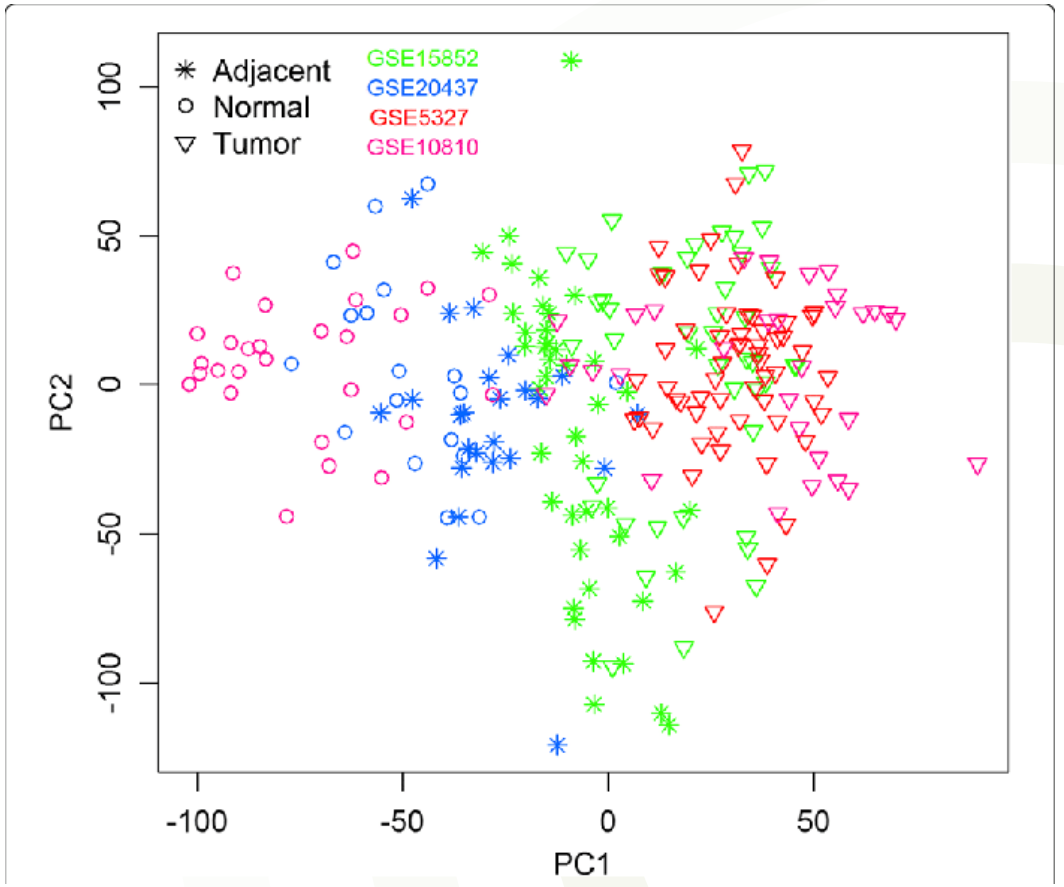
Comparison of the transcriptional landscapes between human and mouse tissues https://f1000research.com/articles/4-121

从PCA结果查看批次效应：PC1/PC2 与 batch、sex condition、或 RIN 的关系如何?

批次校正前



批次校正后



https://www.researchgate.net/figure/The-PCA-plot-after-ComBat-batch-effect-removal-The-same-set-of-samples-as-in-the_fig3_321984956

批次与处理完全重合会怎样?

处理组全部在批次 A，对照组全部在批次 B，能否估计药物效应?

可以

可以，加 batch 协变量

不能可靠分离

批次与处理完全重合会怎样?

处理组全部在批次 A，对照组全部在批次 B，能否估计药物效应?

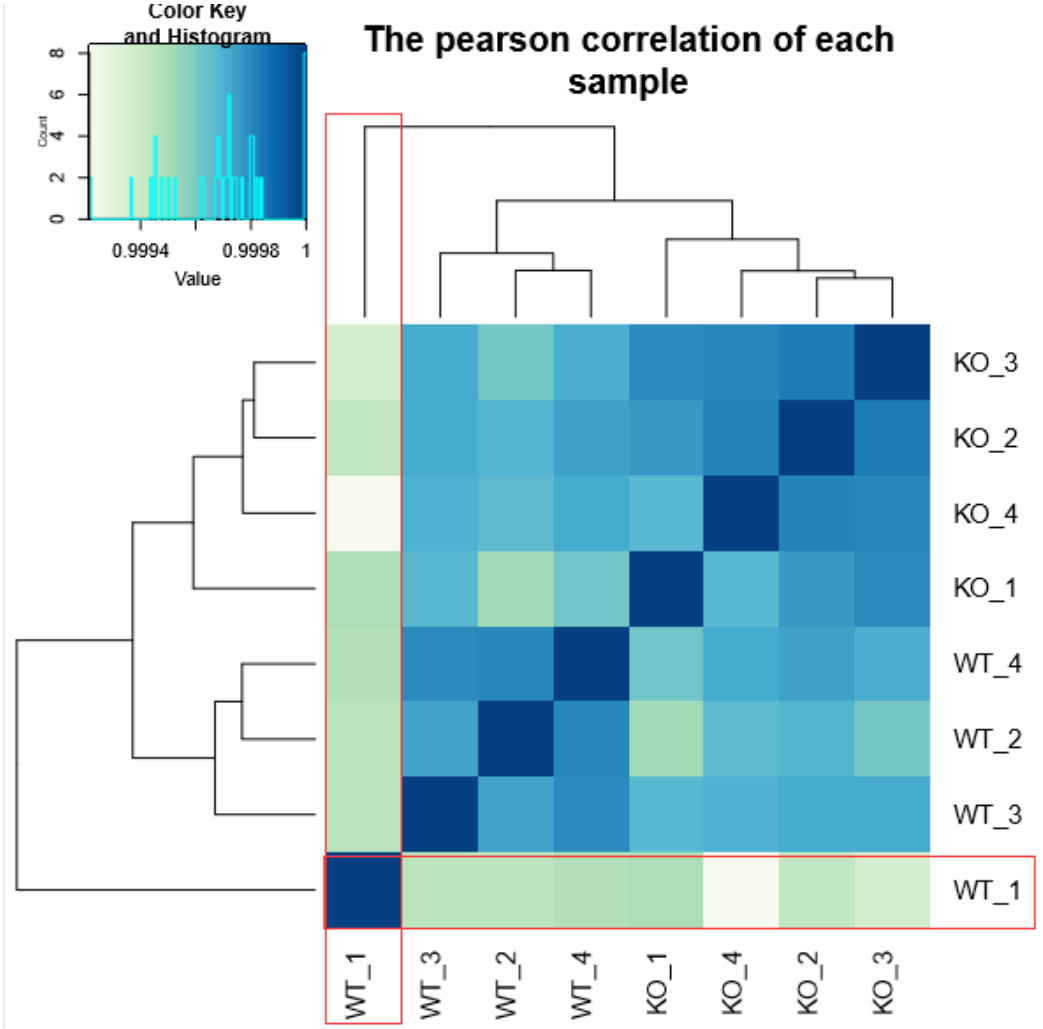
可以

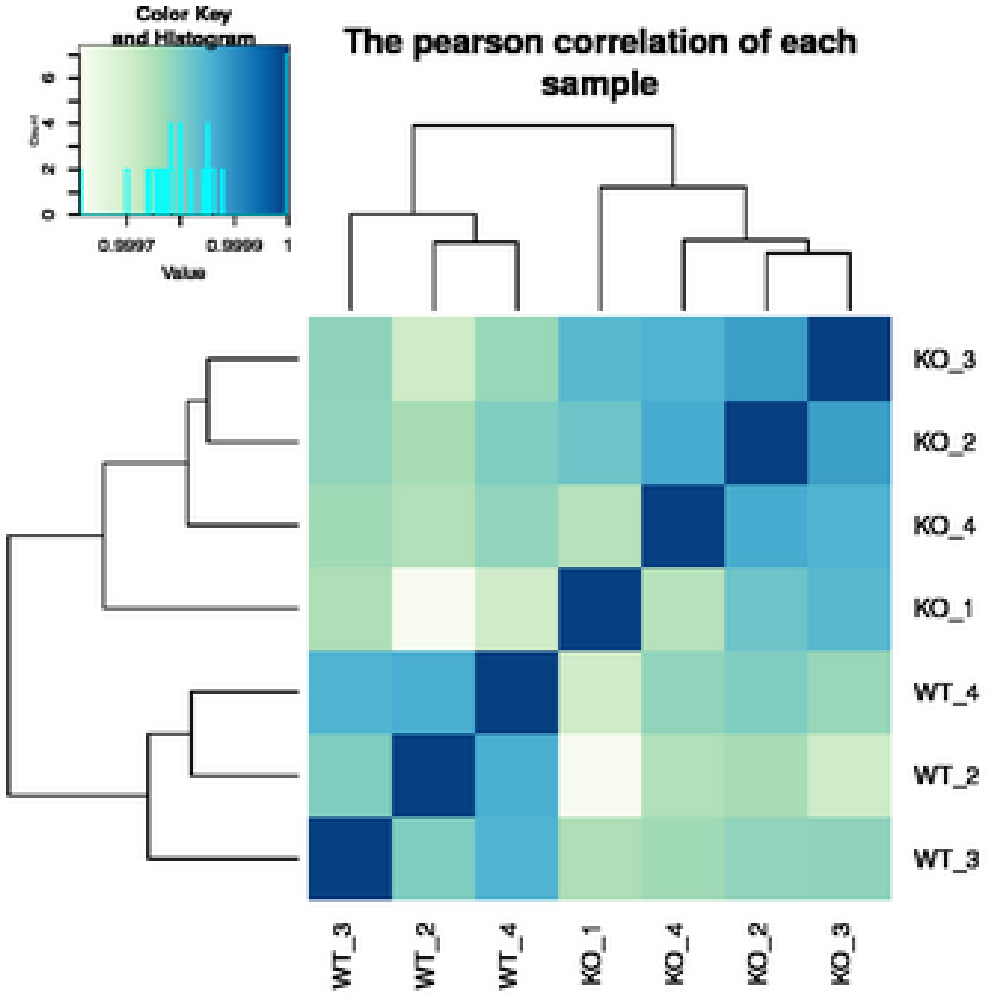
可以，加 batch 协变量

不能可靠分离

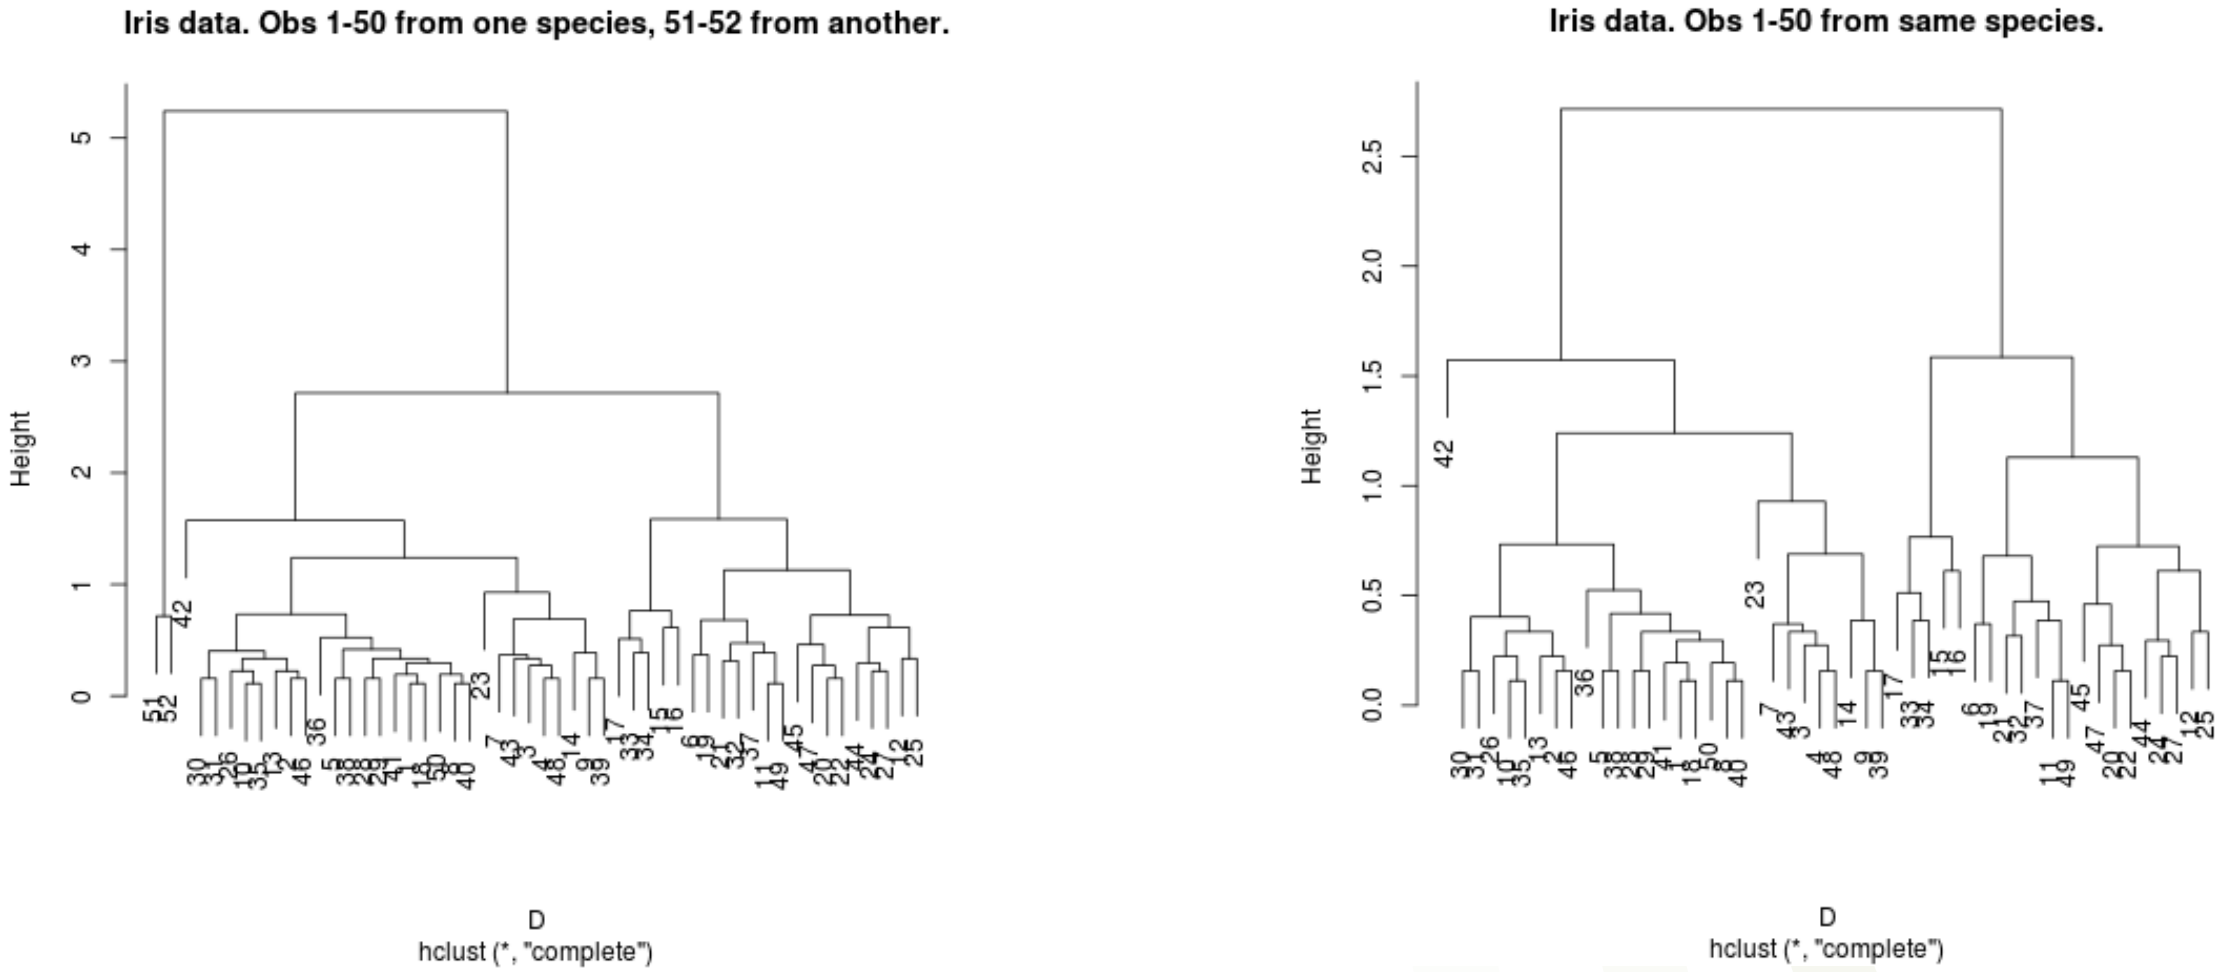
处理与批次完全混杂时，模型无法知道差异来自药物还是批次。

WT_1是不是个异常样本?





异常样品检测



https://stats.stackexchange.com/questions/101254/outlier-detection-using-clustering-and-dissimilarity-matrix-in-r

不同距离计算方法和聚类算法会得到不同的聚类结果

Cluster method

- (•) Complete
- ( ) Ward.D
- ( ) Ward.D2
- ( ) Single
- ( ) Average
- ( ) Mcquitty
- ( ) Median
- ( ) Centroid

Row distance matrix method

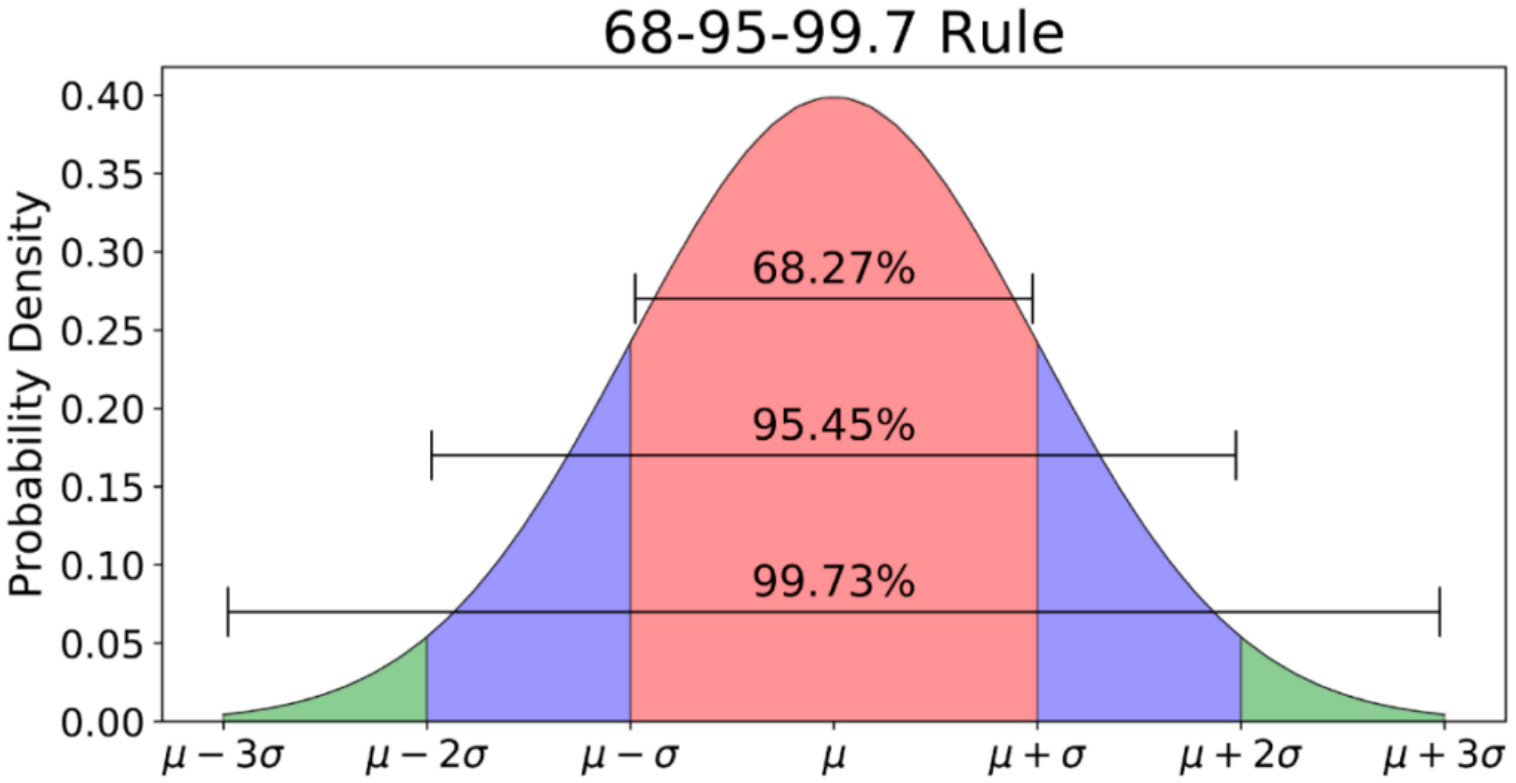
- (•) Pearson
- ( ) Euclidean
- ( ) Manhattan
- ( ) Maximum
- ( ) Canberra
- ( ) Binary
- ( ) Minkowski
- ( ) Spearman
- ( ) Bray
- ( ) Kulczynski
- ( ) Jaccard
- ( ) Gower
- ( ) AltGower
- ( ) Morisita
- ( ) Horn
- ( ) Mountford
- ( ) Raup
- ( ) Binomial
- ( ) Chao
- ( ) Cao
- ( ) Mahalanobis

Column distance matrix method

- (•) Pearson
- ( ) Euclidean
- ( ) Manhattan
- ( ) Maximum
- ( ) Canberra
- ( ) Binary
- ( ) Minkowski
- ( ) Spearman
- ( ) Bray
- ( ) Kulczynski
- ( ) Jaccard
- ( ) Gower
- ( ) AltGower
- ( ) Morisita
- ( ) Horn
- ( ) Mountford
- ( ) Raup
- ( ) Binomial
- ( ) Chao
- ( ) Cao
- ( ) Mahalanobis

高颜值免费在线绘图平台

如何鉴定一组数中的异常值?



$$Z = \frac{X - \mu}{\sigma}$$

- Z → Standard (Normal) or Z score
- X → member element of group
- μ → mean of expectation
- σ → standard deviation

一个可操作的异常样本评分思路

1

计算相似性

对每个样本计算与其他样本的 Pearson/Spearman 相关

2

汇总个体分数

将每个样本与整体的相似程度汇总为 S_i

3

标准化

把 S_i 转换为 Z 分数，标记极端偏离

4

多证据复核

与 PCA、样本质控、批次和实验记录共同判断

Z < -3 可作为候选标记，不应成为无条件删除规则。

一个可操作的异常样本评分思路

id	untrt_N080611	trt_N080611	untrt_N61311	untrt_N052611	untrt_N061011	trt_N61311	trt_N052611	trt_N061011	
untrt_N080611	1	0.9771	0.9779	0.9796	0.9757	0.9619	0.9564	0.9549	
trt_N080611	0.9771	1	0.9555	0.9636	0.9569	0.9722	0.9746	0.9727	
untrt_N61311	0.9779	0.9555	1	0.9838	0.9826	0.9764	0.9581	0.9574	
untrt_N052611	0.9796	0.9636	0.9838	1	0.9852	0.9683	0.9745	0.9654	
untrt_N061011	0.9757	0.9569	0.9826	0.9852	1	0.964	0.9631	0.9727	
trt_N61311	0.9619	0.9722	0.9764	0.9683	0.964	1	0.9803	0.9798	
trt_N052611	0.9564	0.9746	0.9581	0.9745	0.9631	0.9803	1	0.9867	
trt_N061011	0.9549	0.9727	0.9574	0.9654	0.9727	0.9798	0.9867	1	
Sum	6.7835	6.7726	6.7917	6.8204	6.8002	6.8029	6.7937	6.7896	sum(B2:B9)-1
mean	6.794325								mean(B10:I10)
sd	0.013260444								std(B10:I10)
K	-0.816337673	-1.6383313	-0.19795717	1.96637458	0.443047005	0.6466601	-0.0471327	-0.3563229	(B10-B11)/B12
Threashold	-2								
Outlier	FALSE	FALSE	FALSE	FALSE	FALSE	FALSE	FALSE	FALSE	B13<B14

排除样本前后的敏感性分析

全样本模型

保留完整设计

记录异常样本影响

查看离散度与效应量

排除后模型

重新估计标准化与离散度

比较 $\log_2$FC、padj 和富集结果

评估结论是否依赖单个样本

操作记录报告

排除决策与证据

分析前预定义还是数据驱动

对主要结论的影响

差异基因分析的几个问题

- 什么是差异基因分析?
  - 不同组间稳定表达差异的基因筛选
- 为什么要做差异基因分析?
  - 筛选靶点
- 怎么做差异基因分析?
  - 标准化
  - 统计差异检测
  - 统计筛选

差异模型中的处理、批次与性别

```
design = ~ batch + sex + condition
```

系数的含义

变量	模型中的问题
batch	在控制性别和处理后，批次 A/B 是否还有差异
sex	在控制批次和处理后，性别是否有差异
condition	在控制批次和性别后，处理是否有差异

普通转录组测序结果是混合样品的结果

ID	untrt	trt	baseMean	log2FoldChange	lfcSE	stat	pvalue	padj
ENSG00000152583	77.9	1900.4	989.1	-4.6	0.2	-21.8	7.80E-106	1.33E-101
ENSG00000148175	7233.0	19483.6	13358.3	-1.4	0.1	-16.5	1.67E-61	1.43E-57
ENSG00000179094	151.7	1380.9	766.3	-3.2	0.2	-15.9	1.01E-56	5.72E-53
ENSG00000134686	1554.0	4082.4	2818.2	-1.4	0.1	-15.2	7.07E-52	3.02E-48
ENSG00000125148	1298.0	5958.9	3628.5	-2.2	0.1	-14.9	5.70E-50	1.94E-46
ENSG00000120129	774.0	5975.5	3374.7	-2.9	0.2	-14.8	1.66E-49	4.73E-46
ENSG00000189221	426.5	4223.5	2325.0	-3.3	0.2	-14.6	3.52E-48	8.59E-45
ENSG00000109906	5.5	745.8	375.7	-7.1	0.5	-14.4	3.45E-47	7.36E-44
ENSG00000178695	4482.6	790.3	2636.4	2.5	0.2	14.1	3.80E-45	7.20E-42
ENSG00000101347	1630.2	23605.6	12617.9	-3.9	0.3	-13.9	9.73E-44	1.66E-40
ENSG00000196517	374.9	79.0	226.9	2.2	0.2	13.7	9.40E-43	1.46E-39
ENSG00000162614	2056.6	8395.4	5226.0	-2.0	0.1	-13.5	9.45E-42	1.34E-38
ENSG00000096060	311.5	4779.3	2545.4	-3.9	0.3	-13.4	7.39E-41	9.70E-38
ENSG00000162616	751.9	2167.2	1459.6	-1.5	0.1	-12.7	9.38E-37	1.14E-33
ENSG00000166741	1762.7	7600.1	4681.4	-2.1	0.2	-12.4	1.46E-35	1.66E-32
ENSG00000116584	2978.4	1479.0	2228.7	1.0	0.1	12.1	9.40E-34	1.00E-30
ENSG00000183044	305.0	681.6	493.3	-1.2	0.1	-12.0	3.12E-33	3.14E-30
ENSG00000144369	1869.9	733.6	1301.7	1.4	0.1	11.8	6.36E-32	6.03E-29

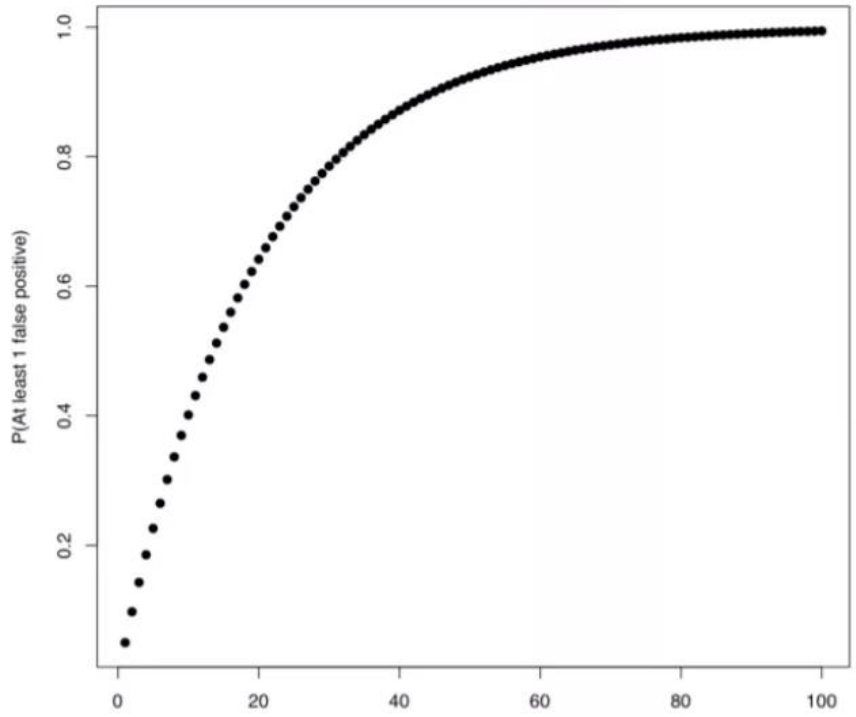
baseMean 平均标准化表达

pvalue 单个基因的检验结果

log2FoldChange 效应方向和大小

padj 多重检验校正后的结果

多重检验不能省略



同时检验的基因越多，至少出现一个假阳性的概率越高。

FDR 控制的是
被判为阳性的结果中假阳性的预期比例

常规分析中应优先报告 padj / FDR，而不是只报原始 p 值。

差异表达之外，转录组还能看什么？

结构

可变剪接

转录本切换

新转录本与融合

序列

RNA 编辑线索

等位基因表达

体细胞变异的 RNA 支持

调控层

新生 RNA、Ribo-seq

小 RNA、lncRNA、circRNA

蛋白-RNA 或 RNA-染色质互作

基因表达不变，功能也可能变

基因层

总 counts 基本不变

差异表达不显著

转录本层

isoform 1 下降

isoform 2 升高

可能产生不同结构域

实验验证

转录本特异 qPCR

长读长/克隆测序

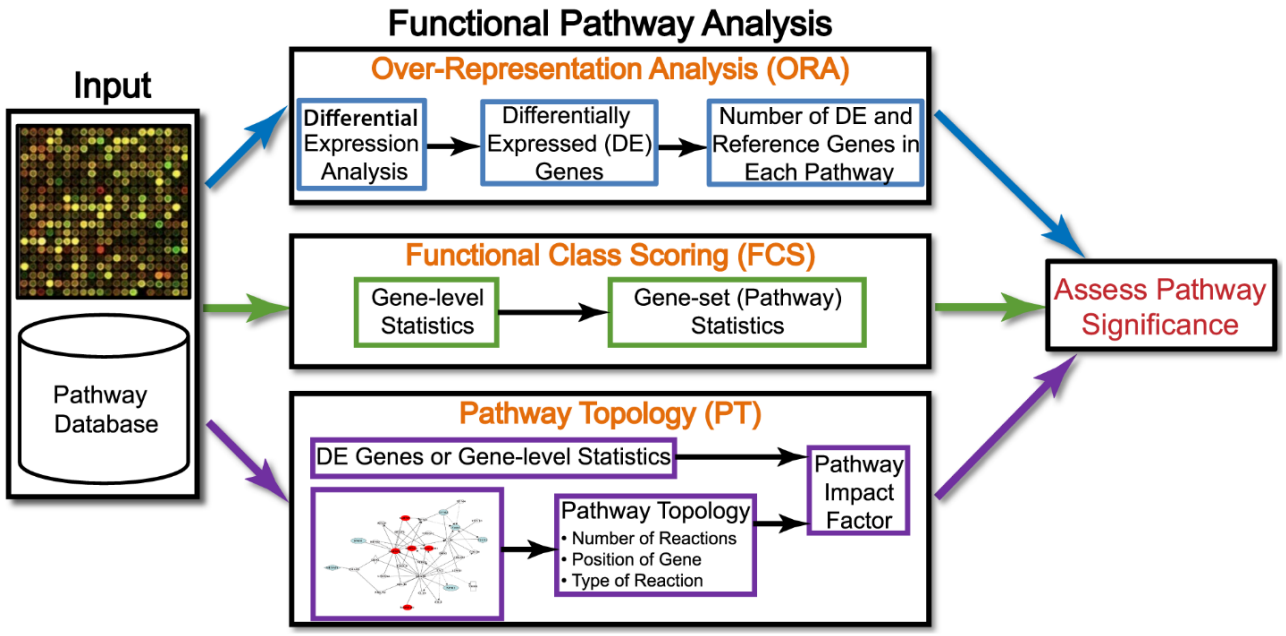
蛋白亚型或功能测定

差异转录本使用可能比差异基因表达更接近功能变化

06

功能富集与生物解释

哪些基因集或通路呈现非随机的集中趋势



ORA

输入：过阈值的基因集

问题：某类别是否过度出现

敏感于阈值和背景集

GSEA

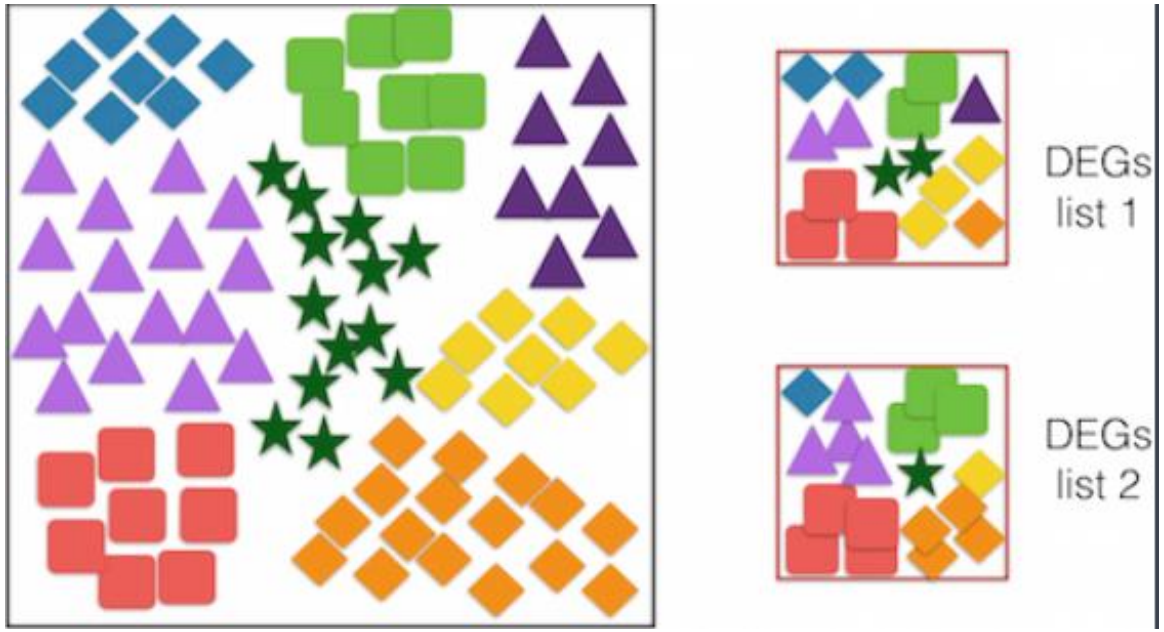
输入：所有基因的排序列表

问题：基因集是否集中在两端

敏感于排序统计量和基因集

GO 过度代表分析（ORA）

问题：差异基因列表中，某个 GO 条目的基因是否过度出现?



四个集合的交叉

- 背景基因集
- 某 GO 条目的基因集
- 差异基因集
- 差异且属于该条目的基因

背景应是实际进入检验的基因，而不是默认全基因组

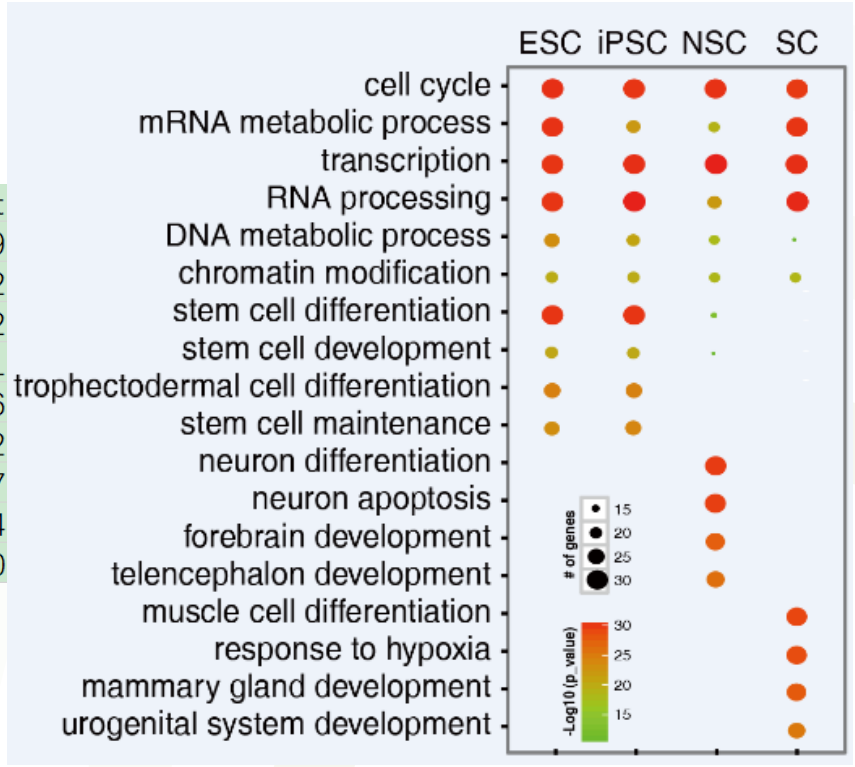
GO 背景基因集决定零假设

- 背景应是“在本实验中有机会被选中的基因”，而非随手用全基因组。
- 常见选择：通过表达过滤并进入差异检验的基因。
- 若候选基因更容易被注释或测得，不当背景会制造偏差。
- 在方法中报告背景集定义和大小。

背景集不是富集软件的技术参数，而是研究设计的延伸。

GO结果表与气泡图

ID	Description	GeneRatio	BgRatio	pvalue	p.adjust	geneID	Count
GO:0048	blood vessel morphogenesis	29/380	492/16992	2.17E-06	0.003360933	FZD8/TGFBR2/SAT1	29
GO:0030	extracellular matrix organiza	22/380	315/16992	2.60E-06	0.003360933	APBB2/CRISPLD2/CI	22
GO:0043	extracellular structure organi	22/380	316/16992	2.74E-06	0.003360933	APBB2/CRISPLD2/CI	22
GO:1901	cellular response to peptide	21/380	320/16992	1.15E-05	0.008437395	KLF15/ERRFI1/IRS2/	21
GO:0045	fat cell differentiation	16/380	204/16992	1.47E-05	0.009026139	ZBTB16/CEBPD/FOX	16
GO:1901	organonitrogen compound c	22/380	362/16992	2.35E-05	0.010478057	MAOA/SAMHD1/AB	22
GO:0072	reactive oxygen species met	17/380	236/16992	2.42E-05	0.010478057	GPX3/FOXO3/FOXC	17
GO:0008	regulation of blood pressure	14/380	168/16992	2.56E-05	0.010478057	ABAT/KCNK6/ADRA	14
GO:0001	urogenital system developm	20/380	315/16992	2.97E-05	0.010942076	ZBTB16/KLF15/ADA	20



阅读顺序：Description → GeneRatio → Count → padj → 具体 geneID

GSEA 使用全基因排序

给定一个排序的基因表 L 和一个预先定义的基因集 S (比如编码某个代谢通路的产物的基因，基因组上物理位置相近的基因，或同一GO注释下的基因)，GSEA的目的是判断 S 里面的成员 s 在 L 里面是随机分布还是主要聚集在 L 的顶部或底部。这些基因排序的依据是其在不同表型状态下的表达差异，若研究的基因集 S 的成员显著聚集在 L 的顶部或底部，则说明此基因集成员对表型的差异有贡献，也是我们关注的基因集。

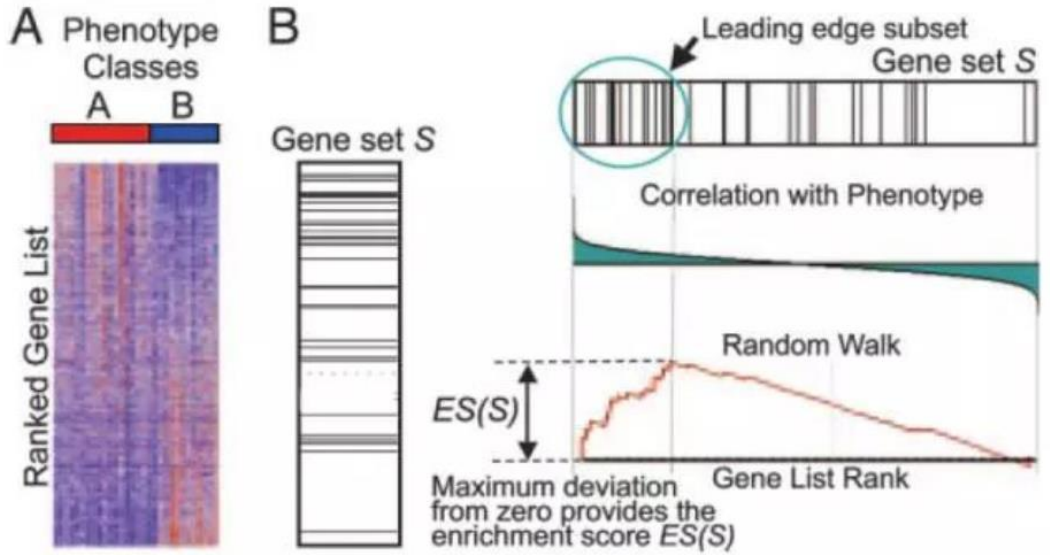


Fig. 1. A GSEA overview illustrating the method. (*A*) An expression data set sorted by correlation with phenotype, the corresponding heat map, and the "gene tags," i.e., location of genes from a set *S* within the sorted list. (*B*) Plot of the running sum for *S* in the data set, including the location of the maximum enrichment score (*ES*) and the leading-edge subset.

与 ORA 的关键区别

- 不需要先定义一条差异基因硬阈值
- 保留方向与效应大小信息
- 检查基因集成员是否集中在排序表的两端
- 结果受排序统计量和基因集定义影响

首先明确排序统计量代表什么

GSEA 排序统计量有哪些?

log_2FC

方向与效应大小直观

低信息基因可有极端估计

可配合 shrinkage

检验统计量

同时结合效应与标准误

通常更稳定

正负方向必须与 contrast 一致

自定义分数

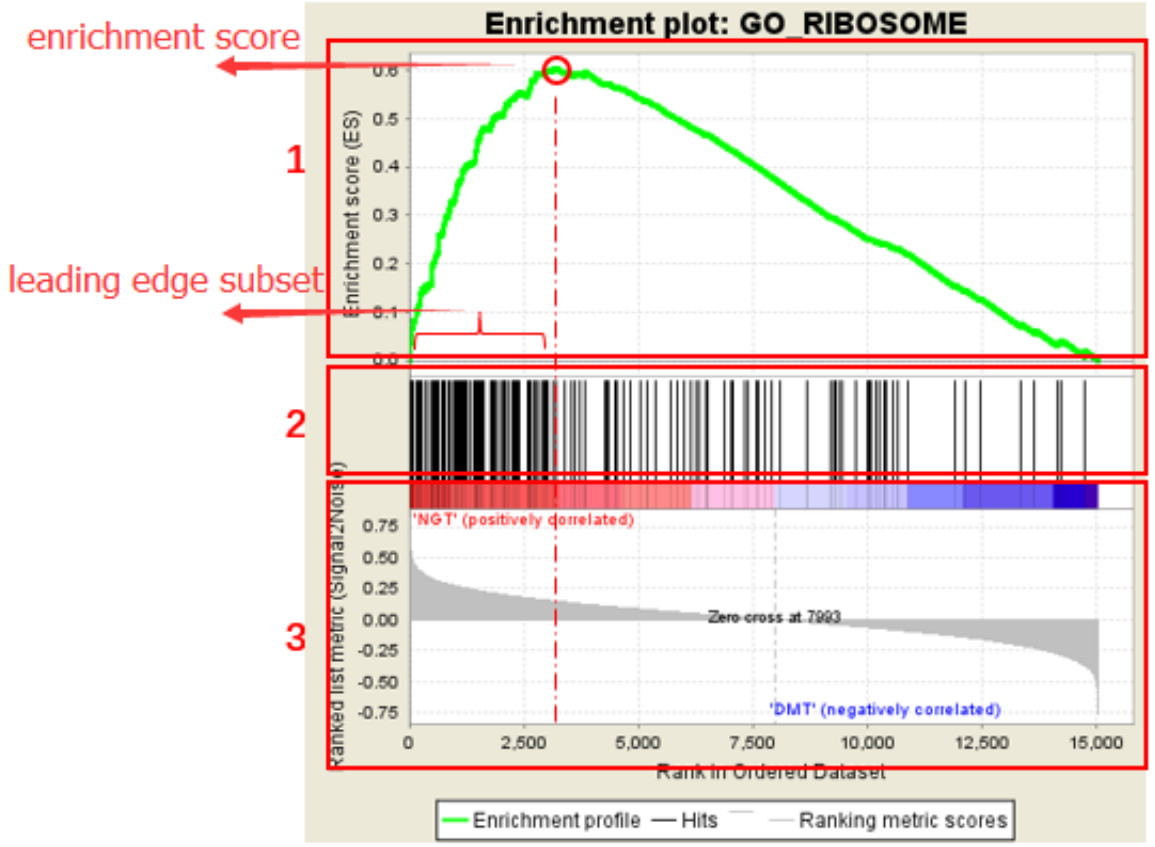
例如 $sign(log_2FC) \times -log_{10}(p)$

要处理 p=0 和无穷值

必须说明定义并做敏感性分析

排序的符号就是生物学方向；在运行前先手工检查几个已知基因。

GSEA 富集结果展示



1 Enrichment score 运行富集得分的峰值与方向

2 Gene hits 基因集成员在排序列表中的位置

3 Ranking metric 所有基因的排序统计量分布

leading-edge genes 是对 ES 贡献最大的核心子集

普通转录组测序结果是混合样品的结果

比较维度	GO ORA	GSEA
输入	阈值后的基因列表	全基因排序
优点	直观、计算简单	保留弱但协同的信号
敏感因素	基因阈值与背景集	排序统计量与基因集
主要问题	差异基因中哪些功能过度出现	某基因集是否在整体排序的一端集中

两者结论一致时信心更高，不一致时需回到输入和假设

转录组数据检测的一套清单

- ✓ 实验分组与 metadata 可以回答研究问题
- ✓ FASTQ 质控异常已经追查，而不是机械删除
- ✓ 参考序列、GTF 和 ID 版本一致
- ✓ 差异分析使用合适的 counts 和设计公式
- ✓ 样本关系、批次与异常值已检查
- ✓ 富集结果已回到核心基因和原始表达

感 谢 各 位 专 家 ， 请 多 多 批 评 指 导 ！